DEPARTAMENTO DE ELÉCTRICA, ELECTRÓNICA Y TELECOMUNICACIONES

CARRERA DE TELECOMUNICACIONES

TEMA: EVALUAR DE FORMA CUANTITATIVA EL POTENCIAL DE LAS TÉCNICAS DE INTELIGENCIA ARTIFICIAL EN LA LOCALIZACIÓN DE DISPOSITIVOS MEDIANTE INFORMACIÓN DEL ESTADO DE CANAL (CSI)

Autores: James Marshall Flores Proaño & Kevin Alexis Logroño López

Director del proyecto: Ing. Enrique Vinicio Carrera Erazo, PhD.

AGENDA

CONTENIDO

1 INTRODUCCIÓN

2 BASE DE DATOS

3 DESARROLLO

4 RESULTADOS

5 CONCLUSIONES

INTRODUCCIÓN

SISTEMAS DE POSICIONAMIENTO

Ambientes Exteriores

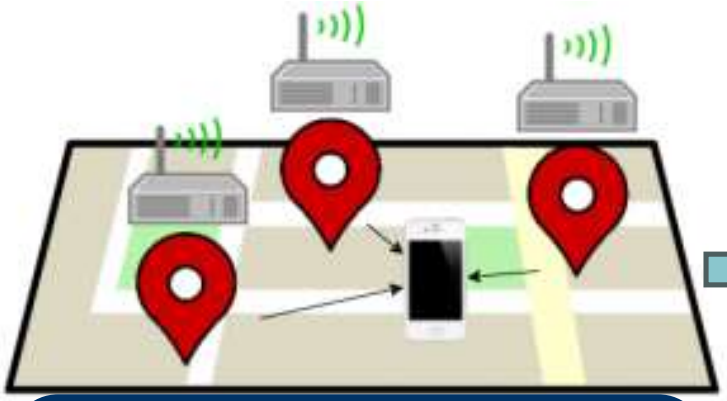

Ambientes Interiores

Precisión

ANTECEDENTES Y JUSTIFICACIÓN

GPS

- (Mautz et al., 2010)
- Análisis en 1D y 2D
- Error cuadrático medio de 5[m] y 7[m]

Fingerprints de Wifi

- (Ranimol & Swapna B, 2018a)
- Uso de Autoencoders
- 93% de precisión

Fingerprints de Bluetooth

- (Ranimol & Swapna B, 2018b)
- Uso de k-NN y FkNN
- 99.83% de precisión

Método Tradicional

Métodos con ML para clasificación

CFR 5G

+

IA

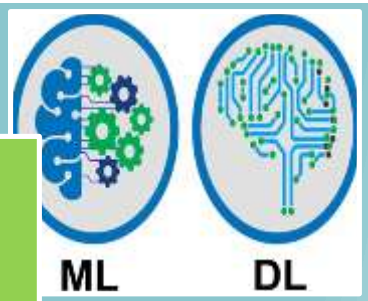

Método Propuesto

ESPE
UNIVERSIDAD DE LAS FUERZAS ARMADAS
INNOVACIÓN PARA LA EXCELENCIA

OBJETIVOS

Objetivo General

Evaluar de forma cuantitativa el potencial de las técnicas de Inteligencia Artificial en la localización de dispositivos mediante Información del Estado del Canal (CSI).

Objetivos Específicos

- Realizar un estudio de los trabajos relacionados más significativos en la localización de dispositivos.
- Buscar y escoger una base de datos relacionada con la Información del Estado de Canal de un escenario.
- Diseñar un sistema de posicionamiento basado en IA, empleando algoritmos de ML y DL
- Recopilar los resultados de cada algoritmo, realizar un análisis cuantitativo y establecer conclusiones.

Materiales

IEEE DataPort

Computador Personal

Matlab Online

BASE DE DATOS

Escenario

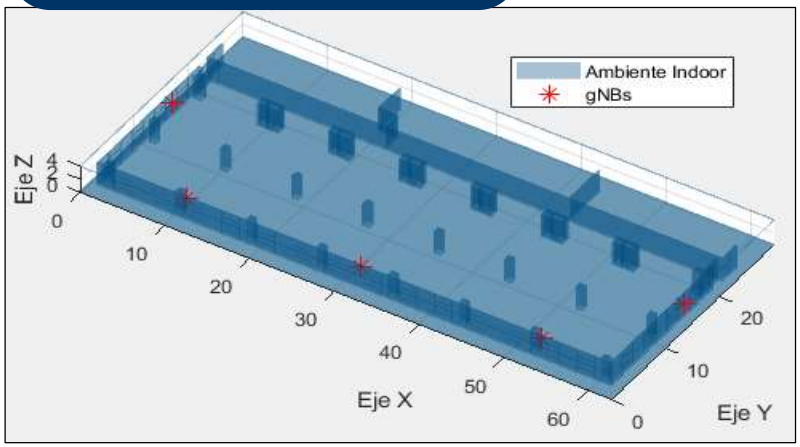

- ✓ **Dimensiones escenario:** 60.5 x 20 x 2.4 [m]
- ✓ **Rango en X:** 4.4 [m] - 58.4 [m]
- ✓ **Rango en Y:** 4.3 [m] – 16.3 [m]
- ✓ **Rango en Z:** 1.2 [m] – 1.7 [m]
- ✓ **Distanciamiento entre muestras:** 0.5 [m]

Comunicación gNB - UE

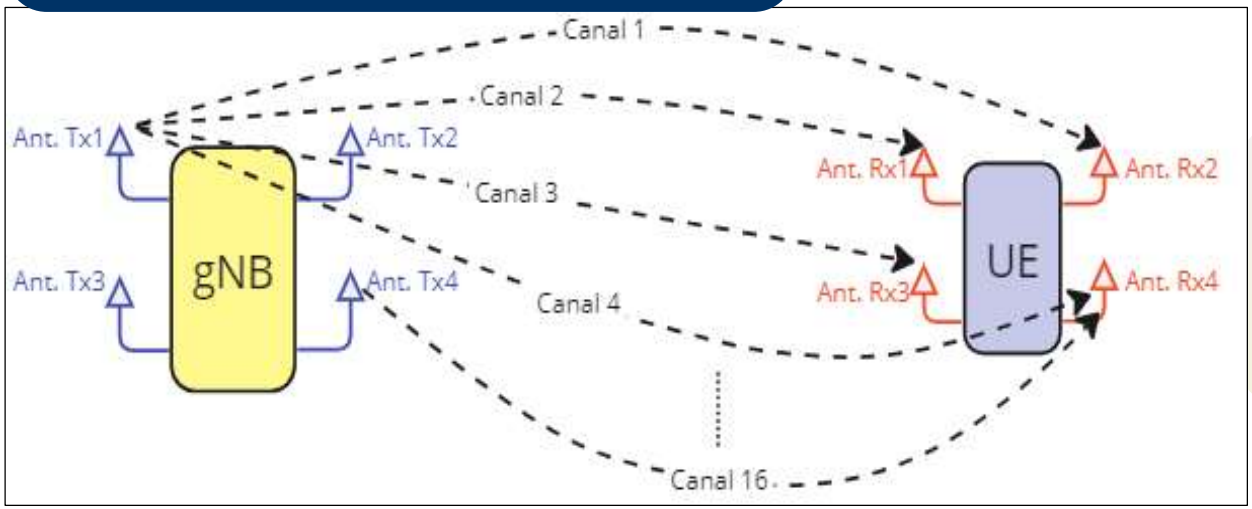

- ✓ **Sistema:** MIMO 4x4
- ✓ **Multiplexación:** OFDM
- ✓ **Frecuencia Portadora:** 3.5 [GHz]
- ✓ **Orden reflexión:** 2
- ✓ **Orden penetración:** 1

BASE DE DATOS

Estructura de datos

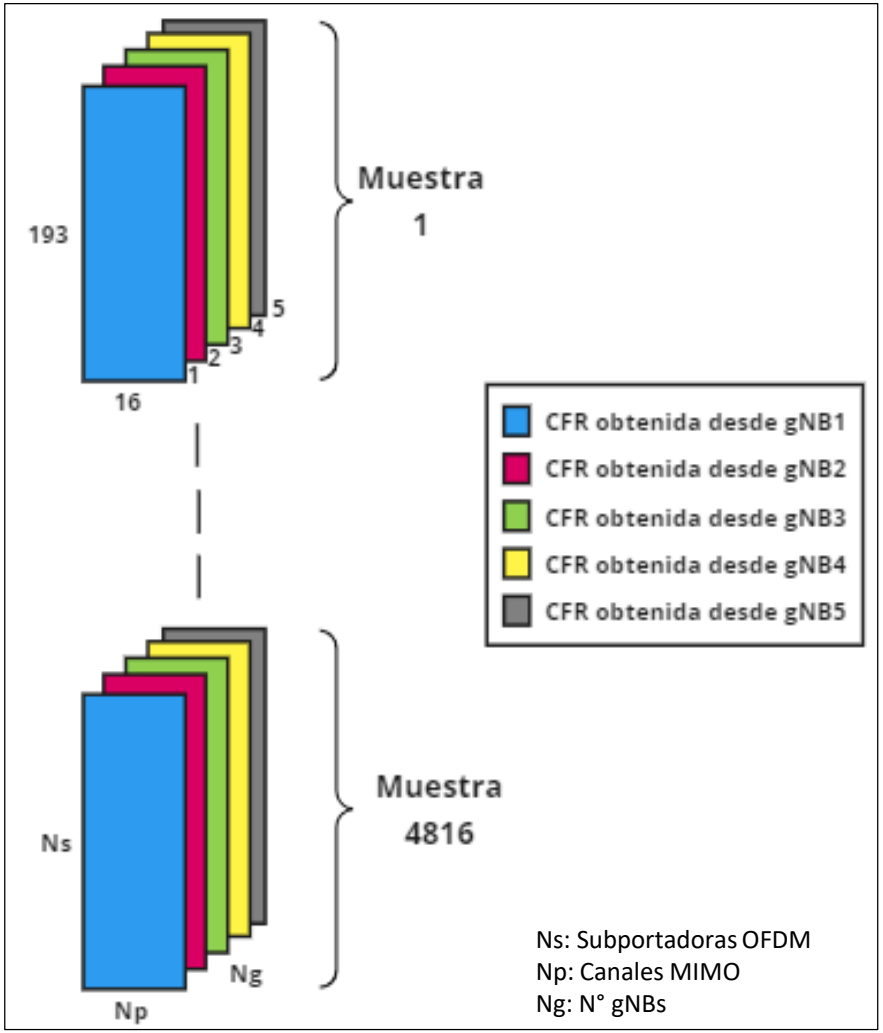

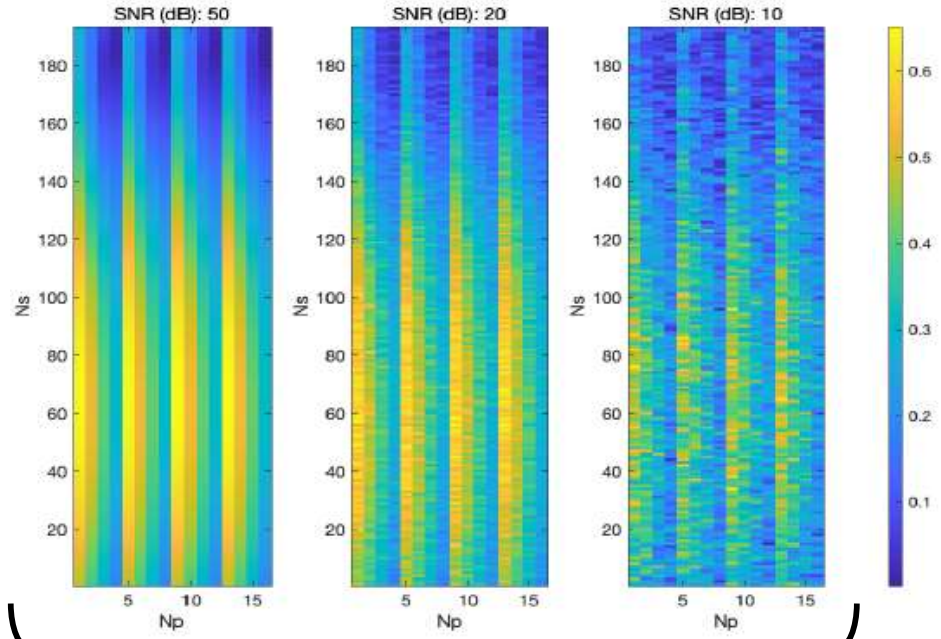

CARACTERÍSTICAS

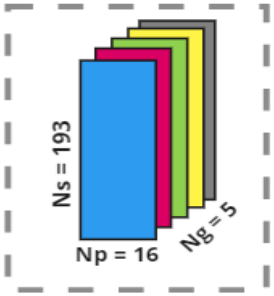

3Nu = 14448

ETIQUETAS

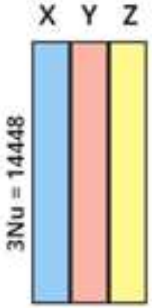

Metodología

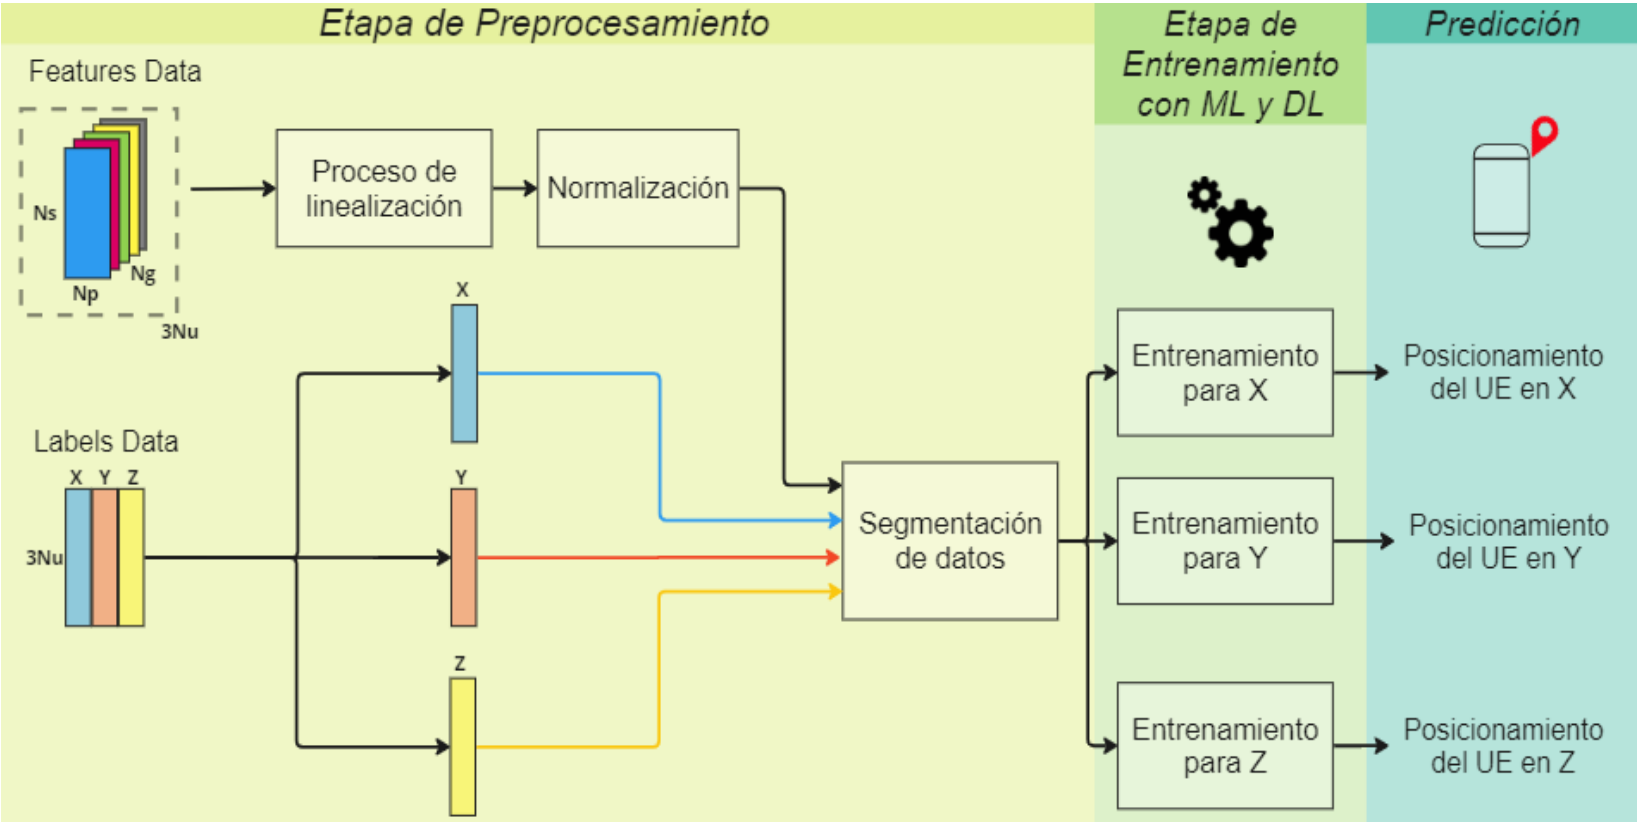

Etapa de Preprocesamiento

Linealización de datos

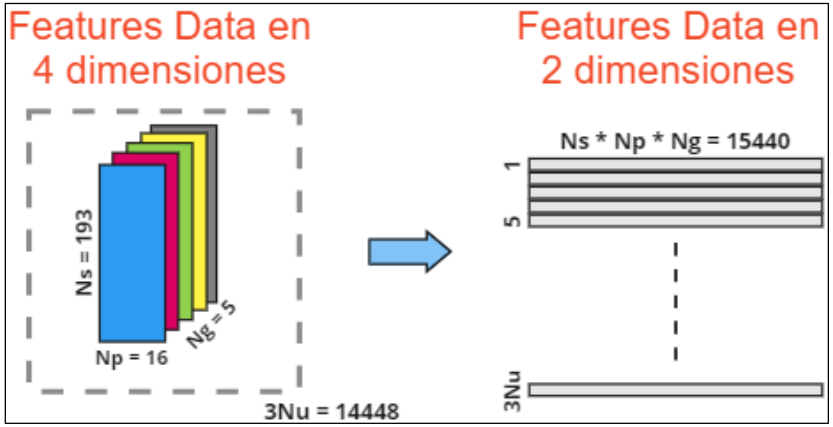

Normalización ZScore

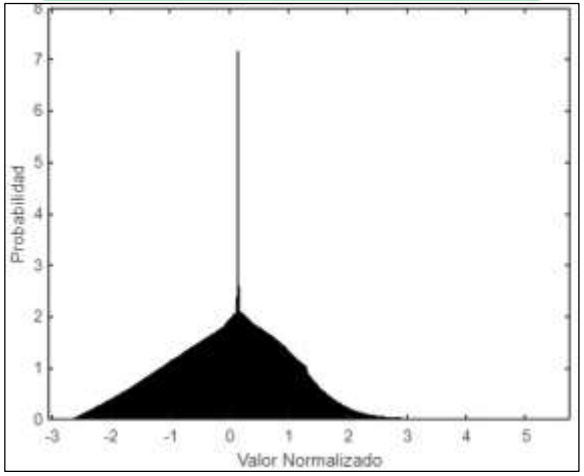

Segmentación Tipo A

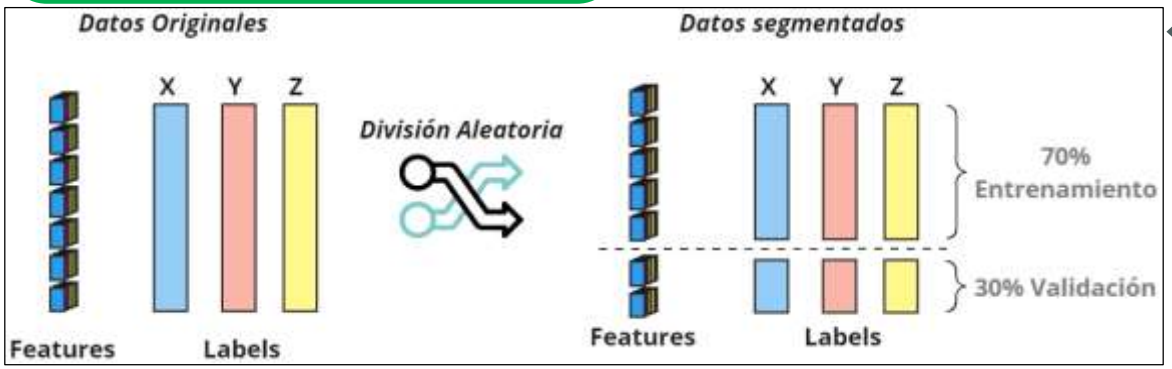

DESARROLLO

MODELOS DE APRENDIZAJE AUTOMÁTICO

1. Regresión Lineal (LR)
2. Árbol de Regresión (RT)
3. Redes Neuronales (ANN)
4. Redes Neuronales Profundas (DNN)
5. Redes Neuronales Convolucionales (CNN)

Etapa de Entrenamiento con ML Tradicional

Regresión Lineal

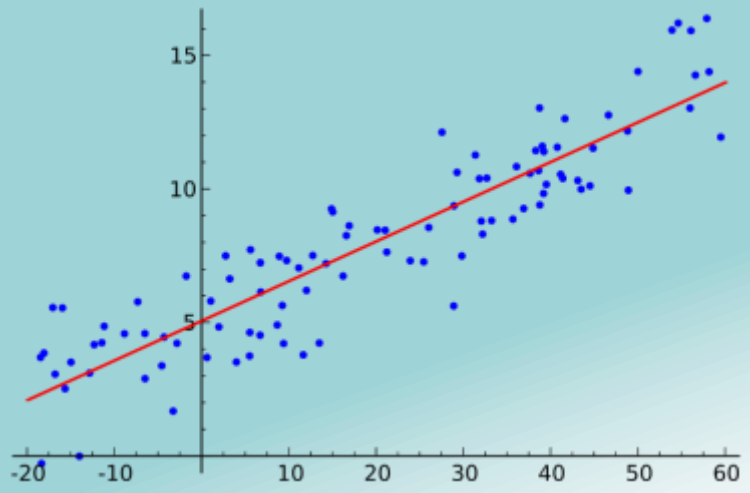

Árbol de Regresión (RT)

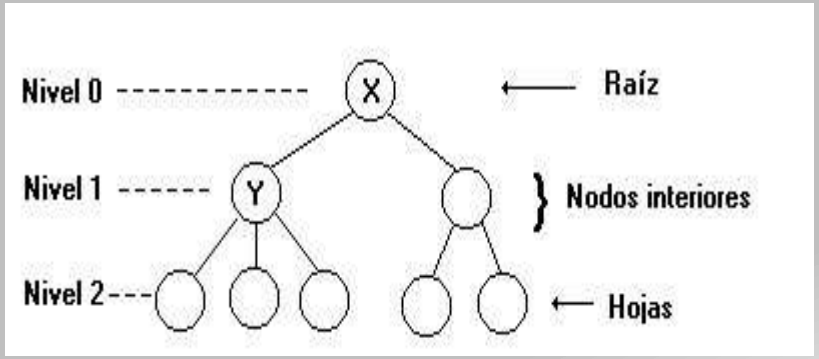

Configuración inicial

Configuración optimizada

Entrenamiento con Deep Learning

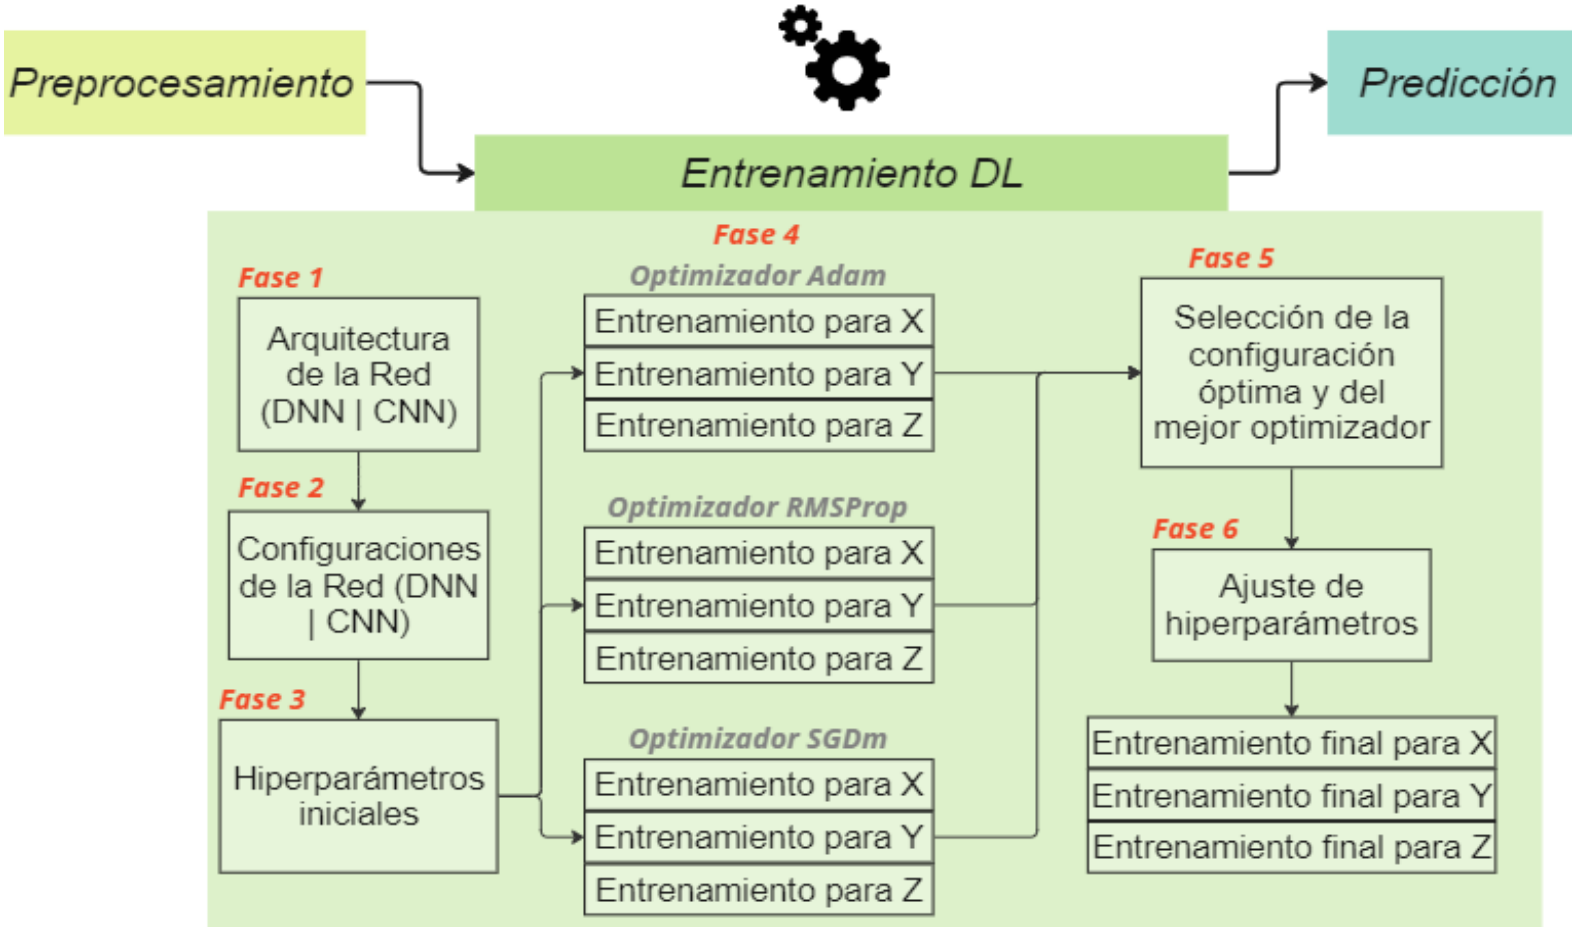

DESARROLLO

Arquitectura de la DNN

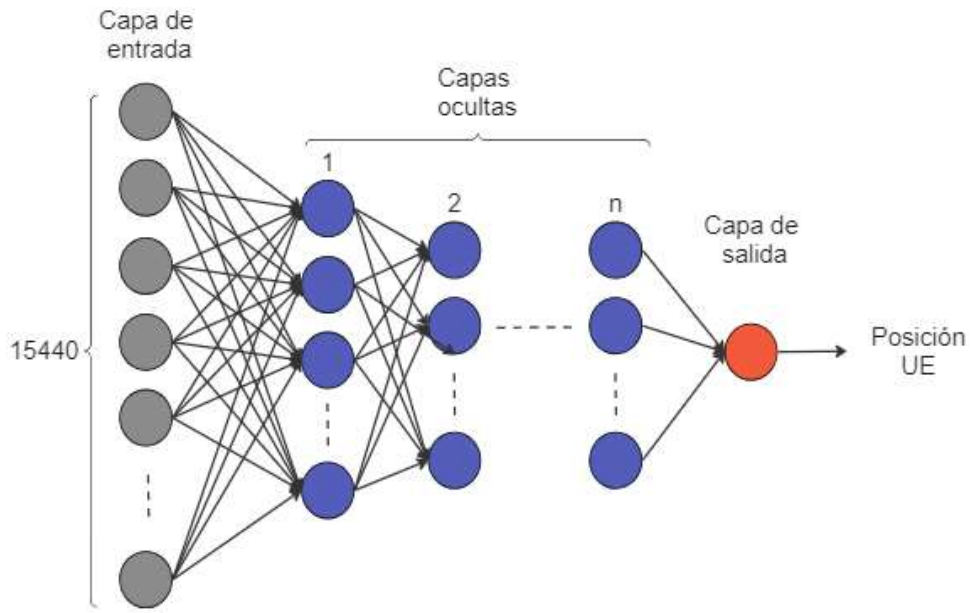

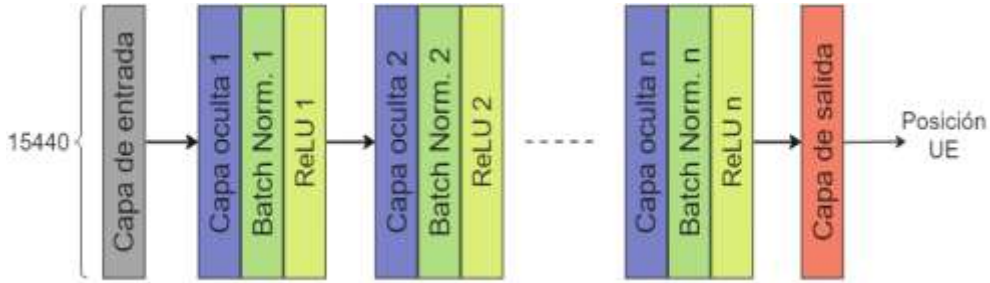

Configuraciones de la DNN

- N° capas ocultas
- N° neuronas

0 → ANN
1 → DNN1
2 → DNN2
3 → DNN3
4 → DNN4
5 → DNN5

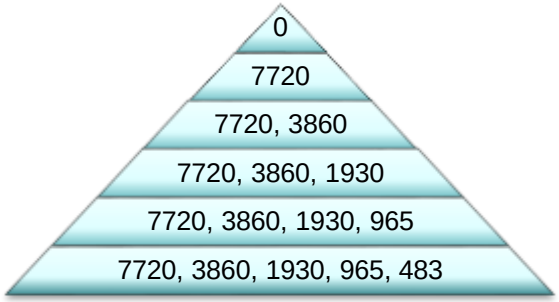

Hiperparámetros iniciales

Tasa de aprendizaje → 0.001
N° Épocas → 100
Batch Size → 128

Arquitectura de la CNN

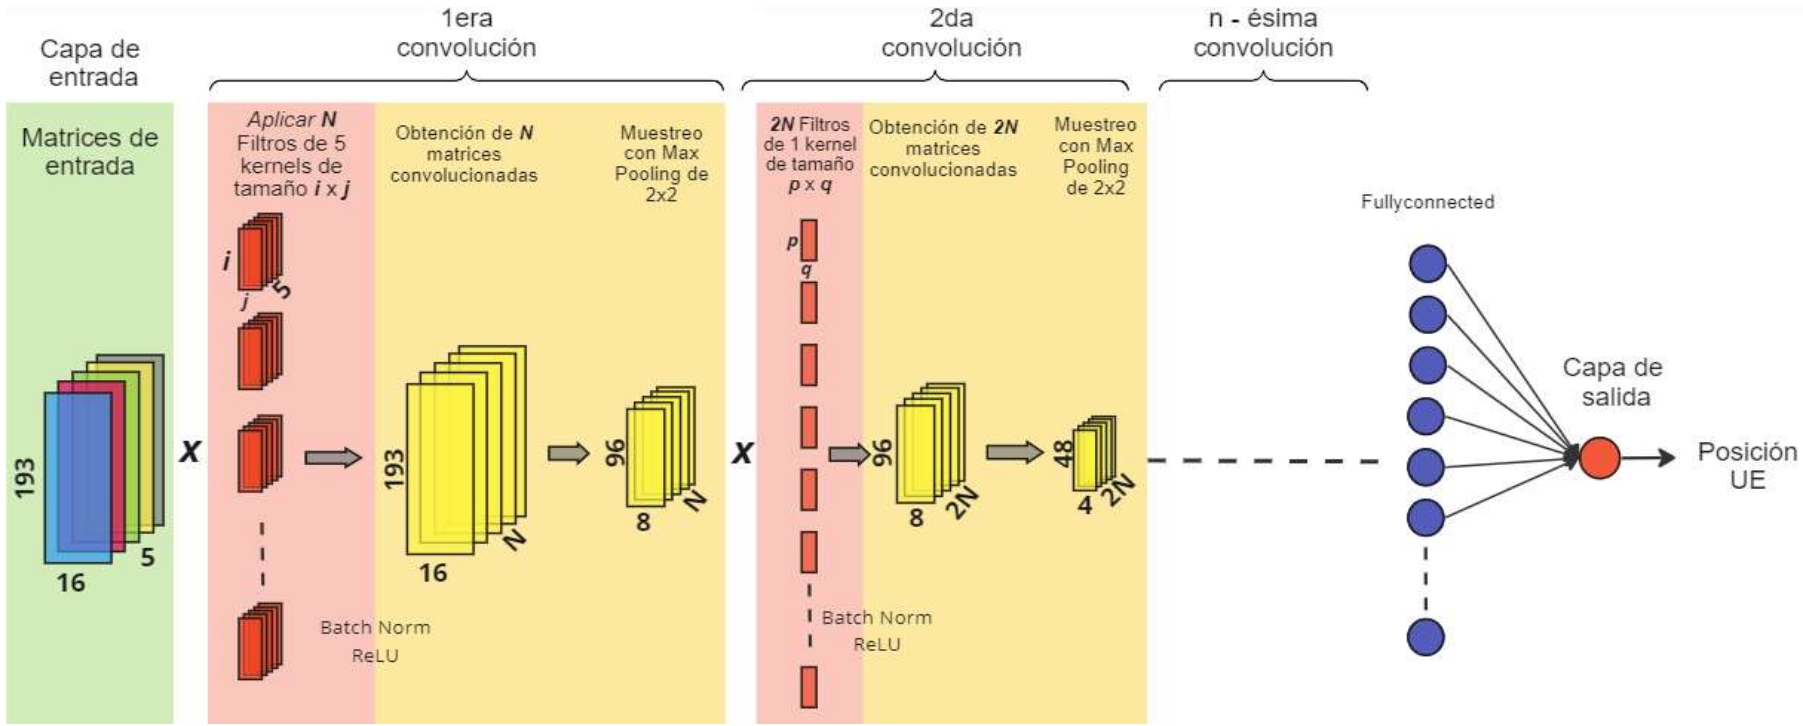

Configuraciones de la CNN

Capa 1 → 32 Filtros de 5 kernels [7x3]
Capa 2 → 64 Filtros [3x3]
Capa 3 → 128 Filtros [5x3]
Capa 4 → 256 Filtros [3x3]

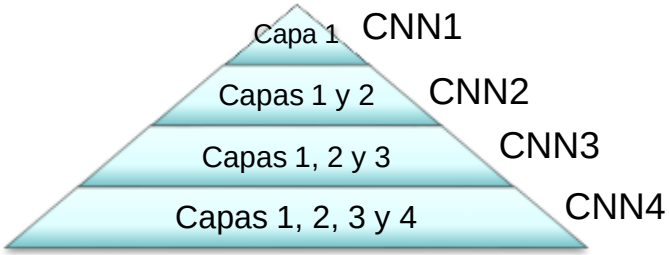

Hiperparámetros iniciales

Tasa aprendizaje → 0.001
N° Épocas → 80
Batch Size → 128

RESULTADOS ML TRADICIONAL Y DL

RMSE con ML Tradicional

Modelo	Coordenada X	Coordenada Y	Coordenada Z
Regresión Lineal	138.5307 [m]	28.9687 [m]	2.7505 [m]
RT Inicial	9.2527 [m]	2.4215 [m]	0.2155 [m]
RT optimizado	8.6631 [m]	2.3131 [m]	0.2124 [m]
ANN	15.393 [m]	3.54 [m]	0.55 [m]

DNN Inicial

Optimizador	Coordenada X	Coordenada Y	Coordenada Z
Adam	2.114 [m]	0.723 [m]	0.192 [m]
RMSProp	3.291 [m]	1.708 [m]	0.368 [m]
SGDm	2.217 [m]	0.774 [m]	0.334 [m]

- ✓ **Configuración:** DNN4
- ✓ **Tasa de Aprendizaje:** 0.001
- ✓ **Batch Size:** 128
- ✓ **Épocas:** 100

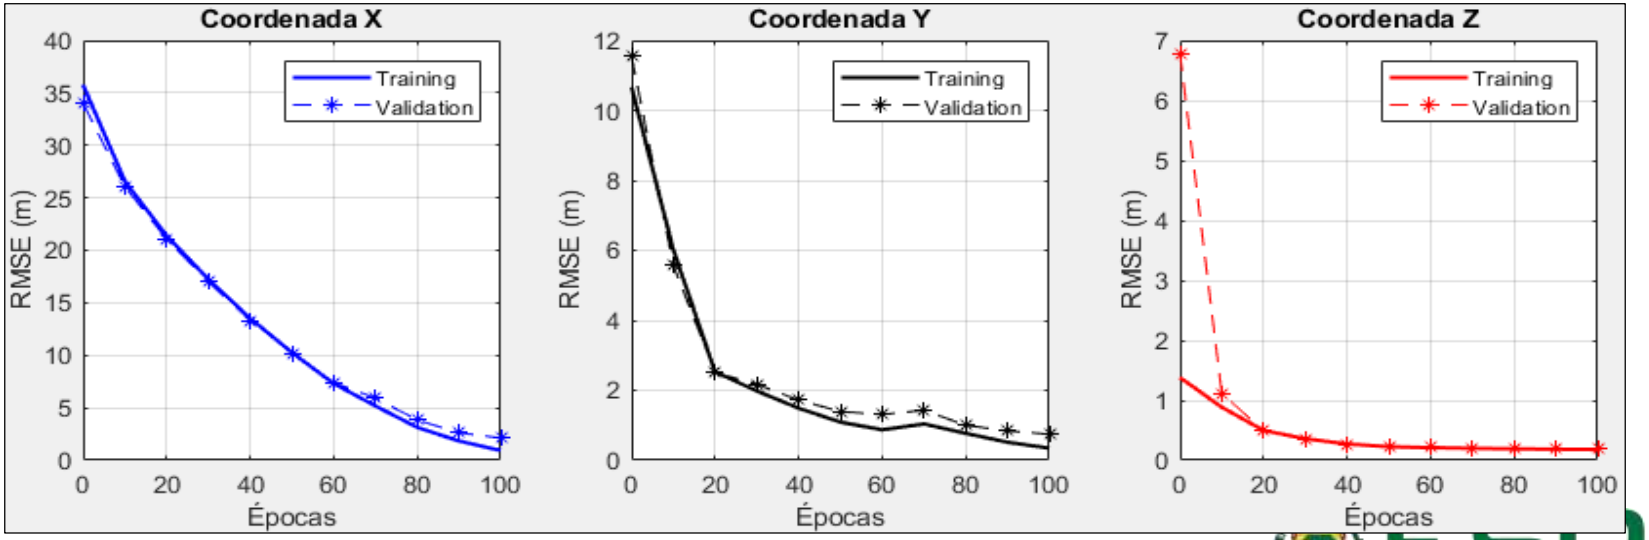

RESULTADOS DEEP LEARNING

DNN Optimizada

Parámetro	Coordenada X	Coordenada Y	Coordenada Z
Épocas	150	150	100
Tasa de Aprendizaje	0.001	0.001	0.001
Regularización	Dropout 35%	Dropout 30%	-
RMSE [m]	1.696	0.6496	0.1926

- ✓ **Configuración:** DNN4
- ✓ **Optimizador:** Adam
- ✓ **Tasa de Aprendizaje:** 0.001
- ✓ **Batch Size:** 128

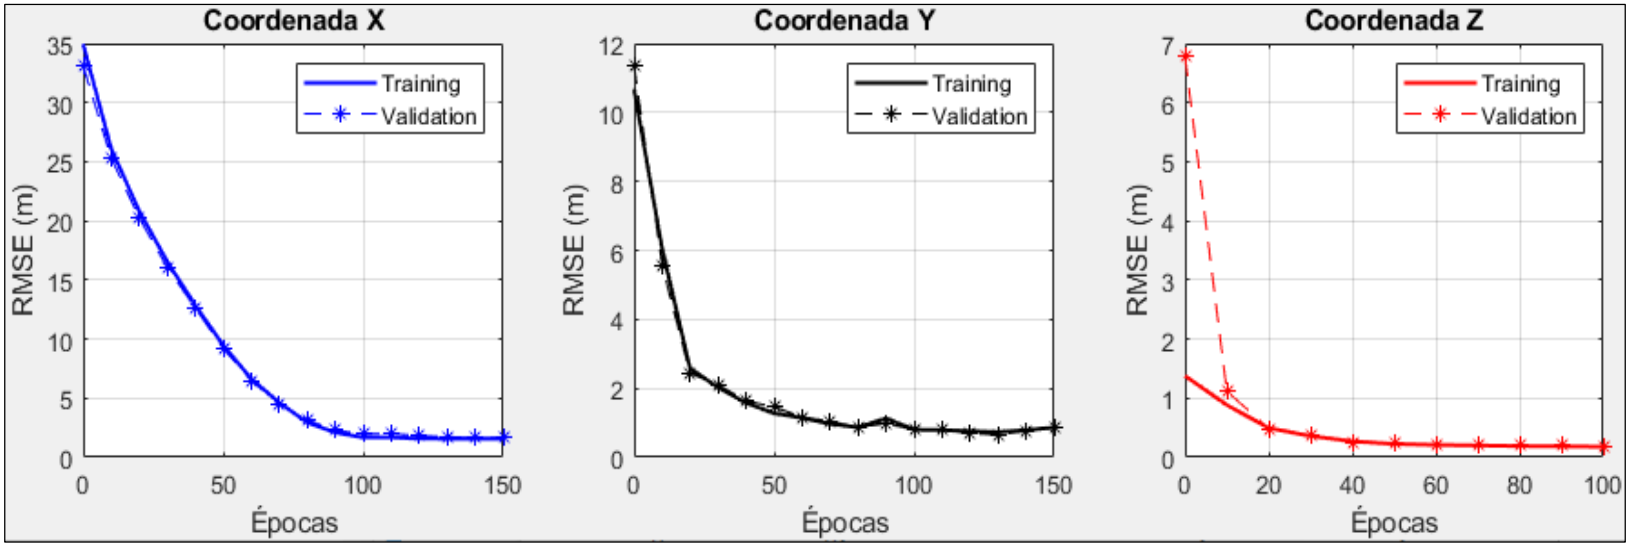

RESULTADOS DEEP LEARNING

CNN Inicial

Optimizador	Coordenada X	Coordenada Y	Coordenada Z
Adam	1.0164 [m]	0.4882 [m]	0.0669 [m]
RMSProp	0.8369 [m]	0.4702 [m]	0.0713 [m]
SGDm	1.3735 [m]	0.5338 [m]	0.1389 [m]

- ✓ **Configuración:** CNN4
- ✓ **Tasa de Aprendizaje:** 0.001
- ✓ **Batch Size:** 128
- ✓ **Épocas:** 80

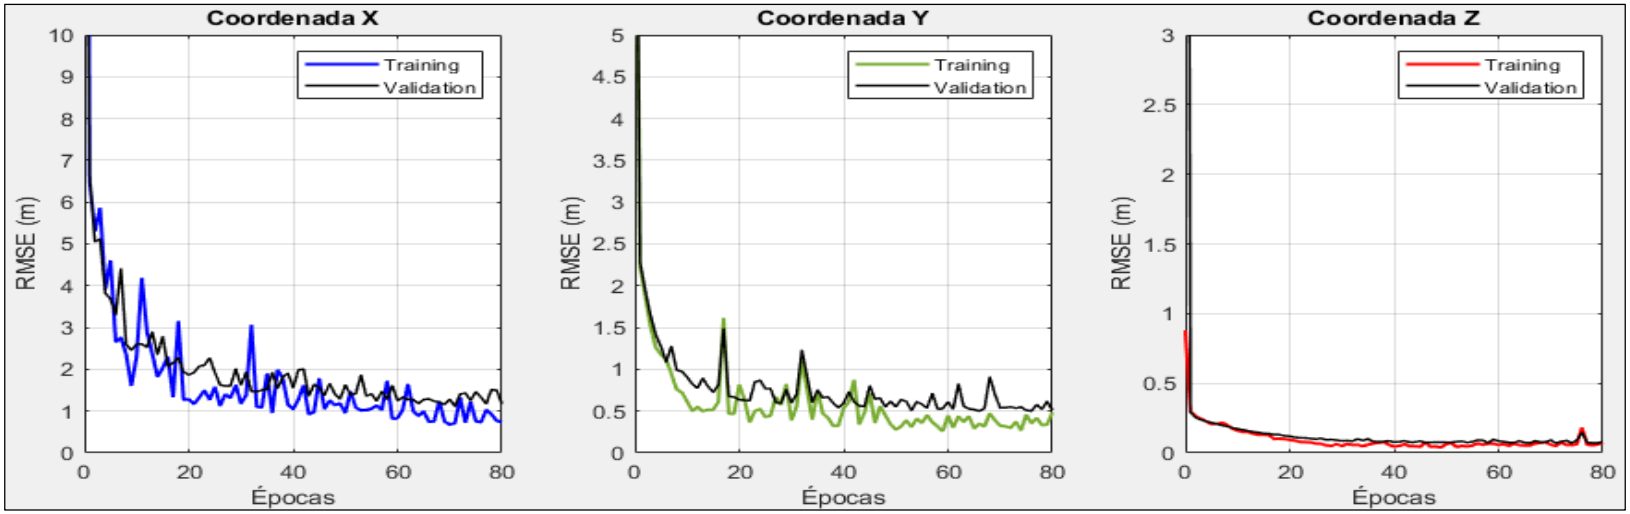

RESULTADOS DEEP LEARNING

CNN Optimizada

Parámetro	Coordenada X	Coordenada Y	Coordenada Z
Épocas	100	50	30
Factor de caída de la tasa	0.3 @40 épocas	0.02 @ 40 épocas	0.1 @ 20 épocas
RMSE [m]	0.3729	0.3851	0.0378

- ✓ **Configuración:** CNN4
- ✓ **Optimizador:** RMSProp
- ✓ **Tasa de Aprendizaje:** 0.001
- ✓ **Batch Size:** 32
- ✓ **Regularización:** No

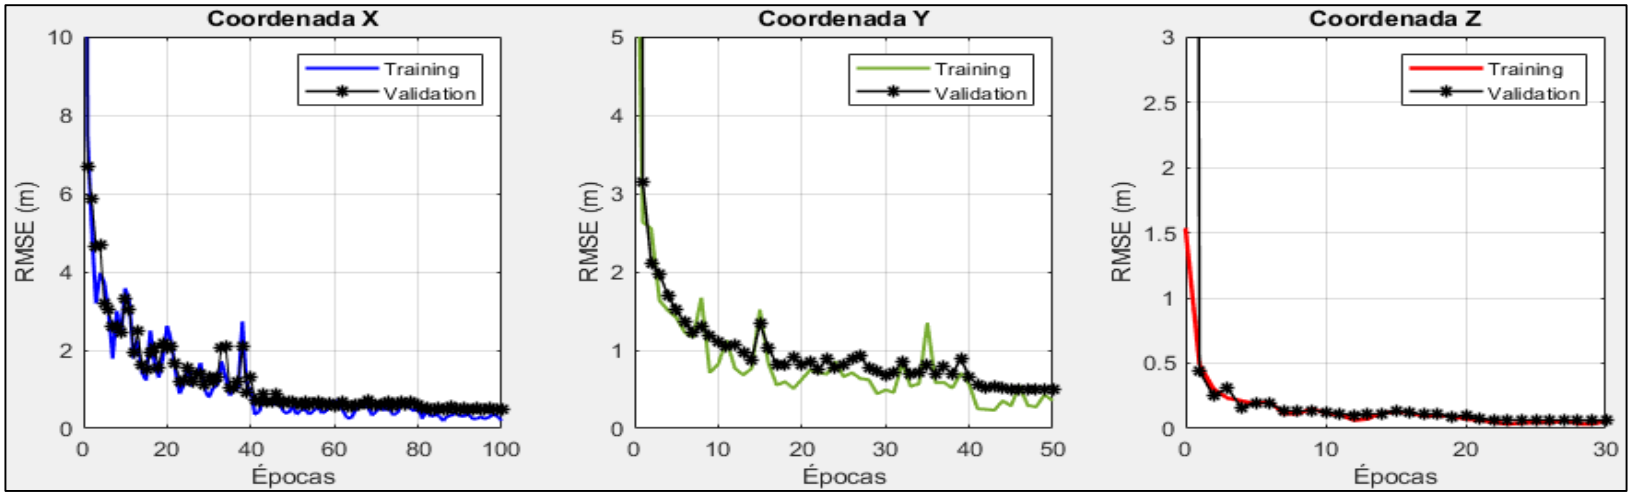

Arquitectura de la CNN

Segmentación de datos	Datos de entrenamiento	Datos de validación	RMSE [m] en X	RMSE [m] en Y	RMSE [m] en Z	Distancia Euclidiana [m]
Tipo A	50, 20 y 10 dB	50, 20 y 10 dB	0.3729	0.3851	0.0378	0.3971
Tipo B	50 y 10 dB	20 dB	0.1674	0.1919	0.0442	0.2282
Tipo C	50 y 20 dB	10 dB	0.4317	0.4615	0.0614	0.5341

VISUALIZACIÓN DE COORDENADAS REALES Y PREDICHAS CON SEGMENTACIÓN TIPO A

Perspectiva en 3D

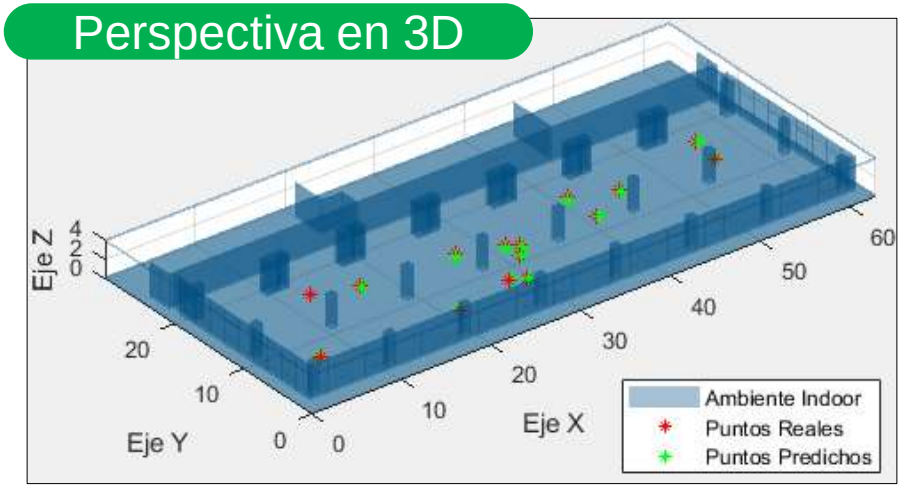

VISUALIZACIÓN DE COORDENADAS REALES Y PREDICHAS CON SEGMENTACIÓN TIPO A

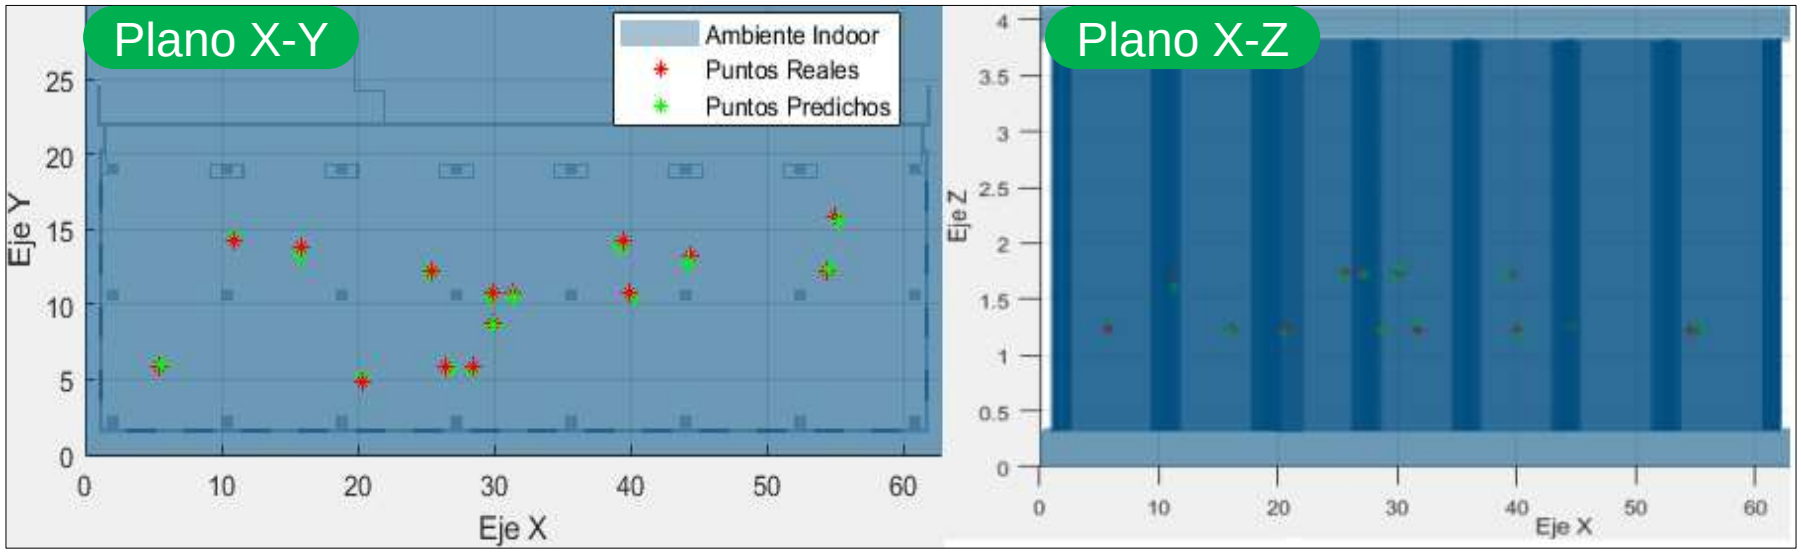

RESULTADOS

CON SEGMENTACIÓN TIPO B

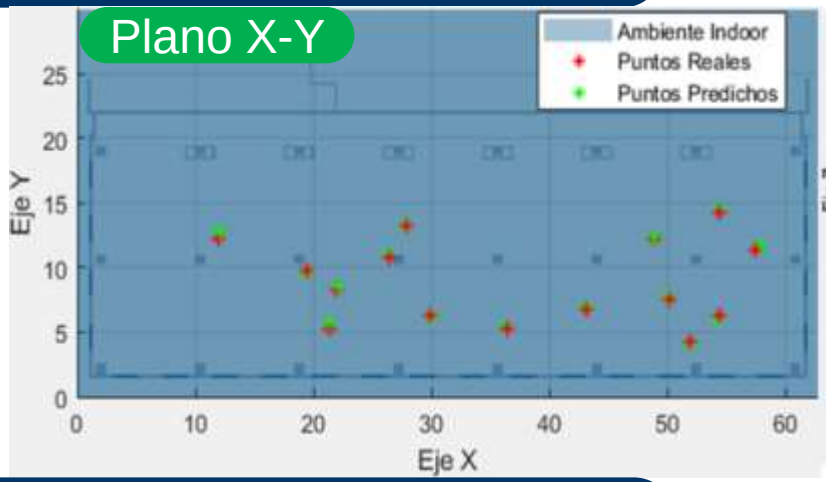

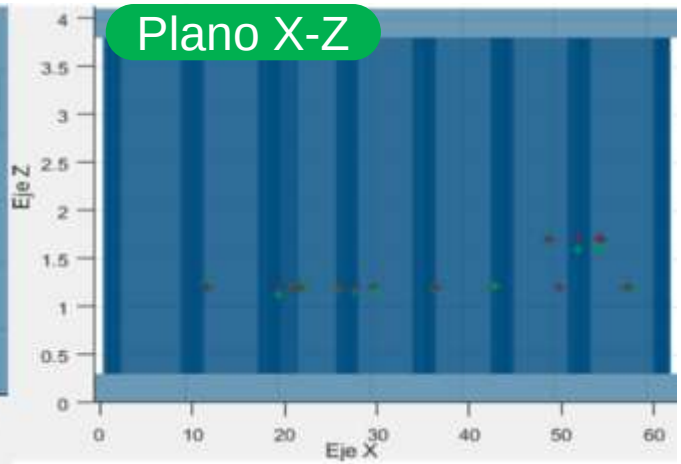

CON SEGMENTACIÓN TIPO C

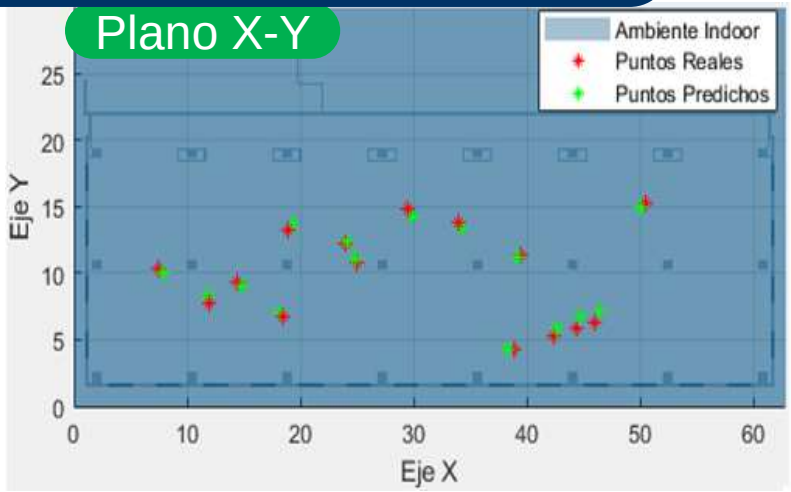

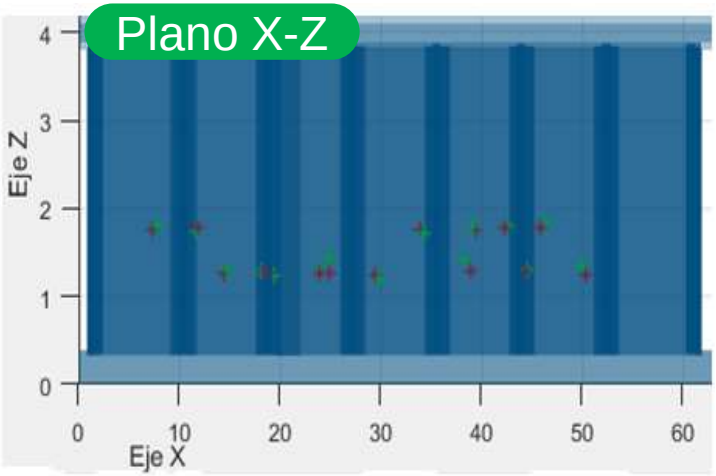

CONCLUSIONES

Se ha logrado desarrollar un sistema de posicionamiento de alta precisión, con un error de 39.71 cm en un entorno tridimensional con dimensiones de 60.5 x 20 x 2.4 [m]

La evaluación cuantitativa revela que los modelos de Machine Learning tradicional no son óptimos para este sistema de posicionamiento. Los algoritmos de Deep Learning, incluso en su forma más básica, superan en precisión a los modelos de ML

Con niveles de SNR intermedios al rango de entrenamiento se logra una precisión óptima. Sin embargo, con niveles de SNR inferiores la precisión se ve comprometida, aunque no es crítica.

Las predicciones más precisas se lograron con las configuraciones de 4 capas ocultas para DNN y 4 capas convolucionales para CNN, siendo este último el que superó a todos los modelos alcanzando valores de 0.3729 m en X, 0.3851 m en Y y 0.0378 m en Z

En los modelos DNN y CNN, cada coordenada conllevó un ajuste diferente de hiperparámetros para obtener los mejores resultados. Esto se atribuye a las diferencias en los rangos presentes en cada una

Tanto las características de los datos como los diversidad de niveles de SNR fueron esenciales para lograr una alta precisión con robustez ante presencia de ruido

TRABAJOS FUTUROS

Tarea de clasificación

- Realizar una tarea de clasificación utilizando los datos reales para el entrenamiento y las coordenadas predichas anteriormente como conjunto de prueba para validar el nivel de precisión logrado.

- Se busca tener mejores sistemas de navegación y posicionamiento en tiempo real, basados en escenarios grandes divididos en subáreas, para su posterior identificación.

TRABAJOS FUTUROS

Implementación de redes pre entrenadas

- Implementar modelos basados en redes pre-entrenadas como, Google-Net, Res-Net o Alex-Net, como otra alternativa para mejorar la precisión de la predicción de las coordenadas
- Generar una mayor cantidad de datos sintéticos para tener una base de datos más robusta
- Realizar simulaciones con condiciones de canal extremas

Inception-V1 (GoogleNet)

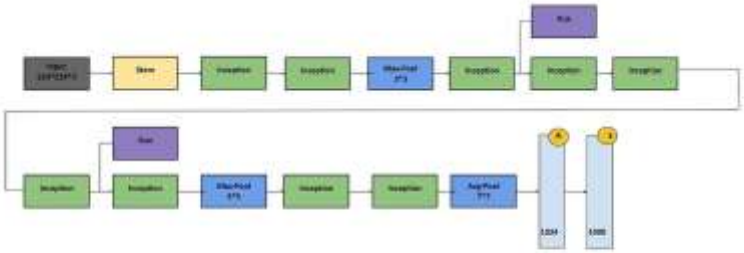

¡GRACIAS!

Telecomunicaciones: cteleco@espe.edu.ec