Evaluar de forma cuantitativa el potencial de las técnicas de Inteligencia Artificial en la localización de dispositivos mediante Información del Estado de Canal (CSI)

Flores Proaño, James Marshall y Logroño López, Kevin Alexis

Departamento de Eléctrica, Electrónica y Telecomunicaciones

Carrera de Telecomunicaciones

Trabajo de integración curricular, previo a la obtención del título de Ingeniero en Telecomunicaciones

Ing. Carrera Erazo, Enrique Vinicio, PhD.

1 de marzo del 2024

Copyleaks

Plagiarism and AI Content Detection Report

MIC_FLORES_LOGROÑO_V5.docx

Scan details

Scan time:	Total Pages:	Total Words:
March 4th, 2024 at 19:55 UTC	89	22061

Plagiarism Detection

1.2%

Types of plagiarism		Words
Identical	0.5%	104
Minor Changes	0.1%	23
Paraphrased	0.5%	117
Omitted Words	7.3%	1607

AI Content Detection

6.4%

Text coverage		Words
AI text	6.4%	867
Human text	93.6%	19587

Learn more

firmado electrónicamente por:
ENRIQUE VINICIO
CARRERA ERAZO

.....

Ing. Carrera Erazo, Enrique Vinicio, PhD.

C.C.: 1708792104

Departamento de Eléctrica, Electrónica y Telecomunicaciones

Carrera de Telecomunicaciones

Certificación

Certifico que el trabajo de integración curricular: **"Evaluar de forma cuantitativa el potencial de las técnicas de Inteligencia Artificial en la localización de dispositivos mediante Información del Estado de Canal (CSI)"** fue realizado por los señores **Flores Proaño, James Marshall** y **Logroño López, Kevin Alexis,** el mismo que cumple con los requisitos legales, teóricos, científicos, técnicos y metodológicos establecidos por la Universidad de las Fuerzas Armadas ESPE, además fue revisado y analizada en su totalidad por la herramienta de prevención y/o verificación de similitud de contenidos; razón por la cual me permito acreditar y autorizar para que se lo sustente públicamente.

Sangolquí, 1 de marzo del 2024

Firmado electrónicamente por:
ENRIQUE VINICIO
CARRERA ERAZO

.....

Ing. Carrera Erazo, Enrique Vinicio, PhD.

C.C.: 1708792104

Departamento de Eléctrica, Electrónica y Telecomunicaciones

Carrera de Telecomunicaciones

Responsabilidad de Autoría

Nosotros, **Flores Proaño, James Marshall** y **Logroño López, Kevin Alexis**, con cédulas de ciudadanía n°1750879700 y n°1750336529, declaramos que el contenido, ideas y criterios del trabajo de integración curricular**: "Evaluar de forma cuantitativa el potencial de las técnicas de Inteligencia Artificial en la localización de dispositivos mediante Información del Estado de Canal (CSI)"** es de nuestra autoría y responsabilidad, cumpliendo con los requisitos legales, teóricos, científicos, técnicos, y metodológicos establecidos por la Universidad de las Fuerzas Armadas ESPE, respetando los derechos intelectuales de terceros y referenciando las citas bibliográficas.

Sangolquí, 1 de marzo del 2024

……

Flores Proaño, James Marshall

C.C.: 1750879700

……..

Logroño López, Kevin Alexis

C.C.: 1750336529

Departamento de Eléctrica, Electrónica y Telecomunicaciones

Carrera de Telecomunicaciones

Autorización de Publicación

Nosotros Flores Proaño**, James Marshall** y **Logroño López, Kevin Alexis**, con cédulas de ciudadanía n°1750879700 y n°1750336529, autorizamos a la Universidad de las Fuerzas Armadas ESPE publicar el trabajo de integración curricular: **"Evaluar de forma cuantitativa el potencial de las técnicas de Inteligencia Artificial en la localización de dispositivos mediante Información del Estado de Canal (CSI)"** en el Repositorio Institucional, cuyo contenido, ideas y criterios son de nuestra responsabilidad.

Sangolquí, 1 de marzo de 2024

……

Flores Proaño, James Marshall

C.C.: 1750879700

……

Logroño López, Kevin Alexis

C.C.: 1750336529

Dedicatoria

Dedico este proyecto a mis queridos padres Rene Logroño y Olga Lopez, quienes han sido mi pilar y fuente de inspiración a lo largo de este arduo camino académico. Su amor incondicional, sacrificio y apoyo constante han sido la fuerza motriz detrás de este logro. Agradezco y dedico este proyecto a mi amada novia, Gabriela Uquillas por su paciencia, comprensión y por ser mi refugio en los momentos de presión y por ser quien me dio la motivación para no darme por vencido, gracias por tu amor, por acompañarme y apoyarme desde el principio. A mi querida familia, cuyo respaldo ha sido invaluable.

Agradezco a mis amigos, quienes compartieron risas, desafíos, largas horas de estudio y momentos invaluables. Su compañía hizo que este viaje fuera más llevadero.

Este logro no solo es mío, sino de cada uno de ustedes que ha sido parte fundamental en este viaje y en mi vida. Su apoyo ha sido la luz que ha iluminado el camino hacia la culminación de este proyecto. Con gratitud eterna, dedico este trabajo a ustedes.

Kevin Alexis Logroño Lopez

Dedicatoria

Quiero dedicar este proyecto a todos aquellos que han sido piezas fundamentales a lo largo de mi vida personal, académica y en el desarrollo del presente proyecto. A mis padres, Guillermo Flores y Katerine Proaño, les agradezco por su apoyo constante, amor, comprensión y aliento incondicional que han sido el pilar fundamental durante esta travesía. A mis hermanos, Frank Flores y Nubia Flores, les dedico este logro, agradecido por su emoción y presencia constante que han contribuido a culminar este proceso. A mis abuelitos, Pedro Proaño y Sonia Flores, les expreso mi gratitud por su atención constante, brindándome ánimo y confianza en cada etapa de este camino.

Este proyecto también va dedicado a mis amigos, quienes han sido testigos y compañeros en innumerables momentos dentro y fuera de las aulas. Agradezco su constante preocupación y apoyo sincero a lo largo de todo este proceso, compartiendo risas, desafíos y triunfos.

James Marshal Flores Proaño

Agradecimiento

Quiero expresar mi sincero agradecimiento a mis compañeros de estudio por su apoyo incondicional y colaboración, en especial a Marshall Flores, quien se destacó como un excelente compañero y amigo en este proyecto, y con quien formé una sincera amistad. También, extiendo mi agradecimiento a mis profesores por su orientación invaluable y dedicación en especial al al Dr. Vinicio Carrera por colaborar con este proyecto y proporcionarnos lecciones valiosas.

Agradezco a mi novia, Silvia Uquillas, por su paciencia y cariño constante. A mis hermanas, Pamela Logroño, María José Lara y Alisson Rubio, a mis padres René Logroño y Olga López, mis abuelitos Rosario Ordónez y Olger Lopez, a mis tíos Silvia, Jorge y Marco les estoy agradecido por su apoyo constante. Aprecio sinceramente la influencia positiva que han tenido en mi vida académica y personal.

Quiero agradecer profundamente a mis mejores amigos, Francisco Simbaña, David Morales, Bruno Aguirre, Omar Montenegro y Miguel Rodríguez, por su apoyo inquebrantable durante este arduo proceso.

Agradezco a Dios y a la Madre Dolorosa, por bendecirme a lo largo de todo este proceso.

Kevin Alexis Logroño Lopez

Agradecimiento

Quiero expresar mi profundo agradecimiento a la universidad, ya que, desde el inicio de esta travesía académica, me ha proporcionado valiosas enseñanzas, profesores excepcionales, inolvidables experiencias, grandes amistades y logros que llevaré conmigo a lo largo de toda mi vida.

Extendiendo mi gratitud al Dr. Vinicio Carrera, cuyas enseñanzas en las aulas y orientación a lo largo de este proceso han sido fundamentales para la realización de este proyecto.

Agradezco de manera especial a mi compañero, Kevin Logroño, quien más allá de ser mi colaborador en este proyecto, me ha brindado constante respaldo tanto en lo académico como en lo personal, compartiendo varias experiencias y forjando una amistad muy valiosa.

Igualmente, quiero agradecer de manera muy amena a mis amigos: Kevin Chillán, Luis Gallo, Jonathan Solano, Carolina Morocho, Andrés Loachamín, Bryan Ramírez, Rashell Moncayo, Hugo Andrade, Ariel Quilachamín y a todos aquellos que forman parte de mi círculo cercano. Con ellos he construido una amistad única e incomparable a lo largo de todo este camino, y se han convertido en personas muy valiosas en mi vida. Su apoyo incondicional y constante preocupación han sido muy importantes desarrollo de este proyecto.

Finalmente, no puedo dejar de expresar mi más profundo agradecimiento a Dios y a mi familia: Guillermo Flores, Katerine Proaño, Frank Flores y Nubia Flores. Ellos han sido el pilar fundamental que me ha impulsado a seguir adelante en este proceso, siendo mi mayor motivación y empuje para superar los desafíos tanto en mi vida universitaria como en la personal. Sin ustedes, nada de esto hubiera sido posible.

James Marshal Flores Proaño

Índice de Contenidos

Dedicatoria 6
Agradecimiento 8
Resumen 16
Abstract 17
Capítulo I: Introducción 18
Antecedentes y Estado del Arte 18
Justificación y Motivación 19
Alcance del Proyecto 23
Objetivo General 25
Objetivos Específicos 25
Capítulo II: Fundamento teórico y conceptual 26
Tecnología 5G orientada al posicionamiento 26
Sistemas MIMO 27
Información del Estado de Canal (CSI) 28
Respuesta en Frecuencia del Canal (CFR) 29
Machine Learning (ML) 29
Aprendizaje supervisado 30
Modelos de aprendizaje supervisado 30
Regresión lineal (LR) 30
Árbol de Regresión (RT) 31
Deep Learning (DL) 32
Redes Neuronales Profundas (DNN) 32
Redes Neuronales Convolucionales (CNN) 33
Hiperparámetros de redes neuronales 33
Batch Size (Tamaño del lote). 33
Épocas. 34

Tasa de aprendizaje. 34
Optimizadores. 34
Métodos de Normalización de Datos 35
Normalización 0-1 35
Normalización Z-Score 35
Métricas de desempeño 36
MSE 36
RMSE. 37
Distancia Euclidiana. 37
Capitulo III: Materiales y Metodología 39
Materiales 39
Software 39
Hardware 39
Base de datos 39
Capa física 41
Capa de sistema. 43
Capa de aplicación. 45
Estructura de datos 47
Concatenación de los tres niveles de SNR 49
Metodología 50
Etapa de Preprocesamiento 51
Proceso de linealización para ML Tradicional y DNN 51
Normalización 52
Segmentación de datos 53
Etapa de Entrenamiento 56
Implementación con Machine Learning Tradicional 56
Implementación con Deep Learning 57

Redes Neuronales Profundas (DNN) 60
Redes Neuronales Convolucionales (CNN) 63
Capítulo IV: Resultados 70
Resultados con Machine Learning 70
Regresión Lineal (LR) 70
Árbol de Regresión (RT) 70
Resultados con Deep Learning 72
Redes Neuronales Profundas (DNN) 72
Fase 4: Resultados del Entrenamiento Inicial 72
Fase 5: Selección de la configuración óptima y del mejor optimizador 76
Fase 6: Ajuste Final de Hiperparámetros 80
Redes Neuronales Convolucionales (CNN) 81
Fase 4: Resultados del Entrenamiento Inicial 81
Fase 5: Selección de la Configuración Óptima y del Mejor Optimizador 83
Fase 6: Ajuste Final de Hiperparámetros 85
Comparación de resultados 87
Análisis de resultados con segmentación de datos Tipo B y C 88
Cálculo de la Distancia Euclidiana 90
Visualización de Puntos Predichos en el Escenario 91
Capítulo V: Conclusiones y Trabajos Futuros 95
Conclusiones 95
Trabajos futuros 97
Referencias 99
Apéndices 102
Apéndice 1: Glosario de Siglas y Acrónimos 102

Índice de Tablas

Tabla 1 *Segmentaciones de Datos Tipo B y C* 55

Tabla 2 *Configuración inicial aplicada al modelo RT* 57

Tabla 3 *Configuraciones de La Red Neuronal* 62

Tabla 4 *Hiperparámetros Iniciales aplicados a cada configuración DNN* 63

Tabla 5 *Configuraciones de la Red Neuronal Convolucional* 66

Tabla 6 *Disposición de Capas Convolucionales* 67

Tabla 7 *Hiperparámetros Iniciales aplicados a cada configuración CNN* 69

Tabla 8 *Resultados de RMSE Obtenidos con el Modelo LR* 70

Tabla 9 *Resultados de RMSE Obtenidos con la Configuración Inicial del Modelo RT* 71

Tabla 10 *Resultados de RMSE optimizados obtenidos con el Modelo RT* 72

Tabla 11 *Resultados de RMSE Obtenidos con Cada Optimizador a las 100 Épocas* 79

Tabla 12 *Resultados de RMSE Obtenidos con la Configuración Optimizada del Modelo DNN* 81

Tabla 13 *Resultados de RMSE Obtenidos con Cada Optimizador a las 80 Épocas* 84

Tabla 14 *Resultados de RMSE Obtenidos con la Configuración Optimizada del Modelo CNN* 87

Tabla 15 *Cuadro Comparativo Final de los Resultados Obtenidos en Todos los Modelos* 88

Tabla 16 *Resultados de RMSE Obtenidos por Cada Tipo de Segmentación de Datos* 90

Tabla 17 *Distancias Euclidianas Obtenidas por Cada Tipo de Segmentación de Datos* 91

Índice de Figuras

Figura 1 *Ilustración en 3D de la Oficina de la Academia de Ciencias de Beijing* 40

Figura 2 *Ubicación de gNBs en el Escenario* 40

Figura 3 *Proceso para la Generación de Matrices CFR* 41

Figura 4 *Canales MIMO Entre Un Par gNB-UE* 41

Figura 5 *CFR Obtenida en el UE desde 4 gNBs Diferentes* 44

Figura 6 *Matriz CFR Obtenida desde una gNB después del Procesamiento* 45

Figura 7 *Matrices CFR Obtenidas desde una gNB con tres niveles de SNR* 46

Figura 8 *Estructuración del Conjunto de Features* 48

Figura 9 *Estructuración del Conjunto de Labels* 48

Figura 10 *Concatenación de tres niveles de SNR en Características y Etiquetas* 49

Figura 11 *Estructura del Conjunto de Datos con los Tres Niveles de SNR* 50

Figura 12 *Esquema General de la Metodología aplicada al Sistema de Posicionamiento* 51

Figura 13 *Linealización del Conjunto de Características* 52

Figura 14 *Distribución de datos sin Normalización* 53

Figura 15 *Distribución de datos con Normalización Z-Score* 53

Figura 16 *Segmentación de Datos Tipo A* 54

Figura 17 *Metodología empleada en la Etapa de Entrenamiento con DL* 57

Figura 18 *Arquitectura de la DNN empleada para el Posicionamiento de Dispositivos* 60

Figura 19 *Arquitectura con Capa de Normalización por Lotes y Función de Activación* 61

Figura 20 *Arquitectura de CNN para el posicionamiento de dispositivos* 64

Figura 21 *Valores de RMSE Obtenidos con la Configuración Optimizada del Modelo RT* 71

Figura 22 *Rendimiento de cada Configuración de la DNN con Optimizador Adam* 73

Figura 23 *RMSE obtenidos con cada Configuración de la DNN con Optimizador Adam* 74

Figura 24 *Rendimiento de cada Configuración de la DNN con Optimizador RMSProp* 75

Figura 25 *RMSE obtenidos con cada Configuración de la DNN con Optimizador RMSProp* 75

Figura 26 *Curvas de Aprendizaje Obtenidas con DNN 4 y Optimizador Adam* 77

Figura 27 *Curvas de Aprendizaje Obtenidas con DNN 4 y con Optimizador RMSProp* 78

Figura 28 *Curvas de Aprendizaje Obtenidas con DNN 4 y Optimizador SGDm* 79

Figura 29 *Curvas de Aprendizaje Obtenidas con Configuración Optimizada del Modelo DNN* 80

Figura 30 *Rendimiento de cada Configuración de la CNN con Optimizador Adam* 82

Figura 31 *RMSE Obtenidos con Cada Configuración de la DNN con Optimizador Adam* 83

Figura 32 *Curvas de Aprendizaje Obtenidas con CNN 4 y optimizador Adam* 83

Figura 33 *Curvas de Aprendizaje Obtenidas con CNN 4 y optimizador RMSProp* 84

Figura 34 *Curvas de Aprendizaje Obtenidas con CNN 4 y Optimizador SGDm* 84

Figura 35 *Curvas de Aprendizaje Obtenidas con Configuración Optimizada del Modelo CNN* 86

Figura 36 *Curvas de Aprendizaje Obtenidas con Segmentación Tipo B* 89

Figura 37 *Curvas de Aprendizaje Obtenidas con Segmentación Tipo C* 89

Figura 38 *Visualización en 3D de Puntos Predichos con Segmentación Tipo A* 92

Figura 39 *Visualización Puntos Predichos en Planos X-Y y X-Z con Segmentación Tipo A* 92

Figura 40 *Visualización Puntos Predichos en Planos X-Y y X-Z con Segmentación Tipo B* 93

Figura 41 *Visualización Puntos Predichos en Planos X-Y y X-Z con Segmentación Tipo C* 93

Resumen

En décadas recientes, la tecnología ha generado creciente interés en la utilización de técnicas de Inteligencia Artificial (IA) en múltiples áreas de investigación que contribuyan en dar solución a problemas latentes en la actualidad. Uno de ellos es mejorar la exactitud de la localización de los dispositivos que hacen uso de redes inalámbricas, específicamente a través de la información de la Respuesta en Frecuencia del Canal (CFR). Si bien existen métodos convencionales para este fin, incluido el ampliamente utilizado GPS, resultan ser poco eficientes en términos de precisión sobre todo en entornos interiores. Es por esta razón que el presente trabajo de titulación toma relevancia y busca una mejora significativa empleando técnicas de IA. Para alcanzar este objetivo, se inicia con una investigación de las técnicas de localización existentes y su eficacia en diversas condiciones de señal y entornos, esto con la finalidad de conocer cuáles son las limitaciones actuales existentes. Posteriormente, se procede con el análisis de la base de datos, la cual contiene características representadas en forma de matrices CFR. Estas matrices son muestras con información detallada del estado del canal inalámbrico 5G de una oficina, y se complementan con etiquetas que contienen las coordenadas tridimensionales de la ubicación del dispositivo, donde fueron tomadas dichas muestras. Finalmente, se lleva a cabo la predicción del posicionamiento de dispositivos abordando la implementación de algoritmos de Machine Learning (ML) supervisado de regresión tradicionales, tales como Regresión Lineal (LR) y Árbol de Regresión (RT). Asimismo, se contempla el uso de Redes Neuronales Profundas (DNN) y de Redes Neuronales Convolucionales (CNN), cubriendo así la parte de DL (Deep Learning) para aprovechar la correlación existente en las matrices CFR y mejorar la precisión del posicionamiento de dispositivos en términos de la Raíz del Error Cuadrático Medio (RMSE).

Palabras clave: Posicionamiento, Respuesta en Frecuencia del Canal, Machine Learning, Deep Learning, Raíz del Error Cuadrático Medio.

Abstract

In recent decades, technology has generated increasing interest in the utilization of Artificial Intelligence (AI) techniques across multiple research areas to address current latent problems. One of these areas involves enhancing the accuracy of device localization using wireless networks, specifically through Channel Frequency Response (CFR) information. While conventional methods, including the widely used GPS, exist for this purpose, they prove to be inefficient in terms of accuracy, especially in indoor environments. This is why the current thesis work is relevant and seeks significant improvement by employing AI techniques. To achieve this goal, the study begins with an investigation of existing localization techniques and their effectiveness in various signal conditions and environments, aiming to identify current limitations. Subsequently, the database analysis takes place, containing features represented in the form of CFR matrices. These matrices serve as samples with detailed information about the state of the 5G wireless channel within an office, complemented by labels containing the three-dimensional coordinates of the device's location where these samples were taken. Finally, device positioning prediction is carried out, addressing the implementation of traditional supervised Machine Learning (ML) regression algorithms, such as Linear Regression (LR) and Regression Tree (RT). Additionally, the use of Deep Neural Networks (DNN) and Convolutional Neural Networks (CNN) is considered, covering the Deep Learning (DL) aspect to leverage the correlation present in CFR matrices and improve device positioning accuracy in terms of Root Mean Square Error (RMSE).

Keywords: Positioning, Channel Frequency Response, Machine Learning, Deep Learning, Root Mean Square Error.

Capítulo I: Introducción

Antecedentes y Estado del Arte

La localización precisa de dispositivos inalámbricos ha sido un tema de investigación de vital importancia en las últimas décadas. A medida que la tecnología inalámbrica ha avanzado, la necesidad de determinar la ubicación de dispositivos de manera eficiente y precisa se ha vuelto esencial en una amplia gama de aplicaciones, desde la navegación en diferentes ambientes hasta la gestión de redes inalámbricas.

Con el paso del tiempo, eventualmente se han empleado métodos tradicionales basados en señales de radiofrecuencia, como el GPS (Mautz et al., 2010), WiFi (Ranimol & Swapna B, 2018a), Bluetooth (Ranimol & Swapna B, 2018b) y otras tecnologías. Sin embargo, estos métodos presentan limitaciones significativas en dichos entornos, ya que las señales tienen dificultades para atravesar obstáculos, como paredes o edificios, lo que resulta en una deficiente precisión en la localización de dispositivos.

Entrando más en detalle, en la investigación de Mautz et al. (2010) se desarrolla un sistema de posicionamiento de dispositivos para ambientes interiores mediante señales GPS. La limitación aquí es que, además de no ser muy realista por no considerar la altura para su localización, obtienen precisiones en términos del Error Cuadrático Medio (MSE, del inglés *Mean Square Error*) de hasta 5 metros en el análisis del posicionamiento en una dimensión, mientras que en dos dimensiones alcanzan una precisión de 7 metros.

Por otro lado, Ranimol & Swapna B (2018) detallan un método más moderno, incluyendo técnicas de Aprendizaje de Máquina (ML, del inglés *Machine Learning*). Este método describe el posicionamiento en interiores usando una base de datos de "fingerprints" de WiFi, las cuales son entrenadas mediante autoencoders para determinar la localización de los dispositivos. No obstante, a pesar de lograr una precisión de alrededor del 93%, resulta ser

limitada en comparación con otras tecnologías de posicionamiento más avanzadas. Esto se debe a que los "fingerprints" son un conjunto de datos que se deben registrar constantemente y recopilan únicamente la Intensidad de la Señal Recibida (RSSI, del inglés *Received Signal Strength Indicator*) en un lugar específico, sin contener información detallada que puede encontrarse en sistemas de Múltiples Entradas y Múltiples Salidas (MIMO, del inglés *Multiple Input Multiple Output*), entre otros. En consecuencia, si el canal se encuentra en presencia de ruido o los objetos presentes en dicho escenario cambian de posición, la precisión en la localización de dispositivos puede verse comprometida.

Algo similar ocurre en el trabajo de Sunardy & Surantha (2018), ya que emplean datos de RSSI basados en Bluetooth Low Energy (BLE, por sus siglas en inglés). Esta vez utilizan dos algoritmos clasificadores: *k* Vecinos Cercanos (kNN, del inglés *k-Nearest Neighbors*) y Vecinos más Cercanos Difusos (FkNN, del inglés *Fuzzy k-Nearest Neighbors*) para determinar la ubicación de dispositivos en 12 posibles áreas de 2 habitaciones (6 áreas por cada habitación), alcanzando una precisión del 99.83%. Si bien es un buen resultado, este método proporciona información limitada al identificar únicamente la zona donde se encuentra el dispositivo, lo que cuestiona su clasificación como un sistema de posicionamiento de alta precisión.

Justificación y Motivación

En respuesta a los desafíos y limitaciones anteriormente mencionados, la Información del Estado del Canal (CSI, del inglés *Channel State Information*) se ha destacado como una fuente prometedora de datos para mejorar la precisión del posicionamiento de dispositivos. La CSI proporciona información sobre el canal de comunicación entre un transmisor y un receptor, detallando características clave como la fase y amplitud de las subportadoras OFDM (*Orthogonal Frequency Division Multiplexing*), la Respuesta en Frecuencia del Canal (CFR, del inglés *Channel Frequency Response*), la Respuesta al Impulso del Canal (CIR, del inglés

Channel Impulse Response), el nivel de ruido, entre otros parámetros que describen el comportamiento de las ondas de radio en el canal de comunicación. Además, permite el análisis de sistemas que implementen la tecnología MIMO, lo cual resulta ventajoso al aprovechar la diversidad espacial mediante múltiples antenas. Este enfoque incrementa la probabilidad de que, al menos, una de las señales sea recibida con calidad suficiente en el receptor, otorgando mayor robustez a los datos frente a ruido e interferencias en la comunicación (Li et al., 2022).

La Inteligencia Artificial (IA), por otro lado, es la tendencia tecnológica actual y se presenta como una alternativa muy viable para ser utilizada con datos de CSI y lograr una localización de dispositivos con un alto nivel de precisión. Aunque esto es cierto, hay que considerar que la recopilación de datos con CSI implica el uso de equipos especializados, y de la misma manera el tiempo necesario para recolectar esta información sobrepasa el plazo establecido para completar este trabajo. Es por esta razón que surge la motivación y necesidad de emplear técnicas de IA con bases de datos ya existentes de CSI y demostrar que al combinar estas tecnologías es posible lograr un sistema de posicionamiento eficiente y confiable.

Si bien las tecnologías basadas en GPS, Wifi y Bluetooth han sido han sido importantes para estimar la ubicación de los dispositivos a lo largo del tiempo, han demostrado ser insuficientes en entornos interiores, donde la señal puede ser bloqueada o reflejada impredeciblemente. Ante estos problemas, la quinta generación (5G) de redes de comunicación han surgido como una solución por sus altas velocidades de transmisión de datos, el uso de tecnología de MIMO, vasto alcance y su integración en escenarios interiores y exteriores para el posicionamiento de dispositivos (Gao et al., 2022). Todo esto conforma a lo que se conoce como Detección y Comunicación Integrada (ISAC, del inglés *Integrated Sensing and Communication*) y su importancia está en que así se puede mejorar la precisión en la

localización de dispositivos, superando así las restricciones de las tecnologías inalámbricas anteriormente mencionadas.

En investigaciones previas se han explorado el uso de redes 5G tanto en entornos interiores como exteriores para generar bases de datos, las cuales podrían contribuir al desarrollo del presente proyecto. El trabajo desarrollado por Pan et al., (2023) se presenta una base de datos que contiene un total de 476 muestras de CFR de un estacionamiento subterráneo de un edificio. Estas muestras corresponden a 476 ubicaciones distintas en las que podría estar el dispositivo dentro del escenario, cada una de ellas separada entre 1.5 y 2.5 metros. Además, el entorno cuenta con 10 columnas repartidas en un área de 45 x 25 metros y una Unidad de Radio Remota (RRU, del inglés *Remote Radio Unit*) con un Arreglo Lineal Uniforme (ULA, del inglés *Uniform Linear Array*) de antenas, ubicada en una esquina, que registra los datos CFR de la ubicación correspondiente, proporcionando de esta manera un conjunto de datos tanto con Línea de Vista (LOS, del inglés *Line of Sight*) como Sin Línea de Vista (NLOS, del inglés *Non Line of Sight*). Sin embargo, a pesar que es un conjunto de datos bastante completo, el número de muestras podría resultar limitado para el entrenamiento mediante técnicas de IA, y el espaciamiento entre cada ubicación es grande en comparación con otras bases de datos, lo que dificulta a esta opción como alternativa viable.

Por otro lado, en el artículo desarrollado por Li, De Bast, et al. (2022) se explica la recopilación de 252004 muestras de CFR en un área cuadrada de 9 metros cuadrados. Cada muestra correspondía a una ubicación, y cada ubicación estaba espaciada por 5 milímetros en todas las direcciones, con respecto a las adyacentes. Además, cada muestra fue recopilada en una estación base con 3 arreglos diferentes de 64 antenas: ULA con una disposición de 8x8, Arreglo Rectangular Uniforme (URA, del inglés *Uniform Rectangular Array*) con una disposición de 64x1, y ULA Distribuido (DIS, del inglés *Distributed ULA*), la cual consistía de arreglos lineales de 8 antenas distribuidos alrededor del área en cuestión, conformando así 3 conjuntos

de datos diferentes. Indudablemente, esta base de datos es bastante completa, ofreciendo datos a escala milimétrica. Sin embargo, cabe señalar que la recopilación de estas muestras requirió el uso de equipos especializados. Específicamente, se utilizaron cuatro mesas de 1.25 x 1.25 metros distribuidas en todo el escenario, cada una de ellas equipada con una rejilla que permitía al dispositivo dar los pasos milimétricos en el plano XY del escenario. En ese sentido, si se quisiera replicar el mismo sistema en escenarios más grandes, se necesitaría una gran cantidad de dichos equipos, lo que lo vuelve poco eficiente en cuanto a tiempo y recursos para la recopilación de la información del canal.

Finalmente, en el trabajo de Gao et al. (2022) se propone una base de datos, la cual contiene la información del canal inalámbrico de una oficina de un edificio de la Academia China de Ciencias de Beijing con una dimensión de 60.5 x 20 metros. Estos datos fueron generados de acuerdo a las especificaciones de 3GPP versión 16 (R16) para redes 5G y contienen 4816 matrices CFR con etiquetas correspondientes a las coordenadas en 3D que representan las múltiples posibles ubicaciones en las que un dispositivo puede encontrarse dentro de dicho escenario, con un espaciamiento de 0.5 metros, tanto en dirección vertical como horizontal. Adicionalmente, las matrices CFR fueron obtenidas en un equipo de usuario (UE, del inglés *User Equipment*) mediante señales piloto transmitidas desde 5 estaciones base (gNB, del inglés *gNodeB*) que cuentan con un arreglo de antenas tipo URA. Estas matrices cuentan con 3 niveles de ruido: 50 dB, 20 dB y 10 dB, generados a nivel de capa física, lo que proporciona un conjunto de información lo suficientemente robusto y completo. A diferencia de las bases de datos anteriormente mencionadas, este conjunto logra un equilibrio entre el espaciamiento de cada ubicación, el número de muestras, las dimensiones del escenario y los recursos en términos de tiempo y equipos que se requiere para obtener la información del canal, por lo que resulta viable para llevar a cabo el desarrollo de las diferentes técnicas de IA y predecir el posicionamiento de dispositivos.

Alcance del Proyecto

Basado en lo anterior, el proyecto se enfoca en el análisis de una de las bases de datos previamente descritas para capacitar una IA que, además de validar la eficiencia de la misma, sea capaz de sintetizar un modelo de aprendizaje automático eficaz que respalde un sistema de posicionamiento de alta precisión. Para lograrlo, se empleará la herramienta de software líder en el campo, MATLAB®, en conjunto de computadores con tarjeta de procesamiento estándar y los servidores de la nube de MATLAB® para el entrenamiento de los distintos modelos de IA.

Es importante destacar que el alcance de este estudio se enfoca en demostrar que, al aplicar técnicas de inteligencia artificial tradicionales mediante el uso de procesadores con un nivel moderado de capacidad de procesamiento, es factible llevar a cabo una evaluación cuantitativa de su potencial en sistemas de posicionamiento basados en CSI para lograr una localización precisa de dispositivos. Este análisis se concentra exclusivamente en este aspecto y no abordará a fondo otros elementos relacionados con la tecnología de comunicación inalámbrica.

Además, dado que las bases de datos contienen muestras de CFR y etiquetas correspondientes a las coordenadas de la ubicación de dispositivos, se trata de un problema de regresión, ya que se desea predecir las coordenadas de ubicación (valores continuos) en función de las características de entrada (CFR). Bajo este criterio, la solución es emplear técnicas de IA centradas en el aprendizaje supervisado para proceder con el entrenamiento del sistema, por lo que ese trabajo contempla el uso de algoritmos tanto de ML tradicional, como Regresión Lineal (LR, del inglés *Linear Regression*) y Árbol de Regresión (RT, del inglés *Regression Tree*), así como algoritmos de Aprendizaje Profundo (DL, del inglés *Deep Learning*), entre los cuales se incluyen Redes Neuronales Profundas (DNN, del inglés *Deep Neural Network*) y Redes Neuronales Convolucionales (CNN, del inglés *Convolutional Neural*

Network). Posteriormente, se realiza una evaluación inicial de cada modelo con el fin de analizar su eficiencia y realizar los ajustes respectivos en configuraciones e hiperparámetros para establecer el mejor modelo capaz de lograr resultados óptimos en términos de RMSE. Finalmente, se evalúa el desempeño del mejor modelo identificado considerando diferentes niveles de Relaciones Señal-Ruido (SNR, del inglés *Signal to Noise Ratio*).

Así, los resultados que se obtengan a través de este trabajo de integración curricular tienen el potencial de aportar significativamente a la optimización de sistemas de posicionamiento en una variedad de aplicaciones. Al hacerlo, se espera contribuir al avance de la tecnología de localización de dispositivos inalámbricos y su aplicación en una variedad de campos, desde la navegación en interiores y exteriores hasta la automatización en ámbitos industriales, comerciales y de seguridad.

En última instancia, el presente documento sigue la siguiente estructura. En el Capítulo II, se proporciona el fundamento teórico y conceptual que sienta las bases para la comprensión de las temáticas relacionadas con la tecnología 5G orientada al posicionamiento, CSI y algoritmos de ML y DL, las cuales sustentan el desarrollo de este trabajo. A continuación, en el Capítulo III, se detallan los materiales y la metodología utilizada, con un enfoque específico en la estructura de la base de datos, el formato de ingreso a los diversos algoritmos de ML y DL y las respectivas arquitecturas y configuraciones consideradas para ejecutar el entrenamiento. El Capítulo IV está dedicado a la presentación de los resultados obtenidos mediante cada uno de los algoritmos empleados, proporcionando un análisis detallado de su desempeño mediante el RMSE. Finalmente, en el Capítulo V, se exponen las conclusiones y recomendaciones derivadas del análisis de los resultados, además de proponer trabajos futuros para ampliar y mejorar el alcance de la investigación.

Objetivo General

Evaluar de forma cuantitativa el potencial de las técnicas de Inteligencia Artificial en la localización de dispositivos mediante Información del Estado del Canal (CSI).

Objetivos Específicos

1. Realizar un estudio de los trabajos relacionados más significativos en la localización de dispositivos, con la finalidad de observar la evolución que ha tenido a lo largo de los años, los alcances logrados y lo que falta por mejorar.
2. Buscar una base de datos relacionada con la Información del Estado de Canal de un escenario, de modo que pueda emplearse para predecir el posicionamiento de dispositivos mediante técnicas de IA.
3. Diseñar un sistema basado en IA, empleando diferentes algoritmos y configuraciones con el propósito de determinar cuál de ellos arroja los resultados más óptimos en términos de precisión en el posicionamiento de dispositivos.
4. Recopilar los resultados de cada algoritmo, realizar un análisis cuantitativo y establecer conclusiones que abarquen una visión integral del rendimiento y evidencien las técnicas utilizadas en la estimación de la ubicación de dispositivos en entornos inalámbricos.

Capítulo II: Fundamento teórico y conceptual

Tecnología 5G orientada al posicionamiento

Según el artículo en línea de CISCO (2024) titulado "¿What is 5G?", la tecnología 5G se presenta como la quinta generación de redes celulares, diseñada con el objetivo claro de proporcionar una comunicación inalámbrica más rápida y confiable. Este avance ofrece velocidades de carga y descarga superiores, menor latencia y mayor capacidad en comparación con sus predecesoras. Además, opera mediante un nuevo tipo de red que posibilita experiencias conectadas desde la nube hasta las redes 5G, respaldando una red convergente y heterogénea que combina tecnologías inalámbricas con y sin licencia.

Una aplicación destacada del 5G es su utilización como alternativa al Bluetooth o el WiFi en el ámbito del posicionamiento, tanto en interiores como exteriores. Esta versatilidad ha llevado a la consideración del 5G como una tecnología con potencial para revolucionar el posicionamiento en interiores. En ese sentido, la infraestructura de comunicaciones inalámbricas es crucial, su funcionamiento se basa en el envío de señales desde los dispositivos 5G a puntos de acceso cercanos con una marca de tiempo, permitiendo la triangulación de la posición del emisor recibiendo señales ligeramente diferentes en el tiempo por parte de cada receptor.

Según Kristersson & Konakanchi (2023), ingenieros de Ericsson enfatizan la capacidad distintiva del 5G para transformar el posicionamiento tanto en interiores como exteriores. Este avance se direcciona como un componente clave en casos de uso industrial avanzado, extendiéndose más allá de entornos industriales para abarcar áreas críticas como almacenes, hospitales y seguridad pública.

El preciso posicionamiento en interiores proporcionado por el 5G tiene un impacto significativo en diversas aplicaciones empresariales. Facilita la ubicación de activos con alta

precisión en entornos cerrados en cualquier momento. Empresas pueden aprovechar esta capacidad para mejorar la logística de almacenes, localizar equipos en hospitales, realizar el seguimiento de vehículos autónomos, posicionar herramientas y llevar a cabo el monitoreo en ambientes de alto riesgo como minas.

A pesar de la fuerte demanda de servicios de posicionamiento en interiores con 5G, actualmente, el 87% de las empresas aún no ha adoptado sistemas de ubicación en tiempo real (Kristersson & Konakanchi, 2023). Esto se atribuye a barreras existentes como la fragmentación tecnológica y los costos operativos. Sin embargo, estudios indican que la implementación de 5G podría mejorar el caso empresarial para su adopción en el futuro.

Las aplicaciones potenciales del posicionamiento en interiores son vastas, abarcando desde la monitorización de inventarios y equipos médicos hasta el rastreo de vehículos autónomos y la automatización de la fabricación inteligente. Además, la tecnología puede integrarse con sistemas de posicionamiento macro, como el GPS, permitiendo un seguimiento continuo tanto en interiores como en exteriores. Ericsson destaca la esencial importancia de esta capacidad de posicionamiento en 5G para la monetización y diferenciación de servicios ofrecidos por los proveedores de servicios de comunicación. En resumen, la tecnología 5G no solo promete una conectividad más rápida, sino que también redefine la manera en que ubicamos y rastreamos objetos en nuestros entornos cotidianos.

Sistemas MIMO

Según Hong, Thaj, & Viterbo (2022) en su libro *Delay-Doppler Communications - Principles and Applications*, la tecnología MIMO, que se representa con la sigla de *Multiple Input, Multiple Output* (Múltiple Entrada, Múltiple Salida), se define como una tecnología de antena utilizada en comunicaciones inalámbricas. Esta técnica emplea múltiples antenas tanto en la fuente como en el destino para mejorar la capacidad y el rendimiento de un enlace de radio. La esencia de MIMO está en la combinación de antenas en ambos extremos del circuito

de comunicación, lo que resulta en minimizar errores, optimizar la velocidad de los datos y fortalecer la capacidad de las transmisiones inalámbricas. La tecnología MIMO aprovecha las trayectorias múltiples, donde la información transmitida rebota en objetos, alcanzando la antena receptora varias veces desde ángulos y momentos ligeramente diferentes. Este enfoque tiene como objetivo mejorar tanto el rendimiento como el alcance de la transmisión. Para el proyecto de investigación, mediante el uso de la tecnología MIMO se realiza la toma de datos de posicionamiento mediante un arreglo de antenas 5G, que funciona como se trató en la sección Tecnología 5G orientada al posicionamiento, para obtener puntos en el ambiente cerrado útil para el enriquecimiento de la base de datos.

Información del Estado de Canal (CSI)

Los autores Ma, Zhou, & Wang (2019) definen que la Información del Estado del Canal (CSI, por sus siglas en inglés) se refiere a las propiedades conocidas del canal de comunicación en las comunicaciones inalámbricas. Esta información describe cómo se propaga una señal desde el transmisor hasta el receptor e incluye dispersión, atenuación y decaimiento de la potencia con la distancia. El CSI se usa para adaptar las transmisiones a las condiciones actuales del canal, crucial para una comunicación confiable con tasas de datos elevadas en sistemas de antenas múltiples. El CSI debe estimarse en el receptor y generalmente cuantificarse y retroalimentarse al transmisor. Hay dos niveles de CSI, a saber, el CSI instantáneo y el CSI estadístico. El CSI instantáneo implica que las condiciones actuales del canal son conocidas, mientras que el CSI estadístico significa que se conoce una caracterización estadística del canal. Bajo el contexto de posicionamiento utilizando tecnología 5G, los autores Zhou, Chen, & Ruan (2024) en su trabajo titulado "*Indoor positioning with multi-beam CSI of commercial 5G signals"*, enfatizan el uso del CSI para la ubicación en interiores y exteriores con el fin de mejorar la precisión y eficiencia del seguimiento de ubicación. La propiedad de múltiples haces de las señales 5G se aprovecha para superar los desafíos de la

ubicación en interiores con una sola estación base 5G. Gracias a la especificación de la 3GPP *Release* 16 para la ubicación en redes 5G se ha demostrado el potencial de una ubicación de alta precisión, con una precisión potencial de unos pocos metros en exteriores y unos pocos decímetros en interiores.

Respuesta en Frecuencia del Canal (CFR)

La Respuesta en Frecuencia del Canal (CFR, por sus siglas en inglés) se refiere a las características de la respuesta en frecuencia de un canal de comunicación, siendo una medida de cómo se comporta el canal al transmitir diferentes frecuencias de la señal a través de él. Este fenómeno se ve influenciado por diversos factores, como el ruido, la interferencia y la atenuación, y se utiliza para diseñar y optimizar sistemas de comunicación de acuerdo con las particularidades del canal Zaidi et al. (2018). En el contexto de la tecnología 5G, el CFR se usa para la ubicación en interiores y exteriores, para mejorar la precisión y eficiencia del seguimiento de ubicación. La representación gráfica del CFR de un canal de comunicación muestra su respuesta a diferentes frecuencias, exhibiendo tanto la magnitud como la fase de dicha respuesta. La magnitud refleja la amplitud de la señal, mientras que la fase indica el retardo temporal experimentado por la señal al atravesar el canal (Yang, Chew, & Tjhung, 2006).

Machine Learning (ML)

La colaboradora del MIT, Brown (2021) en su artículo "*Machine learning, explained*", define que el aprendizaje automático es una rama de la inteligencia artificial (IA) y la informática que se centra en el uso de datos y algoritmos para permitir que las computadoras aprendan y tomen decisiones o realicen predicciones sin ser programadas explícitamente para cada tarea. Implica el desarrollo de algoritmos que aprenden y hacen predicciones basadas en datos. El aprendizaje automático se ha convertido en un componente crucial de la IA, permitiendo

diversas aplicaciones como chatbots, texto predictivo, sistemas de recomendación, vehículos autónomos y diagnóstico médico basado en imágenes.

Brown destaca que el campo del aprendizaje automático ha experimentado avances significativos en los últimos años, impulsados por el progreso tecnológico en almacenamiento, potencia de procesamiento y la disponibilidad de grandes conjuntos de datos.

Aprendizaje supervisado

Ashenden (2021), detalla que el aprendizaje supervisado consiste de algoritmos que son entrenados mediante conjuntos de datos etiquetados que pueden ser categóricos o numéricos. Estos datos constan de entradas o ejemplos, que incluyen la respuesta o salida a la que se quiere llegar, de modo que el algoritmo pueda aprender a asignar los datos de entrada con la salida correspondiente y así predecir la categoría a la que pertenecen (clasificación) o predecir valores numéricos (regresión).

En el contexto del proyecto, dado que el objetivo es predecir las múltiples posiciones en las que puede estar un dispositivo, se trata de un problema de regresión ya que se desea predecir valores numéricos asociados a las coordenadas de dichas ubicaciones. Existen diversos modelos para emplear el aprendizaje supervisado. A continuación, se presentan los que serán utilizados en este proyecto.

Modelos de aprendizaje supervisado

Regresión lineal (LR)

La regresión lineal es un algoritmo que modela la relación lineal entre una variable dependiente o salida, y una o más variables independientes o entradas. Este método supone que existe una relación lineal entre las variables de entrada (x) y la única variable de salidas (Huff, 2018). La ecuación que modela su funcionamiento es:

$$y = mx + c \tag{1}$$

Donde:

y → Es la variable dependiente

x → Es la variable independiente

c → Es la intersección (término constante)

m → Es la pendiente

La regresión lineal se aplica en diversas áreas debido a su simplicidad y fácil interpretabilidad, lo que la convierte en una opción popular en el campo del aprendizaje automático y la ciencia de datos y en el caso del proyecto presentado sirve como un modelo básico para el estudio del comportamiento de la base de datos.

Árbol de Regresión (RT)

Un árbol de regresión es un tipo de árbol de decisión utilizado para predecir variables objetivo continuas y funciona dividiendo recursivamente los datos de entrenamiento en conjuntos más pequeños basados en ciertas características, con el objetivo de minimizar la impureza dentro de cada conjunto. Los árboles de regresión construyen una estructura similar a un árbol que consta de nodos o ramas y hojas, donde los nodos representan diferentes puntos de decisión, y las hojas representan los posibles resultados de esas decisiones (IBM, 2022).

Este algoritmo es muy utilizado y eficiente, ya que realiza implícitamente la selección de características, requiere supervisión mínima y produce modelos fáciles de entender. Sin embargo, tiene limitaciones como el sobreajuste, la alta varianza y la estructura del árbol puede ser inestable (IBM, 2022). En MATLAB® existen diversos parámetros que ayudan a solventar estos problemas, algunos de los más importantes incluyen:

- ‘*MinLeafSize*’: Controla la cantidad mínima de ejemplos/observaciones que deben estar presentes en un nodo terminal (hoja) del árbol para que el mismo pueda seguir dividiéndose.
- *‘MinParentSize*’: Controla la cantidad mínima de ejemplos que debe haber en un nodo antes de considerar realizar una nueva división.
- ‘*Prune*’: Controla la poda del árbol, eliminando ciertos nodos o ramas para reducir su complejidad y mejorar su rendimiento ante datos no vistos.

Dado que todos estos parámetros influyen directamente en la capacidad para evitar el sobreajuste, serán considerados en el presente trabajo para regular la profundidad del árbol, y así obtener resultados óptimos en la precisión de la ubicación de dispositivos.

Deep Learning (DL)

Redes Neuronales Profundas (DNN)

Las Redes Neuronales Profundas (DNN, por sus siglas en inglés) es un algoritmo que se componen de capas de nodos, o también llamados neuronas, que contienen una capa de entrada, una o más capas ocultas y una capa de salida. Cada nodo se conecta con otro y tiene un peso y un umbral asociados. Si la salida de cualquier nodo individual está por encima del valor umbral especificado, ese nodo se activa y envía datos a la siguiente capa de la red. De lo contrario, no se pasan datos a la siguiente capa de la red (IBM, 2024).

Cada conexión puede transmitir una señal a otras neuronas, lo que permite que la red aprenda y modele no linealidades y relaciones complejas, ideal para resolver problemas más complicados que los modelos de ML tradicional, como la detección de objetos, procesamiento de lenguaje natural, entre otros (Pérez, 2022).

Redes Neuronales Convolucionales (CNN)

Una Red Neuronal Convolucional (CNN) es un tipo de arquitectura de red neuronal profunda comúnmente utilizada en visión por computadora. Las CNN utilizan una serie de capas de convolución y agrupamiento para extraer características de imágenes y videos, y luego utilizan estas características para clasificar o detectar objetos o escenas. El bloque de construcción central de una CNN es la capa de convolución, la cual contiene un conjunto de filtros kernel que se convolucionan con los datos de entrada para producir el mapa de características de salida. Este mapa de características se pasa luego a través de una función de activación no lineal, como ReLU, para introducir no linealidad en el modelo, luego la salida de la capa de convolución se pasa a través de una capa de agrupamiento, que reduce el tamaño de los datos para disminuir la computación, hasta que, por último, la capa totalmente conectada realiza la predicción final y la red aprende los filtros óptimos a través de la retropropagación y el descenso de gradiente. Las CNN se utilizan en diversas aplicaciones, incluyendo reconocimiento de imágenes, reconocimiento de patrones y visión por computadora (IBM, 2024).

Hiperparámetros de redes neuronales

Los hiperparámetros son características que describen el comportamiento de las redes neuronales y que, además, permiten mejorar su rendimiento, de acuerdo a los ajustes que se empleen. A continuación, se presentan los más importantes que serán considerados en este proyecto.

Batch Size (Tamaño del lote). Es el número de ejemplos que se utiliza para realizar el entrenamiento por cada iteración. En MATLAB®, este valor puede configurarse en 32, 64 o 128.

Épocas. Es el número de veces que todo el conjunto de datos se pasa hacia adelante y hacia atrás a través de la red neuronal (Morales, 2020). Es importante mencionar que, debido a que el conjunto de datos se divide en mini lotes, el paso hacia adelante y el paso hacia atrás se repite para cada lote de datos, formando así el número de iteraciones por época. En cada iteración, los pesos de la red se actualizan. Por lo tanto, si se incrementa el número de épocas, se experimenta una mayor cantidad de iteraciones, y, en consecuencia, un aumento en las actualizaciones de los pesos.

Tasa de aprendizaje. La tasa de aprendizaje controla cuánto se deben ajustar los pesos con respecto al gradiente de pérdida. Cuanto menor sea el valor de la tasa de aprendizaje, más lenta será la convergencia a los mínimos globales. Caso contrario, si la tasa de aprendizaje tiene un valor alto, no permitirá que el gradiente de descenso converja (Khandelwal, 2019a). Esta tasa puede ajustarse dinámicamente, disminuyendo un cierto porcentaje del valor inicial después de un número específico de épocas.

Optimizadores. Son algoritmos que ajustan parámetros, como los pesos y sesgos, de una red neuronal durante el entrenamiento, con el objetivo de minimizar la función de pérdida. Algunos de los más comúnmente utilizados, que también están incorporados en MATLAB son:

SGD (Stochastic Gradient Descent). Por cada iteración se toma aleatoriamente un ejemplo de todo el conjunto de datos para calcular el gradiente y actualizar los pesos (Khandelwal, 2019b). A pesar de tener una convergencia rápida suele presentar fluctuaciones, por tal motivo se suele aplicar SGDM (SGD con Momento) el cual toma mini lotes de datos y utiliza un promedio ponderado de los gradientes anteriores para guiar las actualizaciones de los parámetros.

RMSProp (Root Mean Square Propagation). Es un optimizador adaptativo que ajusta las tasas de aprendizaje de cada parámetro de manera individual, mediante el uso de una

media móvil del gradiente al cuadrado, donde además toma en cuenta la magnitud de los descensos de gradiente recientes para normalizar el gradiente (Khandelwal, 2019b).

Adam (Adaptative Moment Estimation). Es un optimizador de descenso de gradiente de los más utilizados, que calcula la tasa de aprendizaje adaptativa individual para cada parámetro a partir del uso de una media móvil exponencial de los gradientes. Todo esto a través de estimaciones del primer y segundo momento de los gradientes (Khandelwal, 2019b).

Métodos de Normalización de Datos

Normalización 0-1

La normalización 0-1, también conocida como estandarización, es una técnica de preprocesamiento de datos utilizada en aprendizaje profundo para normalizar o reescalar los datos en un rango de (0,1). La normalización es importante porque ayuda a mejorar el rendimiento de los modelos de aprendizaje profundo al estabilizar el gradiente, asegurando que las características estén en una escala similar y facilitando que el modelo converja durante el entrenamiento (Sharma & Machiwal, 2021). Este tipo de normalización se calcula como:

$$X_{nuevo} = \frac{X - X_{min}}{X_{max} - X_{\min}} \tag{2}$$

La ecuación (2) permite ajustar el rango de [0, 1] o, a veces, a [-1, 1], y es especialmente útil cuando no hay valores atípicos, ya que no puede manejarlos eficientemente.

Normalización Z-Score

Z-score es una técnica de preprocesamiento de datos utilizada en aprendizaje automático y aprendizaje profundo para normalizar los datos de una manera que represente la cantidad de desviaciones estándar respecto a la media. El objetivo de la normalización Z-score es transformar los datos para que tengan una media de 0 y una desviación estándar de 1. (Giuseppe, Kishore, & Alexis, 2018).

En la práctica, la normalización Z-score se realiza restando la media de los datos de cada punto de datos y luego dividiendo por la desviación estándar. La fórmula para calcular el Z-score de un punto, x, es la siguiente:

$$x' = \frac{x - \mu}{\sigma} \tag{3}$$

Donde x es el valor original, μ es la media de los datos y σ es la desviación estándar de los datos.

La normalización Z-score se ve mucho menos afectada por valores atípicos en relación a la normalización 0-1, y no se limita a un rango específico.

Métricas de desempeño

MSE

El Error Cuadrático Medio (MSE, por sus siglas en inglés) es una métrica de rendimiento popular utilizada para evaluar modelos de aprendizaje automático, especialmente en problemas de regresión. Mide el promedio de las diferencias al cuadrado entre los valores reales y los predichos. El MSE se calcula como el promedio de las diferencias al cuadrado entre los valores predichos y reales. Es ampliamente utilizado debido a su diferenciabilidad, su capacidad para penalizar errores más grandes en mayor medida que los más pequeños, y su capacidad para proporcionar una medida del rendimiento del modelo que ayuda a identificar el modelo con las predicciones más precisas. El MSE es una función de pérdida importante para algoritmos ajustados u optimizados mediante el método de mínimos cuadrados. Se emplea comúnmente al comparar diferentes modelos en el mismo conjunto de datos, ya que ayuda a identificar el modelo con las predicciones más precisas (Giuseppe, Kishore, & Alexis, 2018).

$$MSE = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2 \tag{4}$$

Donde y_i es el valor real, $\hat{y}_i$ es el valor predicho y N es el número de puntos de datos

RMSE.

La Raíz del Error Cuadrático Medio (RMSE, por sus siglas en inglés) es una métrica de rendimiento utilizada para evaluar modelos de aprendizaje automático, especialmente en tareas de regresión. Mide la diferencia cuadrada promedio entre los valores reales y los valores predichos, y luego calcula la raíz cuadrada del resultado. La ecuación (5) presenta la forma de calcular El RMSE.

$$RMSE = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2} \qquad (5)$$

Donde y_i es el valor real, $\hat{y}_i$ es el valor predicho y N es el número de puntos de datos. La Raíz del Error Cuadrático Medio (RMSE) destaca por su facilidad de diferenciación, lo que lo hace compatible con métodos de optimización basados en gradientes como el descenso de gradiente. Además, la inclusión de la raíz cuadrada en su fórmula garantiza que las unidades del RMSE coincidan con las unidades originales de la variable objetivo. Este aspecto es crucial para mantener la coherencia en las unidades de medida. Un rasgo distintivo del RMSE es su capacidad para penalizar de manera más pronunciada los errores de mayor magnitud en comparación con los errores más pequeños, aspecto relevante en situaciones donde el conjunto de datos presenta valores atípicos. Esta característica contribuye a que el RMSE sea una métrica efectiva, especialmente cuando se busca dar mayor peso a los errores significativos en la evaluación del rendimiento del modelo (Giuseppe, Kishore, & Alexis, 2018).

Distancia Euclidiana.

La métrica de distancia euclidiana se utiliza en aprendizaje automático para medir la similitud entre dos puntos de datos. Es la distancia más corta entre cualquier par de puntos en un espacio métrico. La distancia euclidiana se calcula utilizando la raíz cuadrada de la suma de

las diferencias al cuadrado entre las coordenadas de los dos puntos y se utiliza ampliamente en varios algoritmos de aprendizaje automático, como *k* Vecinos Más Cercanos (KNN, por sus siglas en inglés), DNN, CNN y algoritmos de agrupamiento, para agrupar puntos de datos o encontrar los puntos más cercanos a un punto de datos dado. La distancia euclidiana es intuitiva y funciona bien cuando la distribución de características está equilibrada. Sin embargo, puede no ser adecuada para datos de alta dimensionalidad, donde la efectividad de la distancia euclidiana se descompone a medida que aumenta la dimensionalidad y la distancia promedio entre dos vectores aumenta, haciendo que la métrica de distancia pierda su significado. A pesar de esto, la distancia euclidiana sigue siendo una métrica de distancia popular y ampliamente utilizada en muchas aplicaciones de aprendizaje automático (Rahayu, 2022).

Capitulo III: Materiales y Metodología

Materiales

En esta sección, se detallan las herramientas de hardware y software empleadas para llevar a cabo los distintos entrenamientos, y se describen las características y estructura de la base de datos escogida para entrenar y evaluar los modelos

Software

La implementación de los diversos algoritmos de ML y DL destinados a predecir el posicionamiento de dispositivos se lleva a cabo utilizando MATLAB® en la versión R2023b. Se opta por este software debido a su versatilidad, lenguaje de programación intuitivo y la inclusión de los Toolbox necesarios para ML y DL. Adicionalmente, aprovechando las licencias académicas proporcionadas por la universidad, se recurre a servidores en la nube para ejecutar algoritmos que demandan recursos computacionales extensos.

Hardware

En cuanto al hardware, se utiliza una computadora equipada con un procesador Intel® Core™ i5 de octava generación, que cuenta con 4 núcleos físicos y 8 lógicos. Además, dispone de 8 GB de memoria RAM y opera bajo el sistema operativo Windows 11 Pro.

Base de datos

Como se introdujo previamente en el Capítulo I, la base de datos desarrollada por Gao et al. (2022), la cual se encuentra en el enlace Dataset, fue considerada como la más viable para utilizarla en el entrenamiento con los distintos modelos, ya que comprende características representadas mediante matrices CFR, totalizando 4816 muestras, un escenario de una oficina lo suficientemente amplio para realizar las predicciones y diferentes niveles de SNR para dar robustez al sistema ante el ruido inherente en el canal. Además, se incluyen etiquetas

asociadas a las 4816 coordenadas en 3D que identifican todos los posibles puntos de ubicación del dispositivo dentro de la oficina, la cual se presenta en detalle en la Figura 1.

Figura 1

Ilustración en 3D de la Oficina de la Academia de Ciencias de Beijing

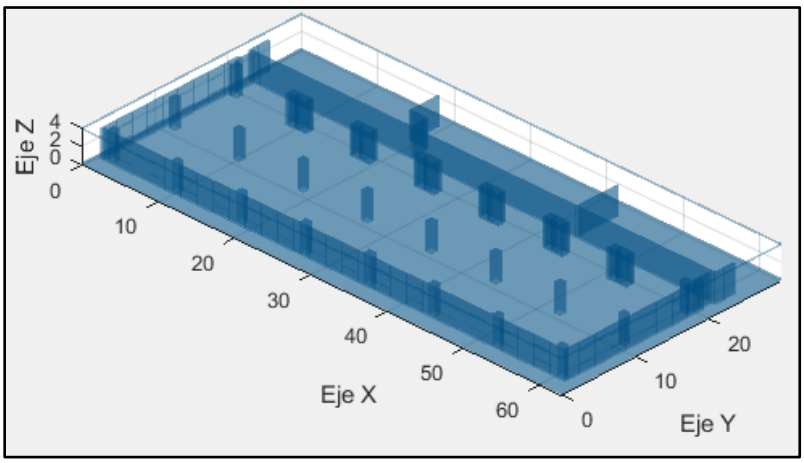

Es importante comprender el proceso de obtención de cada muestra. En este sentido, los autores Gao et al. (2022) ubicaron un conjunto de 5 estaciones base (gNBs) estratégicamente distribuidas en todo el escenario a una altura de 2.4 metros del nivel del suelo, como se ilustra en la Figura 2.

Figura 2

Ubicación de gNBs en el Escenario

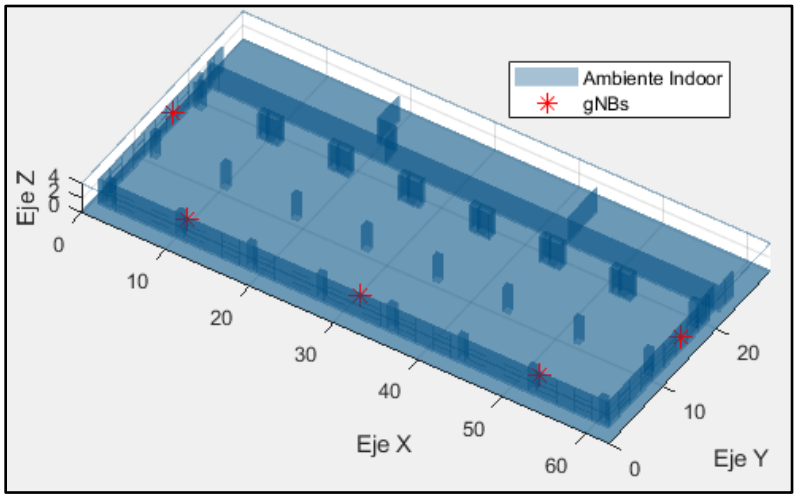

Cada estación base (gNB) emite una señal piloto dirigida al dispositivo (UE). Al recibir estas señales, independientemente de la ubicación específica en la que se encuentre, se logra obtener una matriz CFR por cada gNB, totalizando 5 matrices CFR por cada muestra. Este procedimiento se repite para cada muestra (ubicación) del dispositivo dentro de la oficina y se materializa a través de un proceso previo que se rige de acuerdo al diagrama de bloques representado en la Figura 3, el cual consta de 3 capas que se analizan a continuación.

Figura 3

Proceso para la Generación de Matrices CFR

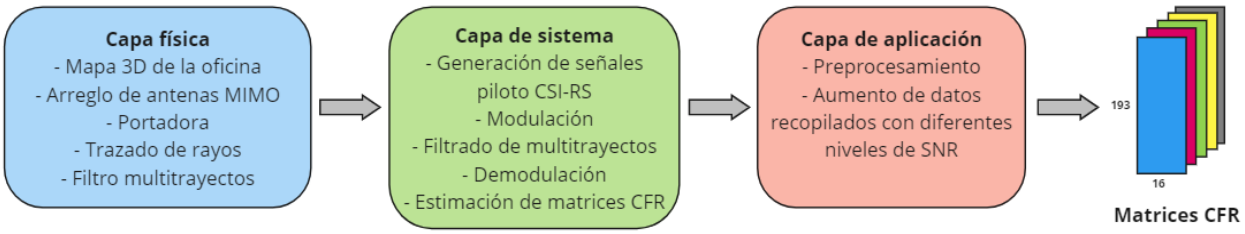

Capa física

Figura 4

Canales MIMO entre un par gNB-UE

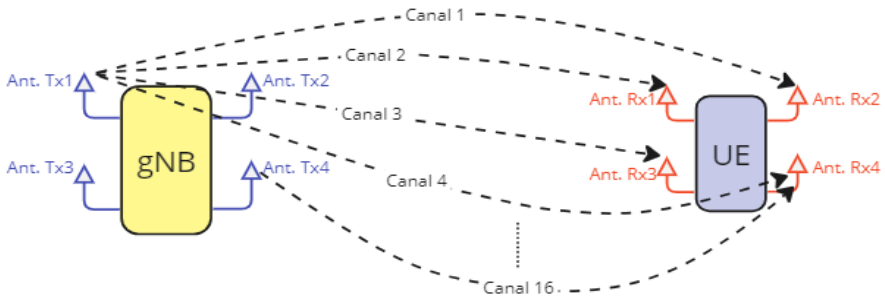

En esta capa se toman en cuenta todas las características físicas necesarias para la generación y propagación de las señales. En ese sentido, primero se considera el escenario físico (oficina) que va a representar el canal inalámbrico por donde se propagan las señales, además, se toma en cuenta el arreglo de antenas de los gNBs y el UE, en ambos casos con un

arreglo de tipo URA de k x k elementos, con una separación de 0.5λ entre cada elemento. En este caso, únicamente se consideran las antenas transmisoras de los gNBs y las receptoras del UE, ya que el estudio se enfoca en el análisis de enlace descendente. De esta manera se forma un sistema MIMO de 16 canales, el cual se ilustra en la Figura 4.

Adicional a ello, se toman en cuenta las especificaciones definidas en 3GPP R16 TR 38.901, que se enfoca en la tecnología 5G. Estas especificaciones detallan, entre otros aspectos, los parámetros de la portadora que las gNBs pueden utilizar, el diseño de la señal de referencia 5G New Ratio (NR) que los gNBs enviarán al UE y las características del modelo de propagación para escenarios interiores. Basado en esto, los autores consideraron trabajar con gNBs que operen a 3.5 GHz y asumieron un modelo de trazado de rayos con un orden máximo de reflexión de 2 y un orden de penetración a obstáculos de 1. Esto quiere decir que una onda puede rebotar en un máximo de dos superficies antes de llegar al receptor, y de manera similar, puede atravesar hasta un obstáculo antes de llegar al receptor. Estos parámetros fueron considerados para construir el modelo de trazado de rayos que se describe en base a la siguiente ecuación:

$$P^{3D}(d) = \frac{P_t \lambda^2}{(4\pi d)^2} \sum_{k=-m}^{m} \cos(\theta_k)\sqrt{G_{tx}G_{rx}} * \left(\Gamma^{ceiling}(\theta_k)\right) * \left|\left[\frac{k+1}{2}\right]\right| \left(\Gamma^{floor}(\theta_k)\right) \left|\left[\frac{k}{2}\right]\right| \prod_{i=0}^{N} I_t(\theta_k), \quad (6)$$

Donde P_t es la Potencia de Transmisión, θ_k es el Ángulo de Elevación del k-ésimo rayo, G_{tx} es la Ganancia de la Antena Transmisora, G_{rx} es la Ganancia de la Antena Receptora, λ es la Longitud de onda, d es la Longitud del camino de propagación, Γ es el Coeficiente de Reflexión y I es el Coeficiente de interacción en presencia de obstáculos (Gao et al., 2022).

Como se puede observar, la ecuación 1 contiene información relevante que está directamente relacionada con la posición del UE, incluyendo el ángulo de llegada que está

indirectamente relacionado con θ_k, el número de rayos y la longitud total que recorre cada uno desde cada gNB hasta el UE. Además, los parámetros que describen las características de los equipos transmisores y receptores, así como la frecuencia de la señal y las distancias, describen el modelo de propagación de los distintos rayos en todo el escenario. Por lo tanto, el método de trazado de rayos realizado por los autores, en concordancia con las especificaciones de 3GPP R16 TR 38.901, resulta ser altamente confiable y fiel al comportamiento de los multitrayectos en una comunicación inalámbrica real.

Posterior a este proceso, el siguiente paso consiste en llevar a cabo la superposición de todos los rayos. Esta etapa resulta fundamental, ya que los dispositivos (UEs) no pueden reconocer los múltiples rayos con todas las características asociadas a cada uno. En realidad, solo pueden captar la superposición de todas esas trayectorias. Por este motivo, se aplica un filtro denominado "Filter Multipath", el cual lleva a cabo este procedimiento, proporcionando al UE las características de la superposición de todos los trayectos, según el canal MIMO correspondiente.

Capa de sistema.

Luego de considerar todos los parámetros físicos discutidos en la capa anterior, se pone en funcionamiento al sistema. Es decir, se generan las señales de referencia CSI (CSI-RS) como pilotos para cada gNB, las cuales son moduladas y filtradas mediante “Filter Multipath”. Posteriormente, se realiza la demodulación de las señales piloto recibidas en el UE y finalmente las matrices CFR se estiman, haciendo previamente una estimación del canal con desvanecimiento por las múltiples trayectorias que se forman dentro de la oficina.

De acuerdo a Gao et al. (2022), la matriz CFR es una medida detallada y relacionada con la posición, que muestra marcadas diferencias en diferentes ubicaciones, lo que es útil para el posicionamiento de alta precisión. Además, las correlaciones de canales derivadas de un conjunto de antenas MIMO son beneficiosas para el posicionamiento, ya que las sutiles

diferencias existentes entre cada canal se utilizan para capturar características integradas, mejorando así la precisión del posicionamiento. Es así, que esto contribuye a una información con mayor confiabilidad y robustez en comparación con el valor RSRP utilizado en otras investigaciones, tal como las mencionadas en el Capítulo I. Finalmente, los autores generan por cada gNB una matriz que encapsula la Respuesta en Frecuencia del Canal, considerando tanto el total de subportadoras como el total de símbolos OFDM. Esta representación se visualiza en la Figura 5.

Figura 5

CFR obtenida en el UE desde 4 gNBs diferentes

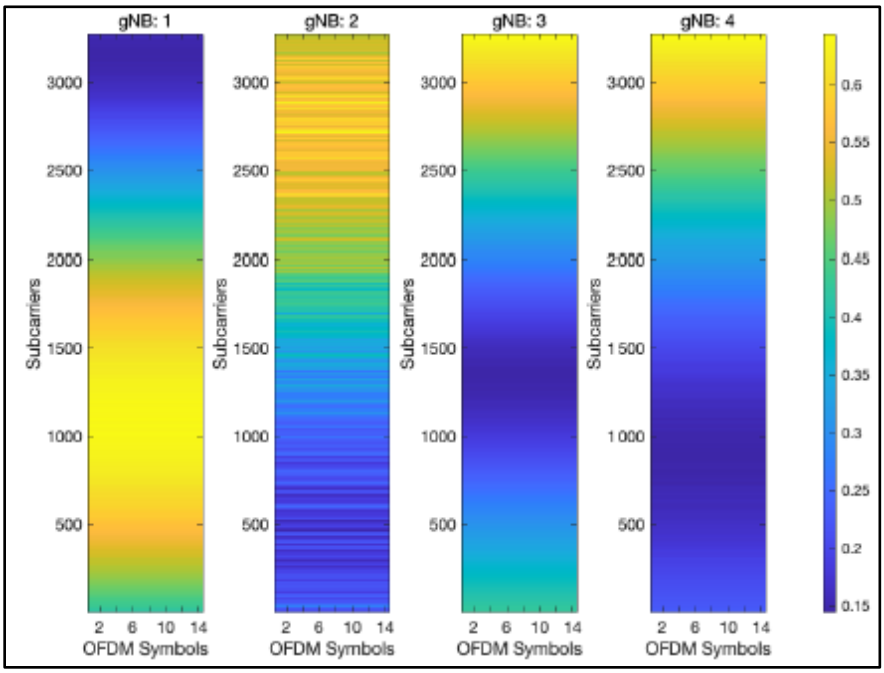

Nota. Recuperado de (Gao et al., 2022)

En las ilustraciones presentadas, se muestran cuatro imágenes correspondientes a la matrices CFR observadas en el UE desde cuatro gNBs diferentes, todas obtenidas con el UE posicionado en la misma ubicación. Esta visualización destaca la marcada disparidad en la

información recopilada desde cada gNB, proporcionando así, inicialmente, una sólida fuente de datos para la estimación precisa del posicionamiento del UE a lo largo de toda la oficina.

Capa de aplicación.

Aunque en la capa anterior se obtuvieron matrices CFR bastante acertadas con información relevante, es importante recalcar que no detallan la información sobre todos los canales MIMO. Además, es evidente que existe redundancia de información a lo largo de todos los símbolos OFDM para cada subportadora, y lo mismo ocurre en rangos determinados de subportadoras adyacentes. Por este motivo, en esta capa los autores aplican un procesamiento adicional, en el que primero se reduce el número de subportadoras, tomando únicamente las muestras más relevantes, y segundo, se toma solamente un símbolo OFDM por cada muestra. Este enfoque logra una considerable reducción en la redundancia de información, posibilitando incorporar en una misma matriz, datos de los 16 canales MIMO, como se muestra en la Figura 6.

Figura 6

Matriz CFR obtenido desde una gNB después del procesamiento

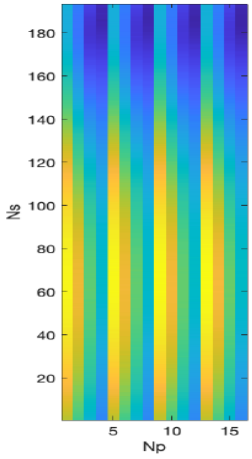

Nota. Recuperado de (Gao et al., 2022)

La ilustración revela que ahora el eje vertical contiene 193 muestras de un total inicial de aproximadamente 3200 subportadoras, mientras que en el eje horizontal se presentan los

16 canales MIMO. Cada matriz tiene, por lo tanto, una dimensión de *Ns* filas por *Np* columnas, donde:

- *Ns*: Número de muestras de las subportadoras
- *Np*: Número de canales MIMO

De esta manera, este procesamiento no solo permitió almacenar una cantidad significativamente mayor de información en un espacio más compacto, sino que también reduce de manera considerable la carga computacional necesaria para aplicar los diversos algoritmos de ML y DL en la estimación del posicionamiento de los dispositivos.

Finalmente, los autores realizaron un aumento de los datos, recopilando matrices CFR con 3 Relaciones Señal a Ruido (SNR) distintas, correspondientes a los valores de 50 dB, 20 dB y 10 dB. Este procedimiento fue realizado a nivel de capa física a través del denominado "Filter Multipath" y su relevancia radica en que son mediciones reales, leales al comportamiento del entorno inalámbrico real. Las matrices obtenidas se ilustran en la Figura 7.

Figura 7

Matrices CFR obtenidas desde una gNB con tres niveles de SNR

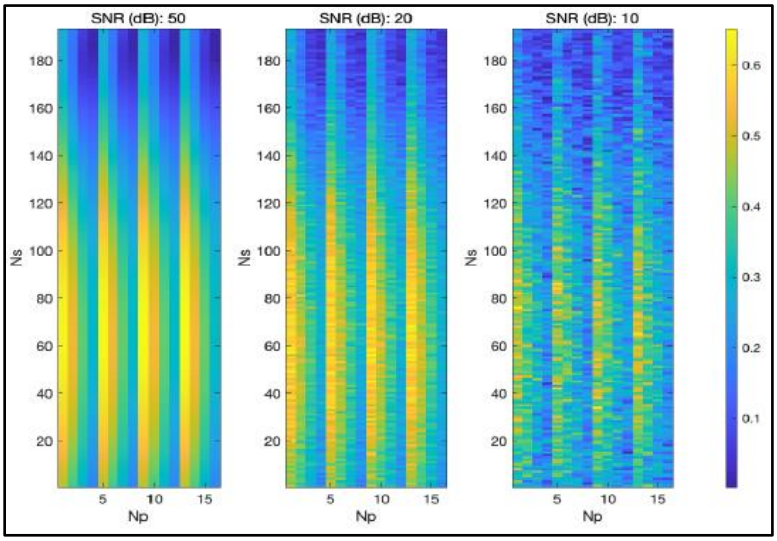

Nota. Recuperado de (Gao et al., 2022)

Después de tener en cuenta estos tres niveles de SNR por cada muestra, se forma una base de datos lo suficientemente robusta frente a los diferentes niveles de ruido que podrían presentarse en el canal inalámbrico. Esta robustez permite que los diversos modelos de Inteligencia Artificial puedan generalizar a partir de un conjunto más amplio de ejemplos de entrada, lo que resulta en una mayor precisión en la predicción del posicionamiento de los dispositivos.

Estructura de datos

Una vez completado el proceso de obtención de las matrices CFR, fueron organizadas de manera estructurada, asegurando que cada conjunto de 5 matrices (características) se corresponda con su respectiva etiqueta.

Características

La Figura 8 presenta la estructura del conjunto de características. Los datos están organizados en un arreglo matricial de 4 dimensiones, donde la primera y segunda dimensión corresponden al largo y ancho de cada matriz CFR, mientras que cada conjunto de 5 matrices CFR, asociado a una muestra diferente, se organiza a lo largo de la tercera dimensión. Por último, en la cuarta dimensión se especifica el número correspondiente a cada muestra.

De esta manera, el tamaño de la matriz tetradimensional del conjunto de características se expresa como *Ns x Np x Ng x Nu*, donde:

- *Ns*: Número de muestras de las subportadoras
- *Np*: Número de canales MIMO
- *Ng*: Número de gNBs
- *Nu*: Número de muestras

Figura 8

Estructuración del Conjunto de Features

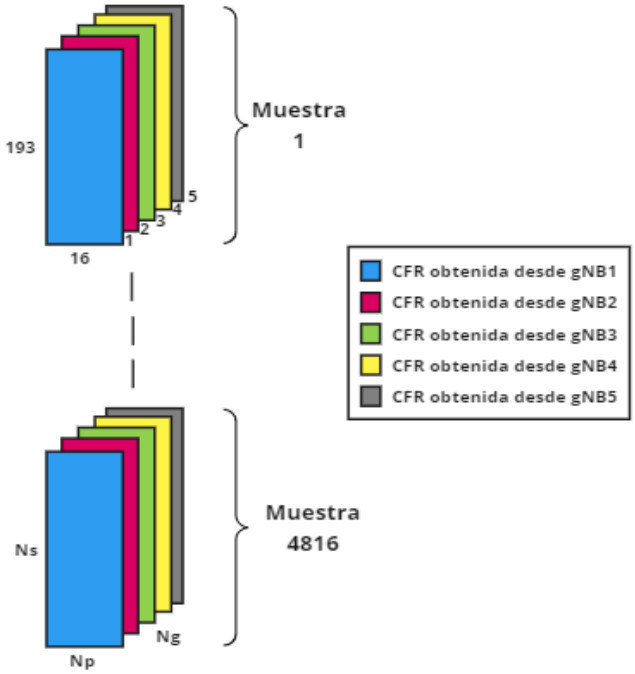

Etiquetas

Las etiquetas contienen la información de las 4816 coordenadas tridimensionales, las cuales están organizadas en un arreglo bidimensional de tamaño *4816 x 3*, donde las filas representan el número total de muestras, mientras que cada columna corresponde a la respectiva coordenada X, Y o Z. Su estructura se presenta en la Figura 9.

Figura 9

Estructuración del Conjunto de Labels

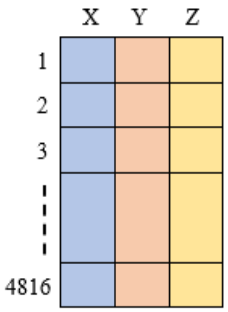

Es importante mencionar que, dentro de las dimensiones totales de la oficina, la coordenada en X abarca un rango desde 4.4 [m] hasta 58.4 [m], con una separación de 0.5 [m] entre cada punto. En cuanto a la coordenada en Y, su rango se extiende desde 4.3 [m] hasta 16.3 [m], también con una separación de 0.5 [m] entre cada punto. Por último, la coordenada en Z comprende únicamente dos alturas: 1.2 [m] y 1.7 [m]. Esta elección se basa en la simulación de la altura promedio a la que una persona tendría su dispositivo móvil en las manos, ya sea estando de pie o sentada.

Concatenación de los tres niveles de SNR

Finalmente, para garantizar la robustez frente al ruido, es necesario tener en cuenta los tres niveles de SNR. Es así, que la consolidación de esta información en un único conjunto de datos se hace necesaria tanto para el conjunto de características como para el conjunto de etiquetas, como se detalla en la Figura 10.

Figura 10

Concatenación de los tres niveles de SNR en los conjuntos de Características y Etiquetas

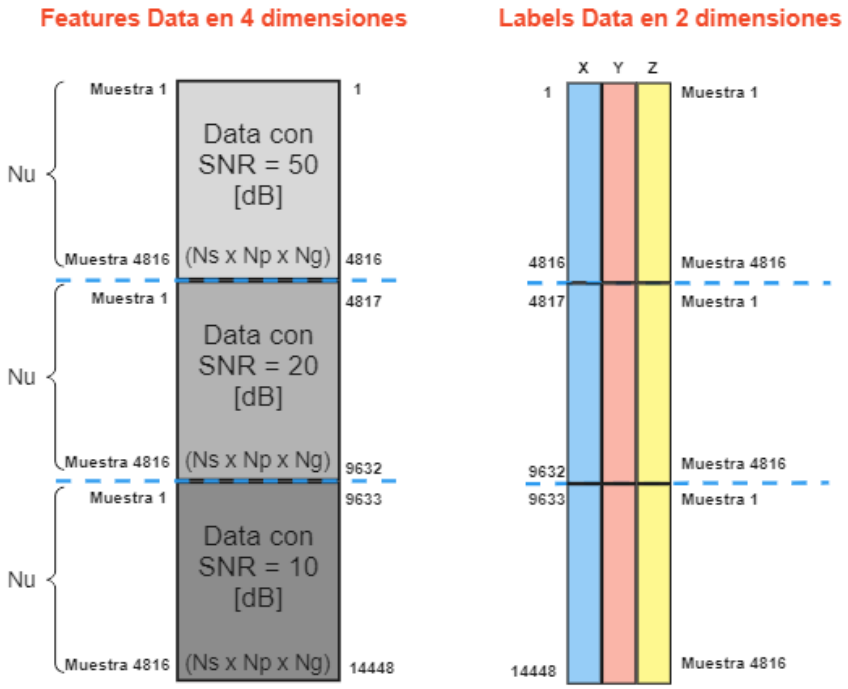

En cuanto a los datos del conjunto de *Features* se unió los tres niveles de SNR realizando una concatenación a lo largo de la dimensión correspondiente al número de muestras (Nu), es decir, en la cuarta dimensión. El mismo procedimiento se realizó en los datos del conjunto de *Labels*, pero en este caso replicando tres veces las 4816 coordenadas a lo largo de la primera dimensión. De esta manera, el número de muestras de cada matriz aumentó a 3Nu, resultando en un tamaño de (*Ns x Np x Ng x 3Nu*) para *Features* y (*3Nu x 3*) para *Labels*, tal como se observa en la Figura 11.

Figura 11

Estructura del Conjunto de Datos con los Tres Niveles de SNR

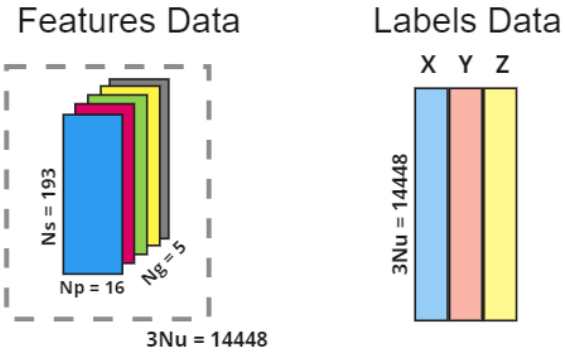

Es importante aclarar que este procedimiento no implica que se haya hecho un aumento en el número de ubicaciones donde se realizaron las mediciones, sino que, ahora por cada ubicación, se tienen tres mediciones con diferentes niveles de SNR

Metodología

La metodología empleada para llevar a cabo la predicción de la ubicación de dispositivos está organizada en tres etapas que son: Preprocesamiento de datos, Entrenamiento y Predicción. Cada una conlleva su respectivo proceso, de acuerdo a lo ilustrado en la Figura 12, abarcando desde la manera en la que ingresan los datos al sistema, los tipos de normalización empleada y la segmentación de datos, hasta la predicción de cada coordenada.

Figura 12

Esquema General de la Metodología aplicada al Sistema de Posicionamiento de Dispositivos

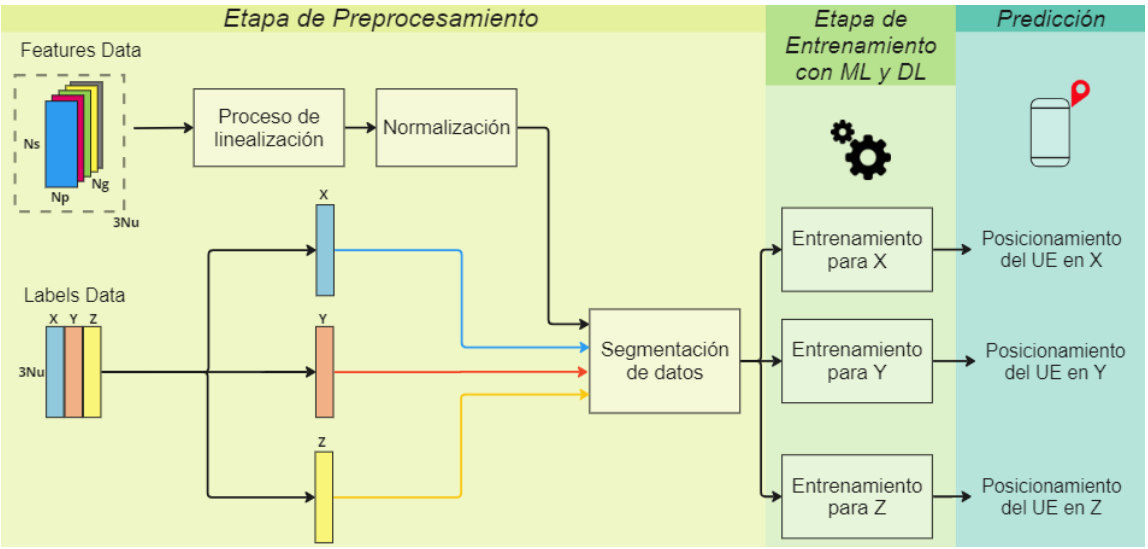

En este caso, la propuesta incluye tanto la implementación con ML mediante los modelos de LR y RT, así como con DL a través de los modelos de DNN y CNN en la Etapa de Entrenamiento.

Cada modelo contempla inicialmente la configuración más simple, con el objetivo de evaluar los primeros resultados, y en función de ello considerar la posibilidad de descartar o ajustar cada modelo, siendo esto último un punto importante para aumentar lo máximo posible la precisión del posicionamiento.

A continuación, se describe más a detalle cada una de las etapas que sustentan la metodología empleada

Etapa de Preprocesamiento

Proceso de linealización para ML Tradicional y DNN

La etapa de preprocesamiento inicia con un proceso de linealización al conjunto de *Features* debido a que, los algoritmos de LR, RT y DNN únicamente permiten el ingreso de información con dicha estructura para realizar el entrenamiento.

Tal como se detalló en la subsección ‘Concatenación de los tres niveles de SNR’, el conjunto de *Features* se organizó en un arreglo de cuatro dimensiones con un total de 3Nu muestras. Luego de aplicar la linealización propuesta, se obtiene un arreglo resultante bidimensional con *3Nu* filas y *Ns*Np*Ng* columnas, que representan el número de muestras y el número de características, respectivamente. Este proceso se ilustra en la Figura 13.

Figura 13

Linealización del Conjunto de Características

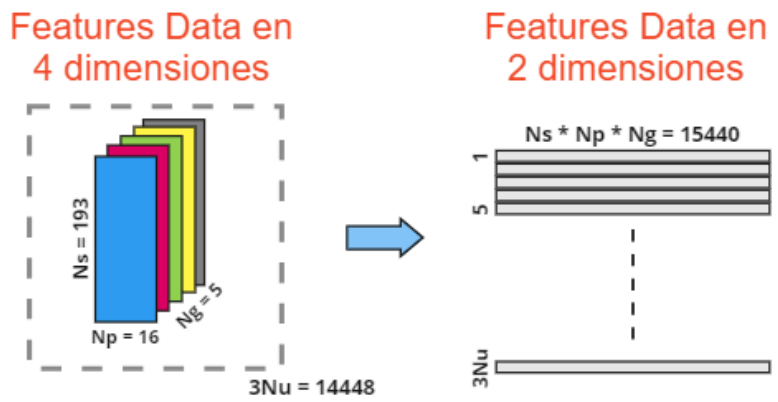

Normalización

Una vez linealizados los datos, se procede con el proceso de normalización. En esta etapa, inicialmente se propuso emplear dos métodos: Normalización 0-1 y Z-score. Sin embargo, al observar la distribución original de los datos, como se presenta en la Figura 14, se evidenció que estos ya se encontraban dentro de un rango aproximado de 0 a 1. Como resultado, se optó por omitir la aplicación de la primera normalización y aplicar únicamente el método Z-Score.

La distribución resultante se presenta en la Figura 15, donde se observa que los datos fueron reescalados alcanzando una media de 0 y una desviación estándar de 1.

Figura 14

Distribución de datos sin Normalización

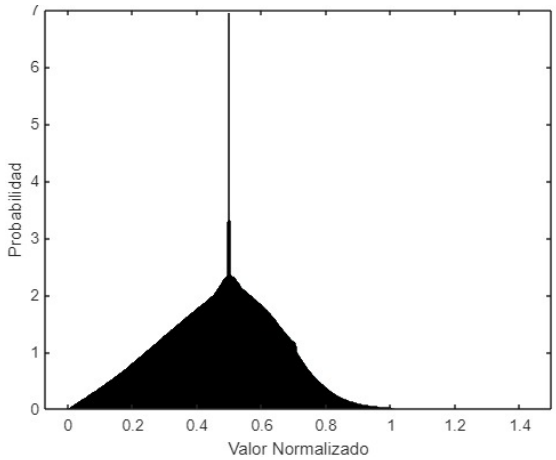

Figura 15

Distribución de datos con Normalización Z-Score

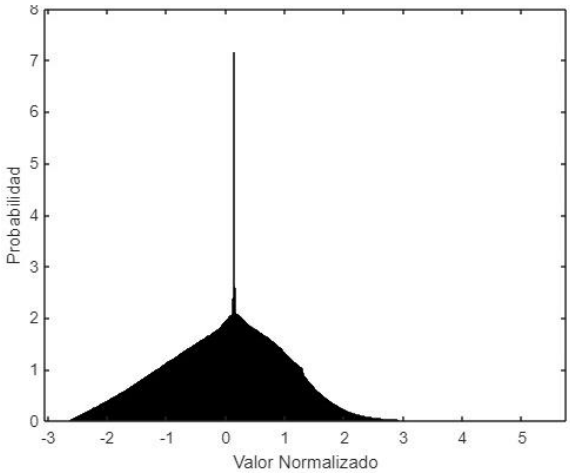

Segmentación de datos

La segmentación o partición de datos es un punto relevante dentro del preprocesamiento, ya que permite realizar la división del conjunto de datos completo (*Features* y *Labels*) en dos conjuntos distintos: el conjunto de entrenamiento y el conjunto de validación, necesarios para entrenar y evaluar el rendimiento de los cuatro modelos considerados.

En este enfoque, dicha segmentación se realiza tanto en las matrices CFR (*Features*) como en las coordenadas (*Labels*) a través del método de *Hold Out*, el cual permite seleccionar muestras de manera aleatoria y las asigna al conjunto de entrenamiento o al conjunto de validación.

Aunque existen diversas proporciones que se pueden aplicar para realizar esta división, en este caso se optó por realizar una partición 70-30. Esta elección se hizo debido al limitado número de muestras que contiene el conjunto de datos, encontrando así un equilibrio entre disponer de datos suficientes para un entrenamiento robusto del sistema y contar con un conjunto de validación representativo y confiable para evaluar el rendimiento del mismo con ejemplos que no se hayan visto durante el entrenamiento. A esta segmentación se la denomina Tipo A, y se muestra en la Figura 16.

Figura 16

Segmentación de Datos Tipo A

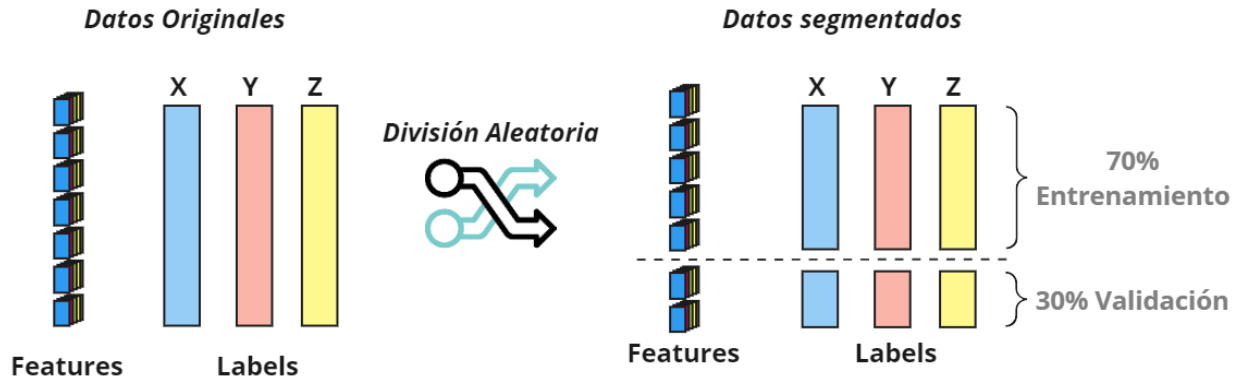

Nota. El gráfico ilustra la partición de datos aplicando el método de *Hold Out*, lo que significa que tanto el conjunto de entrenamiento como el de validación contendrán muestras con SNR de 50 dB, 20 dB y 10 dB, seleccionadas de forma aleatoria. Esta segmentación da como resultado un total de 10114 muestras para entrenamiento y 4334 muestras para validación.

La segmentación Tipo A es utilizada en todos los modelos, con el fin de evaluar y determinar cuál proporciona los mejores resultados. Una vez identificado el mejor modelo, se optó por implementar dos tipos de segmentación adicionales, las cuales se detallan en la Tabla 1, con el propósito de evaluar de manera más exhaustiva el desempeño del modelo seleccionado.

Tabla 1

Segmentaciones de Datos Tipo B y C

Tipo	Segmentación Tipo B	Segmentación Tipo C	Proporción
Entrenamiento	Data con SNR de 50 dB Data con SNR de 10 dB	Data con SNR de 50 dB Data con SNR de 20 dB	9632 (66.67%)
Validación	Data con SNR de 20 dB	Data con SNR de 10 dB	4816 (33.33%)

Nota. Esta tabla presenta la distribución de los datos entre los conjuntos de entrenamiento y validación, de acuerdo a los diferentes niveles de SNR incluidos en la base de datos. Estas segmentaciones están destinadas a ser utilizadas únicamente en el mejor modelo.

Como se puede observar, para la Segmentación Tipo B se planteó utilizar los datos con SNR de 50 dB y 10 dB para entrenamiento, mientras que los datos con SNR de 20 dB se destinan para validación. Esta partición se hizo con la finalidad de observar qué tan eficiente sería el sistema si se enfrenta a condiciones de canal con una SNR que se encuentre dentro de ese rango, determinado en este caso por el conjunto de entrenamiento.

Por otro lado, la Segmentación Tipo C utiliza los datos con SNR de 50 dB y 20 dB para entrenamiento, dejando los datos con SNR de 10 dB para validación. Asimismo, el objetivo es analizar la eficiencia del sistema, pero esta vez ante condiciones de canal en peores condiciones con una SNR inferior, situada por debajo de dicho rango.

Etapa de Entrenamiento

Una vez culminado el preprocesamiento de los datos, se inicia la Etapa de Entrenamiento con cada uno de los modelos. A continuación, se describe la manera en la que se emplea cada uno, así como sus requerimientos, configuraciones y arquitecturas.

Implementación con Machine Learning Tradicional

Regresión lineal (LR)

Este modelo es el más simple dentro de todos los considerados en este estudio y se utilizó como punto de partida para observar su eficiencia en la predicción de las coordenadas. Para su funcionamiento únicamente se requirió ingresar los datos previamente linealizados, donde 10114 muestras fueron utilizadas para el entrenamiento del modelo y 4334 para validación, cada una con 15440 características. Es importante acotar que, el entrenamiento se hizo de manera individual para cada coordenada, ya que este modelo no permite predecir más de una variable a la vez.

Árbol de regresión (RT)

Para el modelo de RT, al igual que con el modelo de LR, se requirió la entrada de datos linealizados con la misma estructura. Sin embargo, una de las ventajas del modelo de RT con respecto al modelo de LR es que es capaz de capturar relaciones no lineales entre las variables predictoras y las coordenadas de posición. Además, es mucho más flexible ya que permite ajustar los parámetros, discutidos en el Capítulo II, para regular la profundidad del árbol, lo que ayudaría a lograr una mejor precisión en el posicionamiento de los dispositivos. En ese sentido, se propuso la implementación de este modelo comenzando con una predicción inicial utilizando los parámetros preestablecidos en MATLAB® presentados en la Tabla 2. Luego, se contempla el ajuste iterativo de los mismos hasta alcanzar un resultado óptimo en la predicción individual de cada coordenada.

Los detalles de este ajuste se presentan en la subsección ‘Regresión Lineal’ del Capítulo IV.

Tabla 2

Configuración inicial aplicada al modelo RT

Configuración	Descripción
MinLeafSize = 1	Cada hoja debe contener al menos una muestra para que el árbol siga dividiéndose
MinParentSize = 10	Cada nodo interno se dividirá si al menos tiene 10 muestras
Prune: No	No se emplea la técnica de poda

Implementación con Deep Learning

Figura 17

Metodología empleada en la Etapa de Entrenamiento con DL

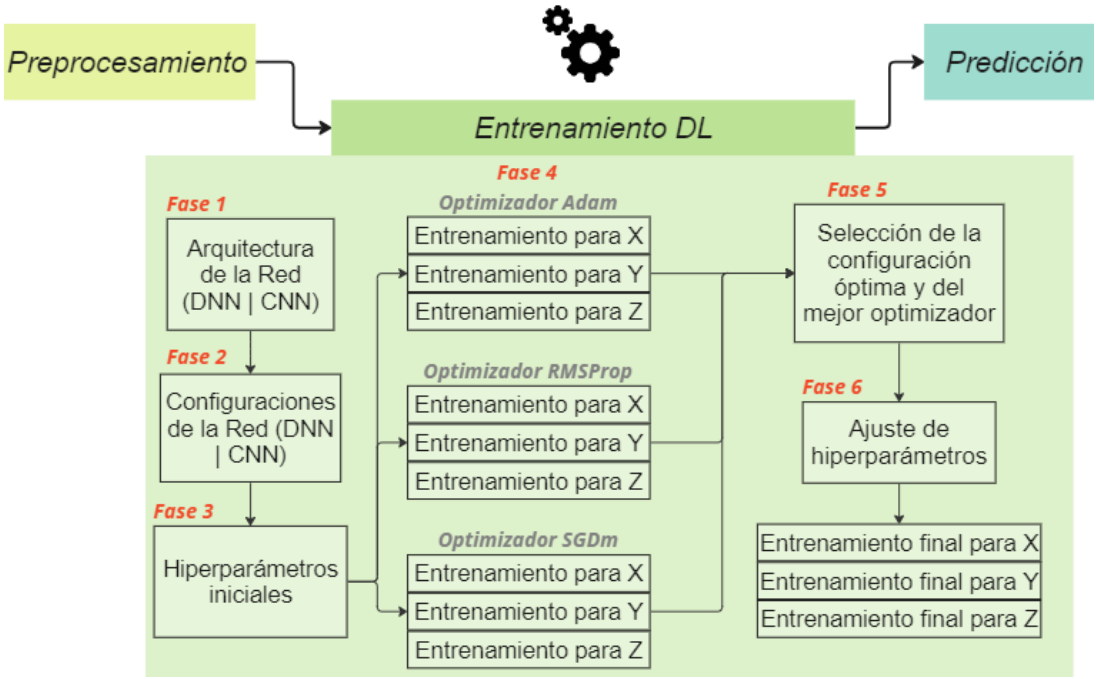

Para la implementación del sistema mediante DL se adoptó el procedimiento especificado en la Figura 17. Esta metodología se aplica de la misma manera tanto para el modelo de DNN como para CNN, y se divide en seis fases fundamentales. A continuación, se presenta una descripción general de cada una.

- Fase 1: La metodología empieza con el establecimiento de la arquitectura de la red, especificando el tipo de capas empleadas, su disposición y la forma en cómo están conectadas.
- Fase 2: Una vez establecida la arquitectura de la red, se procede a configurar los parámetros específicos de acuerdo al tipo de modelo. En el caso del modelo de DNN, se define el número de capas ocultas y el número de neuronas por cada una. Por otro lado, para el modelo de CNN, se especifica el número de capas convolucionales, así como el número de filtros por cada capa y su respectivo tamaño. En cada modelo se tomaron en cuenta un total de 6 y 4 configuraciones, respectivamente, con el objetivo de compararlas y seleccionar aquella que demuestre un mejor desempeño. Los detalles específicos de cada una de estas configuraciones serán abordados en las subsecciones ‘Redes Neuronales Profundas’ y ‘Redes Neuronales Convolucionales’ del presente capítulo.
- Fase 3: El siguiente paso consiste en establecer los hiperparámetros iniciales a todas las configuraciones establecidas en la fase anterior. Para este caso, se aplica una metodología en la que se mantienen constantes los valores de tasa de aprendizaje, el *Batch Size* y el número de épocas, pero se varía el optimizador. Esta estrategia permite evaluar el impacto de los diferentes optimizadores en el rendimiento de los modelos.

- Fase 4: A pesar de que en los modelos de DNN y CNN sí es posible predecir más de una variable a la vez, se propuso realizar un entrenamiento por separado para cada coordenada. Esto se debe a varias razones, como la simplificación del aprendizaje, flexibilidad en la arquitectura de la red para cada coordenada, una mejor generalización y una interpretación más sencilla de las predicciones. Por lo tanto, esta fase contempla el entrenamiento de manera individual para cada coordenada utilizando los tres optimizadores considerados en este estudio que son: *Adam, RMSProp y SGDm.*
- Fase 5: En función de los resultados obtenidos con cada optimizador, se selecciona aquel que haya demostrado el mejor rendimiento, junto con la configuración más eficaz, basándose en su capacidad de convergencia y la precisión alcanzada en términos de RMSE.
- Fase 6: Finalmente, después de haber escogido el modelo con el mejor optimizador y la mejor configuración, se realiza el ajuste final de los hiperparámetros y se procede a entrenar nuevamente la red hasta mejorar los resultados y lograr un sistema más preciso.

Esta propuesta brinda una forma sistemática para garantizar la optimización y mejora de los resultados con los modelos DNN y CNN. Para comprender a fondo este proceso, a continuación, se explican las Fases 1, 2 y 3, las cuales abordan la metodología de diseño aplicada a cada modelo. Por otro lado, las Fases 4, 5 y 6 se profundizarán con mayor detalle en la sección ‘Resultados con Deep Learning’ del Capítulo IV, ya que están directamente relacionadas con los resultados obtenidos después del entrenamiento de cada modelo.

Redes Neuronales Profundas (DNN)

Fase 1: Arquitectura de la DNN

La arquitectura propuesta para este modelo se caracteriza no solo por tener una capa de entrada y una capa de salida como en las Redes Neuronales Simples (ANN, del inglés *Artificial Neural Networks*), sino que además contiene múltiples capas ocultas, cada una compuesta por un número determinado de neuronas, tal como se observa en la Figura 18.

Figura 18

Arquitectura de la DNN empleada para el Posicionamiento de Dispositivos

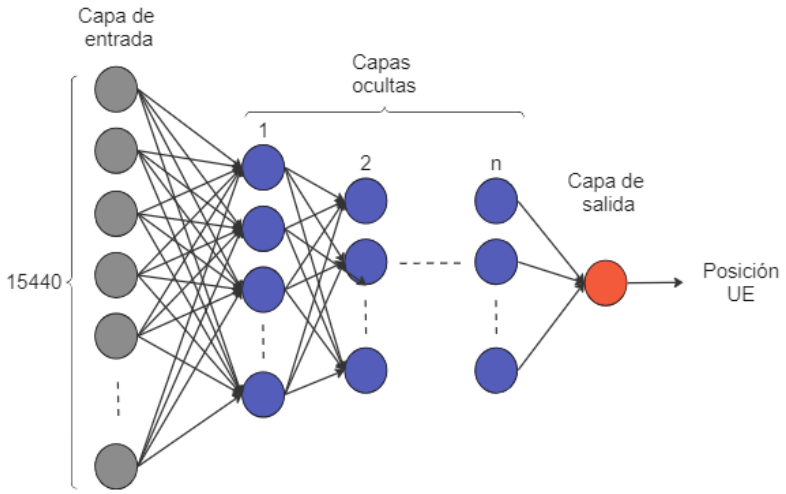

Nota: La Figura muestra la arquitectura de la red neuronal a implementar. El valor de *n* y el número de neuronas por cada capa oculta fueron ajustados de acuerdo a las configuraciones detalladas en la Tabla 3.

Para complementar la arquitectura, después de cada capa oculta se incorporaron dos capas adicionales, según se detalla en la Figura 19: *Batch Normalization* y la función de activación ReLU (*Rectified Linear Unit*). La capa de *Batch Normalization* desempeña un papel importante al normalizar todas las salidas de las capas ocultas, logrando una distribución con media 0 y desviación estándar 1. Este proceso se realiza por cada lote que ingresa a la red, y contribuye no solo a una convergencia más rápida, mayor estabilidad y una mejor

generalización del modelo, sino que además proporciona cierto grado de regularización para evitar el sobreajuste. Posteriormente, la capa de activación ReLU complementa todo este proceso al introducir no linealidades a la red, transformando los valores negativos en 0 después de la capa de *Batch Normalization*, lo que, en consecuencia, permite que la red pueda aprender patrones más complejos presentes en los datos y realizar predicciones más precisas.

Figura 19

Arquitectura con Capa de Normalización por Lotes y Función de Activación

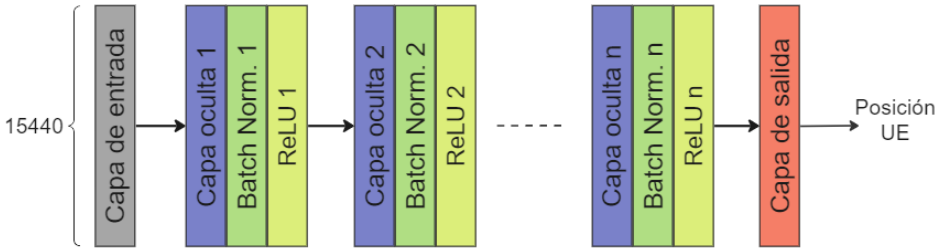

Fase 2: Configuración de la DNN

Dado que este modelo únicamente admite datos linealizados, es importante que el número de neuronas en la capa de entrada de la red sea igual al total de características organizadas a lo largo de cada muestra. En este caso, este valor es:

$$N° \, Neuronas_{InputLayer} = Ns * Np * Ng = 193 * 16 * 5 = 15440 \qquad (7)$$

Además, considerando que en la metodología adoptada se realiza un entrenamiento por cada coordenada, la capa de salida contiene una única neurona. Por otra parte, muchas estructuras de red implementan una disposición de capas donde el número de neuronas disminuye gradualmente a medida que se avanza por la red, mientras que la elección del número de capas ocultas se determina comenzando con una arquitectura simple y aumentando progresivamente su complejidad.

Bajo estas consideraciones, primero se optó por empezar con una configuración de una red neuronal simple (ANN), es decir, únicamente considerando las capas de entrada y salida. Posteriormente, se incrementó gradualmente el número de capas ocultas y se ajustó la cantidad de neuronas, según lo detallado en la Tabla 3.

Tabla 3

Configuraciones de La Red Neuronal

Tipo	N° neuronas capa de entrada	N° capas ocultas	N° neuronas por capa oculta	N° neuronas capa de salida
ANN	15440	0	0	1
DNN 1		1	7720	
DNN 2		2	7720, 3860	
DNN 3	15440	3	7720, 3860, 1930	1
DNN 4		4	7720, 3860, 1930, 965	
DNN 5		5	7720, 3860, 1930, 965, 483	

Nota: Esta tabla muestra la configuración de seis tipos de redes neuronales, donde el número de neuronas disminuye a razón de ½ en comparación con la capa anterior. Todas estas configuraciones serán aplicadas individualmente a cada una de las coordenadas (X, Y, Z).

Es así, que este enfoque busca explorar seis configuraciones distintas, no solo con el propósito de comprender cómo la variación en la disposición de neuronas afecta la capacidad predictiva del modelo, sino también con el objetivo de determinar la configuración más óptima que conduzca a la obtención de los mejores resultados.

Fase 3: Hiperparámetros Iniciales para DNN

Los hiperparámetros iniciales considerados para este modelo son los que se presentan en la Tabla 4, los cuales se aplicaron de manera uniforme a todas las configuraciones de red previamente delineadas. Los resultados de este procedimiento, así como el ajuste de hiperparámetros, se proporcionan en la subsección 'Redes Neuronales Profundas' del Capítulo IV.

Tabla 4

Hiperparámetros Iniciales aplicados a cada configuración DNN

Hiperparámetro	**Descripción**
Épocas = 100	El algoritmo recorrerá 100 veces el conjunto de datos durante el proceso de entrenamiento
Batch Size = 128	Lotes de 128 muestras tomados del conjunto de entrenamiento
Learning Rate = 0.001	Valor por defecto que controla la magnitud de los pesos del modelo

Redes Neuronales Convolucionales (CNN)

Fase 1: Arquitectura de la CNN

La CNN propuesta consta de una serie de filtros convolucionales, o también llamados "*kernels*", que son pequeñas matrices cuyo tamaño debe ser proporcional a las dimensiones de las matrices CFR que van a ingresar a la red. Su funcionamiento consiste en desplazarse a lo largo de las matrices CFR en sentido izquierda-derecha, arriba-abajo, realizando la operación de convolución. Este proceso se repite de acuerdo al número de capas presentes en la arquitectura de la red, como el que se ilustra en la Figura 20.

Figura 20

Arquitectura de CNN para el posicionamiento de dispositivos

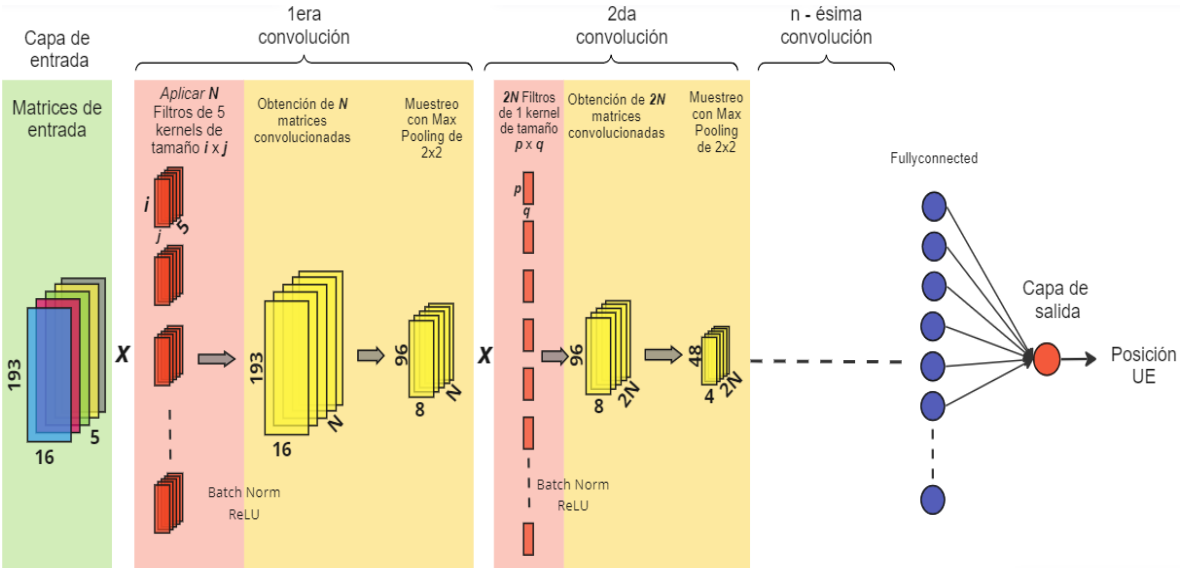

Nota. El esquema presenta la estructura de la CNN a ser implementada, donde el número de matrices de características se incrementa después de cada capa convolucional de acuerdo al número de filtros *kernel* utilizados, mientras que su tamaño se reduce a la mitad por el submuestreo de *Maxpooling*. Finalmente, la red culmina en una capa de *FullyConnected* que se enlaza a la capa de salida para proporcionar la coordenada predicha.

A diferencia de los modelos anteriores que requerían realizar un proceso previo de linealización a los datos, en este caso se omite esa etapa y los datos se introducen directamente en formato de matrices tridimensionales, tal como se observa en la Figura 20. Para comprender este enfoque, resulta intuitivo recordar que habitualmente las CNNs se utilizan en aplicaciones con imágenes, donde cada imagen es bidimensional, pero están organizadas a lo largo de una tercera dimensión para ser ingresadas una por una a la CNN para su entrenamiento. En el enfoque propuesto, se sigue el mismo razonamiento, pero aplicado a matrices de tres dimensiones que están organizadas a lo largo de la cuarta dimensión. Esto quiere decir que, en lugar de ingresar matrices en formato bidimensional,

ingresarán matrices (bloques) en formato tridimensional en el orden en el que están dispuestas a lo largo de la cuarta dimensión.

Ahora bien, siguiendo el mismo ejemplo anterior, si se estuviera trabajando con imágenes en escala de grises, únicamente se tendría un canal, por lo tanto, la convolución se haría aplicando *N* filtros de tamaño *i x j*. Sin embargo, si las imágenes fueran a color, contendrían 3 canales que corresponden a los colores rojo, verde y azul (RGB). Esto quiere decir que para hacer la convolución se tendrían que aplicar *N* filtros, cada uno con 3 *kernels* de tamaño *i x j* (un *kernel* para cada canal). Posteriormente, los resultados de la convolución en los 3 canales se sumarían, generando así una única salida como si se tratase de 1 solo canal.

En el enfoque propuesto, evidentemente no se está trabajando con imágenes, sino con matrices CFR de tamaño *193 x 16 x 5*, lo importante aquí es que la tercera dimensión se interpreta como el número de canales que ingresaría a la capa de entrada de la CNN, lo que quiere decir que para efectuar la convolución se deben aplicar *N* filtros con 5 *kernels* de tamaño *i x j*. Esto trae consigo la ventaja de mantener la correlación del conjunto de las 5 matrices CFR provenientes de cada gNB y, por consiguiente, una mayor probabilidad de reconocer patrones distintivos para cada muestra que ingrese a la red, siendo cada una de ellas asociada a una posición específica del UE en la oficina. A partir de la primera convolución, las subsiguientes se hacen con filtros de un solo *kernel*, ya que la salida de la capa anterior siempre proporciona un único canal.

Fase 2: Configuración de la CNN

De manera similar a la metodología adoptada para la DNN, la implementación de las diferentes CNN también sigue un enfoque progresivo, empezando con una estructura simple y avanzando hacia configuraciones más complejas.

Es así, que se propuso implementar cuatro configuraciones, cada una con su respectivo número de capas convolucionales, de acuerdo a lo presentado en la Tabla 5.

Tabla 5

Configuraciones de la Red Neuronal Convolucional

Tipo	N° Capas convolucionales	Capas convolucionales involucradas	Tamaño matrices de salida	N° neuronas en Capa FullyConnected
CNN 1	1	Capa 1	[96x8x32]	16
CNN 2	2	Capas 1 y 2	[48x4x64]	32
CNN 3	3	Capas 1, 2 y 3	[24x2x128]	64
CNN 4	4	Capas 1, 2, 3 y 4	[12x1x256]	128

Nota: Esta tabla muestra la configuración de cuatro tipos de CNN, las cuales serán aplicadas individualmente a cada una de las coordenadas (X, Y, Z)

Una característica importante de estas configuraciones es que el número de neuronas en la capa *FullyConnected* se estableció como la mitad del total de matrices resultantes de la última capa convolucional. Con este enfoque se encontró el mejor rendimiento de cada configuración.

Por otro lado, cada capa convolucional ha sido configurada, definiendo tanto el número de filtros como sus respectivos tamaños. Estos parámetros específicos se encuentran descritos en la Tabla 6.

Tabla 6

Disposición de Capas Convolucionales

Capa	Matrices de entrada	Configuración	Matrices de salida
Capa 1	[193x16x5]	32 filtros de 5 kernels [7x3] Batchnorm 1 Relu 1 Maxpool 1 de [2x2]	[96x8x32]
Capa 2	[96x8x32]	64 filtros de [3x3] Batchnorm 2 Relu 2 Maxpool 2 de [2x2]	[48x4x64]
Capa 3	[48x4x64]	128 filtros de [5x3] Batchnorm 3 Relu 3 Maxpool 3 de [2x2]	[24x2x128]
Capa 4	[24x2x128]	256 filtros de [3x3] Batchnorm 4 Relu 4 Maxpool 4 de [2x2]	[12x1x256]

Nota. Esta tabla proporciona una descripción detallada de la configuración de cada capa convolucional, incluyendo las dimensiones de las matrices que ingresan a cada capa, la cantidad de filtros convolucionales junto con sus tamaños respectivos, la presencia de capas de *Batch Normalization* y ReLU, así como la operación de *Maxpooling*.

Para los filtros convolucionales, diversas arquitecturas generalmente implementan redes, donde el número de filtros se va duplicando en cada capa para permitir que la red aprenda y

represente una variedad más amplia y compleja de características a medida que se avanza por la red. En este caso, se consideró empezar con 32 filtros en la primera capa, alcanzando así un total de 256 en la última. Cabe aclarar que únicamente se consideró un límite de 4 capas, debido a que las matrices resultantes a la salida de la misma tienen dimensiones de *12x1*, lo que implica que ya no es posible reducir más su tamaño.

Además, considerando que la estructura de los datos es rectangular con dimensiones de *193x16* (con una mayor extensión en la primera dimensión), se optó por emplear el primer filtro convolucional (Capa 1) con dimensiones de *7x3*, proporcional al tamaño de las matrices de entrada mencionado. Esta elección se hace no solo por la captura de características con un bajo coste computacional debido a su reducido tamaño, sino que también permite la extracción de patrones y características presentes en ambas dimensiones, con una mayor sensibilidad a las características que se extienden a lo largo de la dimensión de las subportadoras, donde se presenta un amplio margen de variabilidad de los datos.

El mismo razonamiento se sigue para la tercera capa, pero esta vez con un tamaño de 5x3, es decir, más reducido en la primera dimensión, debido a la disminución del tamaño de las matrices obtenidas a la salida de la capa previa de *Maxpooling*.

Una vez que la primera y la tercera capa capturen patrones con un enfoque más amplio en la primera dimensión (subportadoras), la segunda y cuarta capa capturarán detalles y patrones más locales con la misma sensibilidad en ambas direcciones (subportadoras y canales MIMO) debido a su forma cuadrada de 3x3. Esta combinación intercalada de filtros adopta un enfoque más flexible y compacto, permitiendo capturar la mayor cantidad de patrones, tanto globales como locales dentro de las matrices CFR para lograr una estimación efectiva del posicionamiento de dispositivos.

Fase 3: Hiperparámetros Iniciales para CNN

Los hiperparámetros iniciales considerados para este modelo son los que se presentan en la Tabla 7, los cuales se aplicaron de manera uniforme a las cuatro configuraciones de red previamente delineadas. Los resultados de este procedimiento, así como el ajuste de hiperparámetros, se proporcionan en la subsección 'Redes Neuronales Convolucionales' del Capítulo IV.

Tabla 7

Hiperparámetros Iniciales aplicados a cada configuración CNN

Hiperparámetro	**Descripción**
Épocas = 80	El algoritmo recorrerá 80 veces el conjunto de datos durante el proceso de entrenamiento
Batch Size = 128	Lotes de 128 muestras tomados del conjunto de entrenamiento
Learning Rate = 0.001	Valor por defecto que controla la magnitud de los pesos del modelo

Posterior a todo el proceso descrito en este capítulo, esta metodología culmina con la selección y evaluación del rendimiento del modelo que haya arrojado los mejores resultados, haciendo uso de las Segmentaciones Tipo B y Tipo C. Luego, con la finalidad de obtener una métrica global en tres dimensiones, se procede al cálculo de la distancia euclidiana, para finalmente graficar los puntos predichos en el escenario propuesto.

Capítulo IV: Resultados

En este capítulo, se exponen los resultados obtenidos después de la metodología empleada en los cuatro modelos descritos en el Capítulo III, abordando desde sus configuraciones iniciales hasta las mejoras aplicadas a cada uno.

Resultados con Machine Learning

Regresión Lineal (LR)

La Tabla 8 presenta los resultados obtenidos al entrenar las tres coordenadas con el modelo LR. Es notable que en todos los casos los valores de RMSE son bastante elevados, no solo en relación al rango de coordenadas especificado de 54 [m] en X, 12 [m] en Y y 0.5 [m] en Z, sino que, además superan las dimensiones totales de la oficina.

Estas diferencias entre las predicciones del modelo y las coordenadas reales son críticas y son en gran parte atribuidas al hecho de tener una gran cantidad de variables predictoras (15440 en total) en presencia de características no lineales que el modelo no puede manejar eficientemente. Por lo tanto, se descartó la posibilidad de seguir explorando este método.

Tabla 8

Resultados de RMSE Obtenidos con el Modelo LR

Coordenada X	Coordenada Y	Coordenada Z
138.5307 [m]	28.9687 [m]	2.7505 [m]

Árbol de Regresión (RT)

El modelo de RT, con su configuración inicial, demostró valores de RMSE que fueron significativamente menores en relación a los obtenidos con el modelo de LR. Esto refleja la notoria diferencia en la capacidad de captar no linealidades, y, en consecuencia, mejorar la precisión en la predicción. La Tabla 9 muestra los resultados obtenidos por cada coordenada.

Tabla 9

Resultados de RMSE Obtenidos con la Configuración Inicial del Modelo RT

Configuración	Coordenada X	Coordenada Y	Coordenada Z
MinLeafSize = 1 MinParentSize = 10 Prune: No	9.2527 [m]	2.4215 [m]	0.2155 [m]

Aunque estos valores representan un gran avance, todavía no se puede considerar como un sistema de posicionamiento de alta precisión, debido a que los errores representan un alto porcentaje en relación al rango de cada coordenada. Dado esto, se optó por realizar ajustes en la configuración del modelo, de modo que pueda reducirse lo máximo posible el RMSE de cada coordenada. La Figura 21 y la Tabla 10 presentan estos resultados, obtenidos de acuerdo a la variabilidad aplicada al valor de '*MinLeafSize*'.

Figura 21

Valores de RMSE Obtenidos con la Configuración Optimizada del Modelo RT

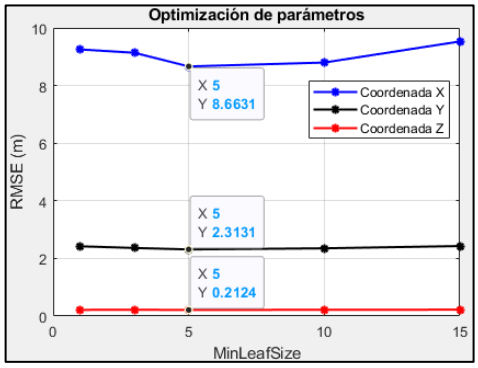

Nota: La gráfica representa la variabilidad del RMSE en función del valor de *MinLeafSize*. La configuración además considera la técnica de poda y un valor de *MinParentSize* de 10.

Como se aprecia, el RMSE en la coordenada X experimenta una disminución a medida que el valor de *MinLeafSize* aumenta, alcanzando su punto mínimo en 5; sin embargo, a partir de este punto, comienza a aumentar nuevamente. Un comportamiento similar se tiene en la

coordenada Y, aunque las variaciones en los valores de RMSE no son tan significativas. Por su parte, en el caso de la coordenada Z, el RMSE prácticamente se mantiene constante a lo largo de los cambios en el valor de *MinLeafSize*.

Todos estos ajustes permitieron establecer a la configuración descrita en la Tabla 10 como la más óptima para las tres coordenadas. Cabe recalcar que el valor de *MinParentSize* se dejó con el valor de 10 dado que no existieron mejoras significativas al momento de variarlo.

Tabla 10

Resultados de RMSE optimizados obtenidos con el Modelo RT

Configuración	Coordenada X	Coordenada Y	Coordenada Z
MinLeafSize = 5 MinParentSize = 10 Prune: Sí	8.6631 [m]	2.3131 [m]	0.2124 [m]

A pesar de los ajustes realizados, y si bien se observaron mejoras con respecto a los resultados iniciales, estas no cumplen con las expectativas esperadas. Por consiguiente, el siguiente paso es explorar los modelos de Deep Learning con el objetivo de mejorar la precisión.

Resultados con Deep Learning

Redes Neuronales Profundas (DNN)

Fase 4: Resultados del Entrenamiento Inicial

Tras aplicar las Fases 1, 2 y 3 del modelo DNN, se procede con la Fase 4, la cual consiste en realizar el entrenamiento para cada coordenada utilizando los optimizadores Adam, RMSProp y SGDm. A continuación, se presentan los resultados obtenidos por cada uno.

Resultados iniciales obtenidos con optimizador Adam

En la Figura 22 se muestra la convergencia de las curvas de entrenamiento logradas mediante el optimizador *Adam* para las seis configuraciones.

Figura 22

Rendimiento de cada Configuración de la DNN con Optimizador Adam

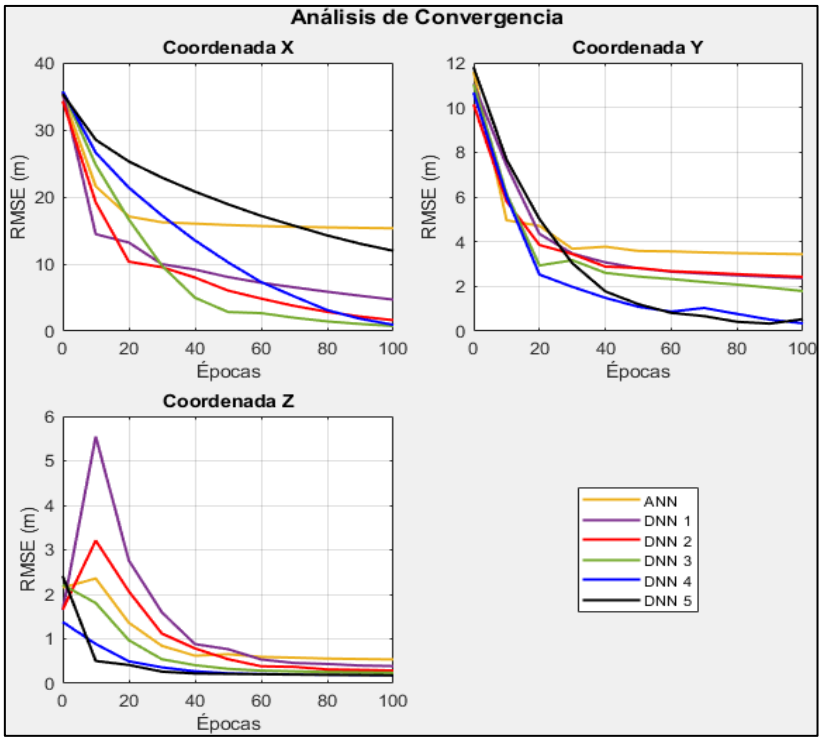

La coordenada X, destaca el mejor desempeño con la configuración DNN 4 (4 capas ocultas), ya que durante las primeras 100 épocas, el RMSE disminuyó de 35 a 2.114 (Ver Figura 23), evidenciando una convergencia con tendencia a reducirse aún más si se aumentase el número de épocas, superando así al resto de configuraciones. Por otro lado, en el caso de la configuración DNN 5, la convergencia es notablemente más lenta, situándose solo por debajo de ANN en el valor de RMSE alcanzado a las 100 épocas. Esto resalta que una mayor cantidad de capas no siempre garantiza un mejor rendimiento.

En el caso de la coordenada Y, se evidencia que la velocidad de convergencia para los casos de DNN4 y DNN5 es muy similar, logrando valores de RMSE cercanos al final de las 100 épocas (Ver Figura 23). Sin embargo, se considera que DNN4 es la configuración más favorable, debido a que, con menor cantidad de capas, no solo logra un buen desempeño, sino que además es menos propenso a que exista sobreentrenamiento.

De manera similar, al analizar la coordenada Z, se observa que las configuraciones DNN4 y DNN5 presentan una velocidad de convergencia similar. Es importante señalar que a lo largo del eje Z, solo se registraron 2 mediciones en la oficina. Esta limitación en el número de medidas influye en que el RMSE alcanzado a las 100 épocas sea notablemente menor en comparación con los obtenidos en las dos coordenadas anteriores. La Figura 23 presenta una síntesis comparativa de los valores de RMSE obtenidos a las 100 épocas para cada una de las configuraciones.

Figura 23

Valores de RMSE obtenidos con cada Configuración de la DNN con Optimizador Adam

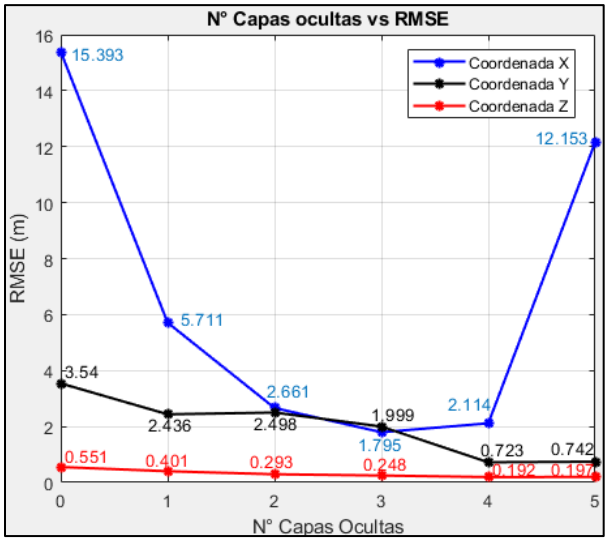

Resultados iniciales obtenidos con optimizador RMSProp

En la Figura 24 se ilustra la convergencia de las curvas de entrenamiento para el optimizador *RMSProp*, donde claramente se observan notorias diferencias en relación a los resultados obtenidos mediante el optimizador *Adam*. Si bien en la coordenada X las curvas muestran una convergencia similar a las logradas con el optimizado *Adam*, el valor de RMSE alcanzado a las 100 épocas es considerablemente mayor (Ver Figura 25). Además, en las coordenadas Y y Z se observa un rendimiento inferior, obteniendo curvas con ciertos niveles de oscilación que difícilmente puedan encontrar mínimos globales que logren una convergencia

adecuada para cada configuración. Dado esto, es necesario realizar un ajuste en la tasa de aprendizaje, lo cual se explica más a detalle en la Fase 5.

Figura 24

Rendimiento de cada Configuración de la DNN con Optimizador RMSProp

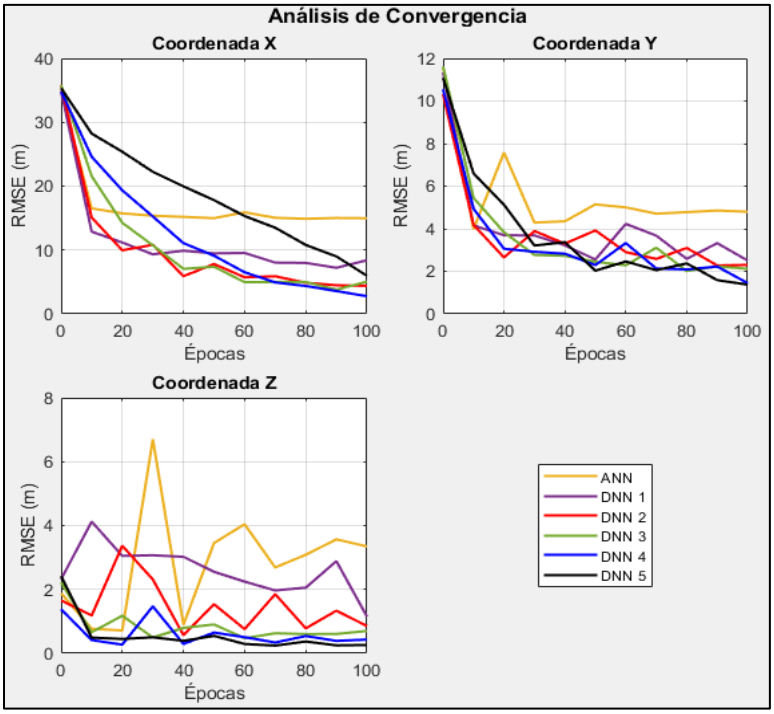

Figura 25

Valores de RMSE obtenidos con cada Configuración de la DNN con Optimizador RMSProp

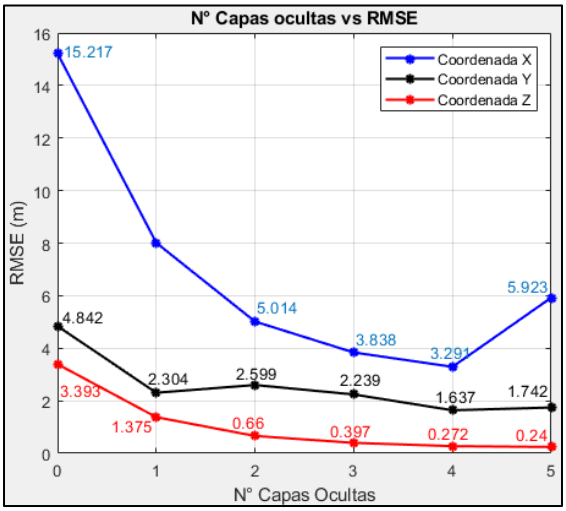

Resultados iniciales obtenidos con optimizador SGDm

Por último, durante la ejecución del entrenamiento utilizando el optimizador *SGDm* se requirió ajustes en uno de los hiperparámetros, haciendo énfasis principalmente en la tasa de aprendizaje. Esto debido a que, en las primeras iteraciones del entrenamiento, el valor de RMSE aumentaba considerablemente a valores extremadamente altos, indicando una divergencia en lugar de una convergencia, lo que condujo a la interrupción de la simulación. La razón de este comportamiento se debe al valor de la tasa de aprendizaje considerado, que, si bien funcionó correctamente para el caso del optimizador *Adam* y demostró un rendimiento regular con el optimizador *RMSProp*, resultó ser un valor alto para este caso, provocando la divergencia mencionada.

Fase 5: Selección de la configuración óptima y del mejor optimizador

Dado que, en los resultados iniciales se observó una tendencia hacia una mejor convergencia de las curvas de entrenamiento con la configuración de 4 capas ocultas (DNN 4), se consideró realizar un ajuste adicional a cada optimizador para esta configuración. En ese sentido, el primer paso consistió en ajustar la tasa de aprendizaje para los modelos con optimizadores RMSProp y SGDm, con el fin de reducir las oscilaciones y evitar la divergencia, respectivamente. A continuación, se presentan los resultados por cada optimizador, incluyendo la curva de validación para verificar la existencia de sobreentrenamiento.

Resultados de la configuración DNN 4 con optimizador Adam

La Figura 26 ilustra que, aunque a partir de las 70 épocas, la curva de validación muestra una leve separación de la curva de entrenamiento para la coordenada X, en la mayoría del trayecto permanecen cercanas, indicando un bajo índice de sobreentrenamiento que puede mitigarse aplicando técnicas de regularización. Por otro lado, en la coordenada Y, se observa que existe un ligero distanciamiento entre ambas curvas a partir de las 30 épocas; sin embargo,

la curva de validación no muestra estabilidad y sigue manteniendo la tendencia decreciente junto con la curva de entrenamiento. Finalmente, la coordenada Z no presenta ningún tipo de sobreajuste, lo que quiere decir que el modelo está aprendiendo correctamente los patrones presentes en los datos de entrenamiento y es capaz de generalizar efectivamente a datos desconocidos.

Figura 26

Curvas de Aprendizaje Obtenidas con DNN 4 y Optimizador Adam

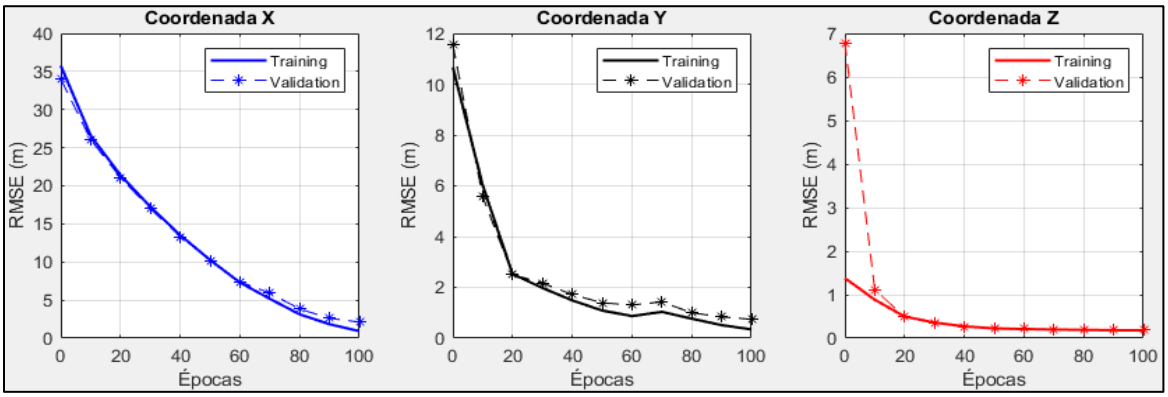

Resultados de la configuración DNN 4 con optimizador RMSProp

En este modelo, se decidió mantener la tasa de aprendizaje inicialmente establecida para la coordenada X en 0.001, ya que la curva de desempeño en esa coordenada no presentó ningún tipo de oscilación. En cuanto a las coordenadas Y y Z, se observó cierto nivel de oscilación en sus curvas de desempeño, por lo que la tasa de aprendizaje para cada una se modificó a un valor de $1x10^{-4}$. Este valor se determinó como el equilibrio óptimo entre lograr una curva sin oscilaciones (lo cual sí se presentaba inicialmente) y minimizar tanto la posibilidad de divergencia como el sobreentrenamiento, aspectos que presentaron aumento al utilizar tasas menores a $1x10^{-5}$. Los resultados después de realizar estos ajustes se presentan en la Figura 27.

Figura 27

Curvas de Aprendizaje Obtenidas con DNN 4 y con Optimizador RMSProp

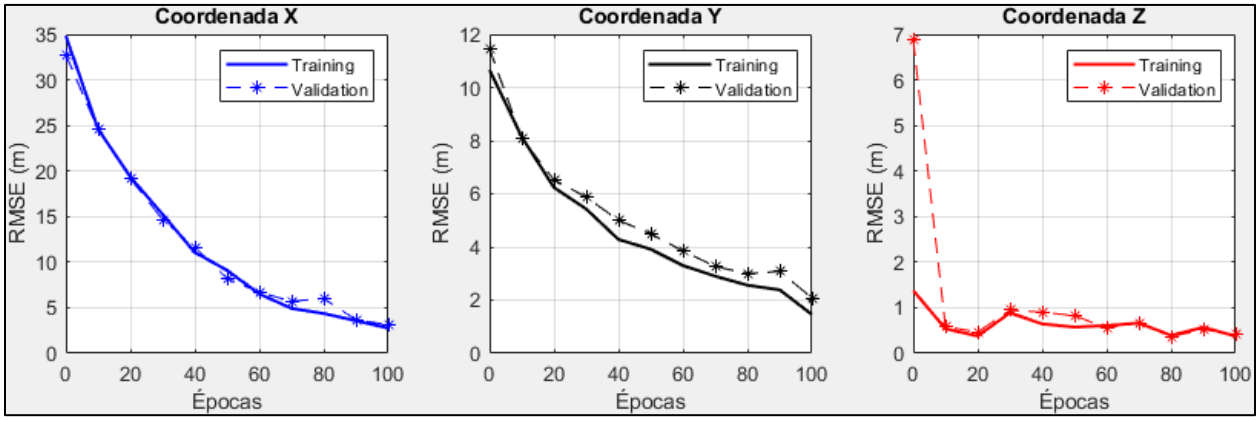

Como se puede observar, aunque la oscilación en la curva de desempeño de la coordenada Y se redujo, el valor de RMSE al final de las 100 épocas sigue siendo superior en comparación con el obtenido utilizando el optimizador *Adam*. De manera similar, en la coordenada Z, a pesar de que la oscilación en la curva de entrenamiento disminuyó, aún persiste, lo que impide que el RMSE descienda aún más y que por lo menos iguale a lo obtenido con *Adam*. Por otro lado, en cuanto a la coordenada X se aprecia que a las 100 épocas prácticamente no existe sobreentrenamiento, lo que indica que el modelo ha logrado generalizar bien a partir de los datos de entrenamiento. Sin embargo, es importante destacar que, a pesar de los ajustes realizados en la tasa de aprendizaje, el rendimiento global del modelo con el optimizador *RMSProp* no iguala al obtenido con el optimizador *Adam*.

Resultados de la configuración DNN 4 con optimizador SGDM

Para este modelo, la tasa de aprendizaje se ajustó al valor de $1x10^{-7}$ a todas las coordenadas. Este fue el valor en el que se encontró un equilibrio para evitar un alto nivel de sobreajuste y que la curva de entrenamiento no diverja, como ocurría inicialmente con el valor de 0.001. Los resultados se presentan en la Figura 28.

Figura 28

Curvas de Aprendizaje Obtenidas con DNN 4 y Optimizador SGDm

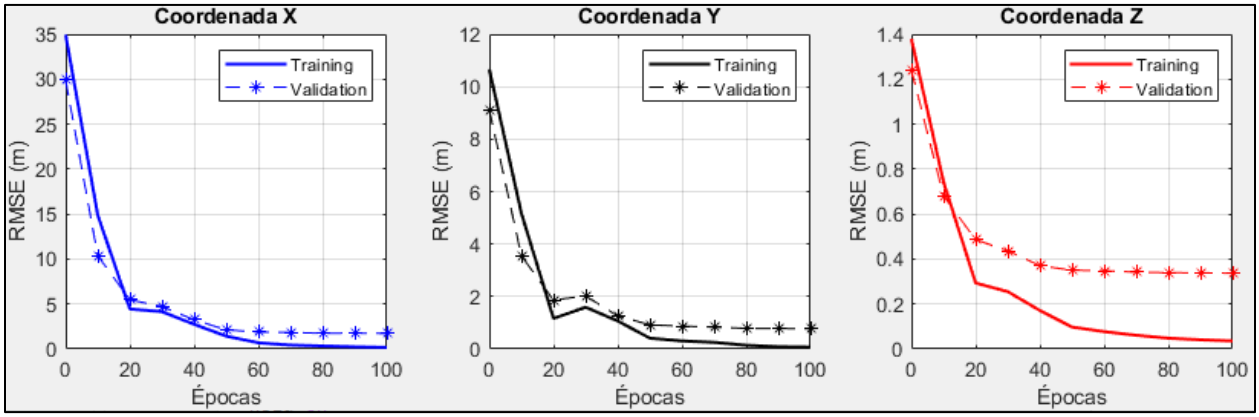

En este modelo se observa que, a pesar de haber ajustado la tasa de aprendizaje para tener los mejores resultados posibles dado el problema de divergencia, es evidente que se presenta cierto índice de sobreajuste para las tres coordenadas, en especial en la coordenada Z. Por otro lado, en las curvas de entrenamiento en las coordenadas X y Y, se observa que a partir de las 80 épocas se tienen valores de RMSE cercanos a 0, sin embargo, las curvas de validación presentan estabilización a partir de las 60 épocas, dejando en claro que no descaerán más, aún si se aumentase el número de épocas. Finalmente, en la Tabla 11 se presentan los resultados de RMSE obtenidos al finalizar las 100 épocas para cada uno de los modelos.

Tabla 11

Resultados de RMSE Obtenidos con Cada Optimizador a las 100 Épocas

Optimizador	Coordenada X	Coordenada Y	Coordenada Z
Adam	2.114 [m]	0.723 [m]	0.192 [m]
RMRProp	3.291 [m]	1.708 [m]	0.368 [m]
SGDm	2.217 [m]	0.774 [m]	0.334 [m]

Basado en los análisis de convergencia realizados y dados los resultados de RMSE presentados en la Tabla 11, se determina que, la red neuronal con 4 capas ocultas utilizando el optimizador *Adam* es la que tiene mejor proyección para mejorar los resultados después de las 100 épocas.

Fase 6: Ajuste Final de Hiperparámetros

Concluido lo anterior, se aplicaron los ajustes de hiperparámetros finales que se muestran en la Tabla 12, donde se puede observar que el número de épocas se aumentó a 150 en las coordenadas X y Y, mientras que en la coordenada Z se mantuvo el mismo valor de 100 debido a que ya no se presentó decaimiento significativo en las curvas, según lo indicado en la Figura 29.

Adicionalmente, debido a la ligera presencia de sobreajuste que se presentó en la Figura 26 para las coordenadas X y Y, se utilizó una capa de Dropout del 35% y 30%, respectivamente para desactivar aleatoriamente esos porcentajes del total de neuronas para mitigar el sobreajuste. Por último, el valor de Batch Size se dejó con el mismo valor, no solo porque no se presentaron diferencias al momento de variarlo a 32 o 64, sino que además el tiempo de entrenamiento es relativamente menor en relación a las dos opciones mencionadas (32 o 64). Así, los resultados finales se presentan en la Tabla 12 y la convergencia de las curvas en la Figura 29

Figura 29

Curvas de Aprendizaje Obtenidas con la Configuración Optimizada del Modelo DNN

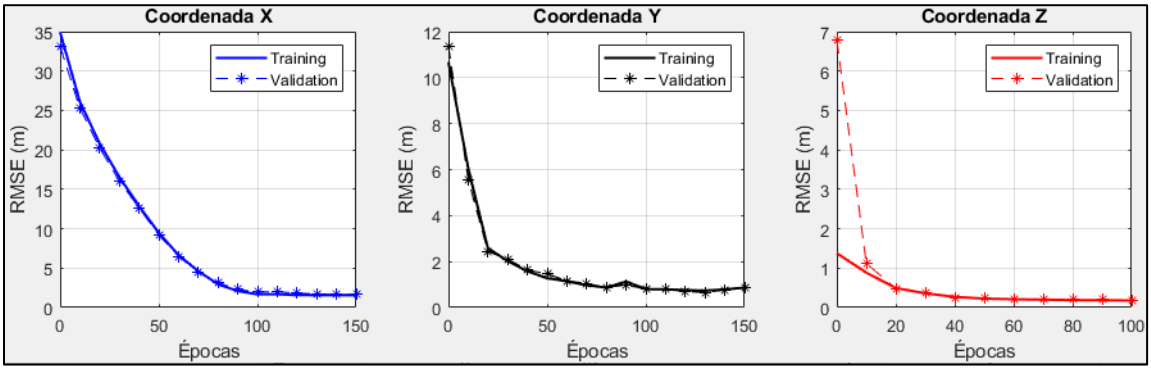

Tabla 12

Resultados de RMSE Obtenidos con la Configuración Optimizada del Modelo DNN

Parámetro	Coordenada X	Coordenada Y	Coordenada Z
Tipo Segmentación	A	A	A
Normalización	Z-Score	Z-Score	Z-Score
Configuración	DNN 4	DNN 4	DNN 4
Optimizador	Adam	Adam	Adam
Épocas	150	150	100
Tasa de Aprendizaje	0.001	0.001	0.001
Batch Size	128	128	128
Regularización	Dropout 35%	Dropout 30%	-
RMSE [m]	1.6696	0.6496	0.1926

Aunque el RMSE en la coordenada Z es satisfactorio y en la coordenada X ha disminuido de 2.114 a 1.6696, sigue siendo un valor relativamente alto debido a la separación de 0.5 [m] que existía entre cada medida a lo largo de este eje. Lo mismo ocurre para el caso de la coordenada Y. La idea es obtener un valor de RMSE menor o igual a ese intervalo de 0.5 [m]. Por lo tanto, se optó por explorar el rendimiento de las CNN para mejorar estos resultados.

Redes Neuronales Convolucionales (CNN)

Fase 4: Resultados del Entrenamiento Inicial

Para este modelo, primeramente, se realizó el entrenamiento de cada coordenada, utilizando el optimizador *Adam* con las cuatro configuraciones descritas en la Fase 2. El resultado de este proceso se muestra en el comportamiento de las curvas de entrenamiento de la Figura 30.

Figura 30

Rendimiento de cada Configuración de la CNN con Optimizador Adam

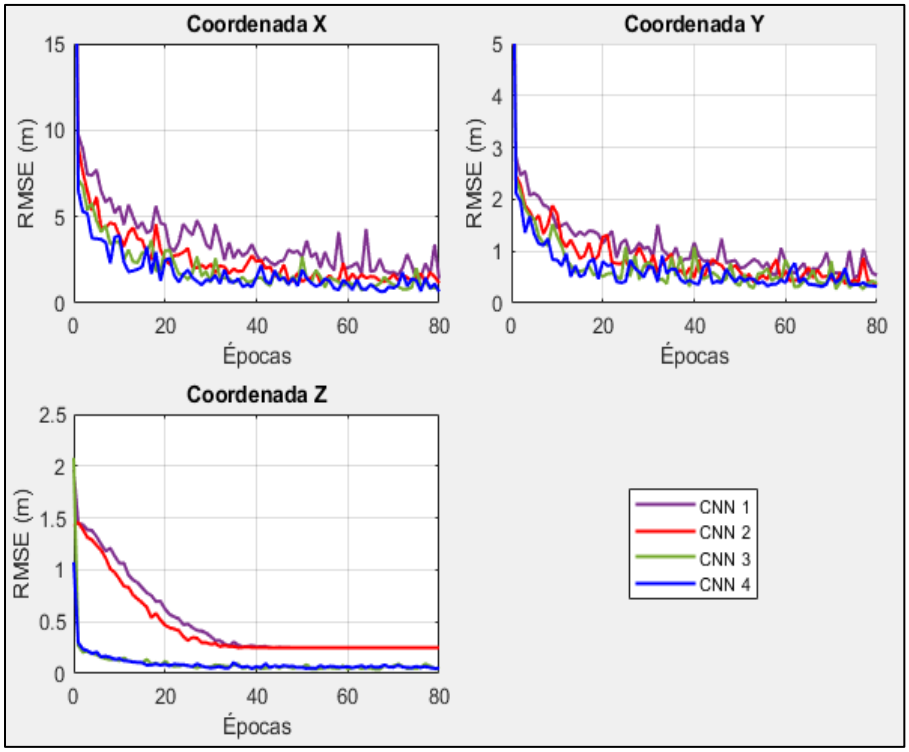

Es evidente que, en todas las coordenadas, la configuración que proyecta los mejores resultados es la CNN 4, no solo por la rápida convergencia que logra en relación al resto de configuraciones, sino que además alcanza un RMSE mínimo a las 80 épocas (Ver Figura 31) con tendencia a seguir disminuyendo. Cabe destacar que, si bien en la coordenada Z se presenta un comportamiento similar entre CNN 3 y CNN 4, las curvas ya no presentan indicio de decaer más, ya que logran una estabilización aproximadamente a las 40 épocas. Esto, a priori, permite disminuir el número de épocas para esta coordenada, de modo que al realizar las optimizaciones con el ajuste de hiperparámetros se obtenga un tiempo menor de ejecución en su entrenamiento.

Figura 31

Valores de RMSE Obtenidos con Cada Configuración de la DNN con Optimizador Adam

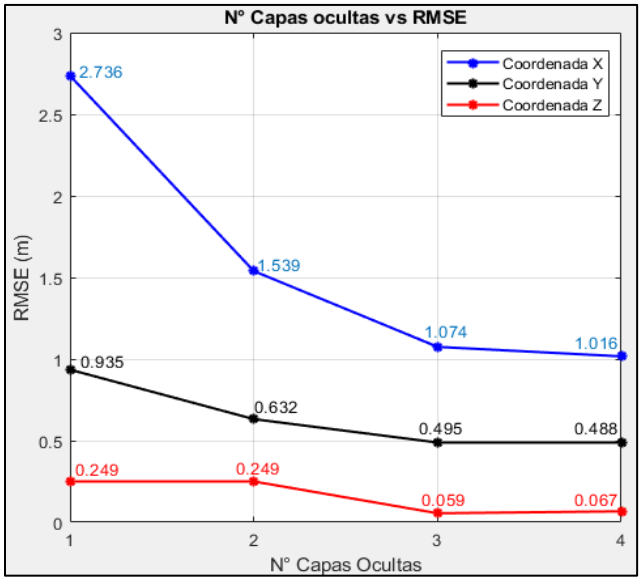

Fase 5: Selección de la Configuración Óptima y del Mejor Optimizador

Dado que la configuración CNN 4 presenta mejor tendencia a obtener mejores resultados, se realizó el entrenamiento con dicha configuración haciendo uso de los dos optimizadores restantes que son RMSProp y SGDm. Todo esto con el fin de determinar la mejor opción para presentar los resultados finales. En la Figuras 32, 33 y 34 se presenta el rendimiento de las curvas de entrenamiento y de validación para cada optimizador, mientras que en la Tabla 13 se proporcionan los resultados de RMSE al finalizar las 80 épocas.

Figura 32

Curvas de Aprendizaje obtenidas con CNN 4 y optimizador Adam

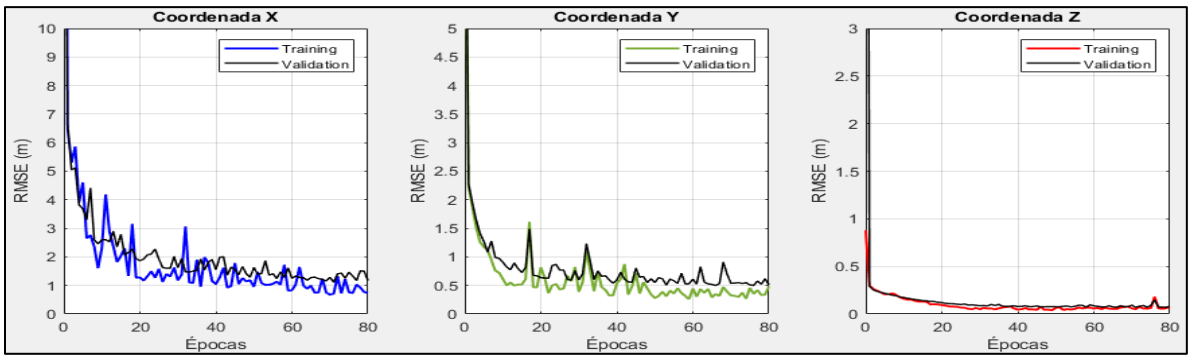

Figura 33

Curvas de Aprendizaje obtenidas con CNN 4 y optimizador RMSProp

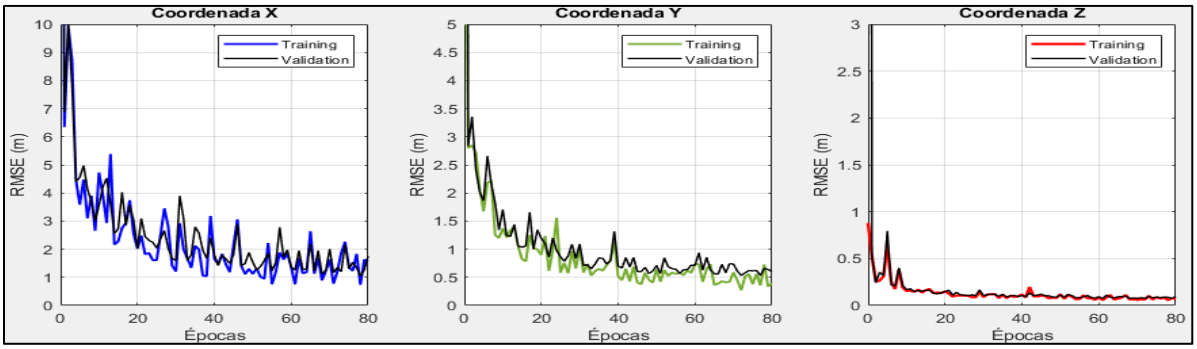

Figura 34

Curvas de Aprendizaje obtenidas con CNN 4 y Optimizador SGDm

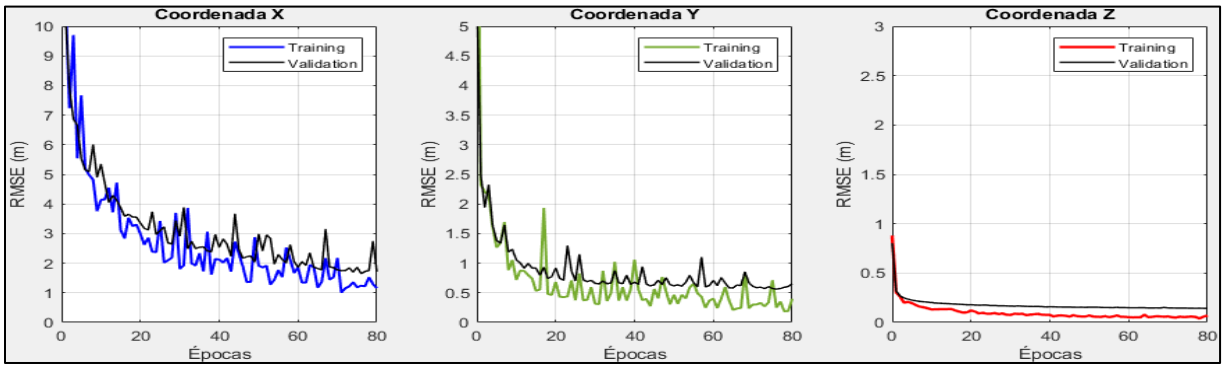

Tabla 13

Resultados de RMSE Obtenidos con Cada Optimizador a las 80 Épocas

Optimizador	Coordenada X	Coordenada Y	Coordenada Z
Adam	1.0164 [m]	0.4882 [m]	0.0669 [m]
RMRProp	0.8369 [m]	0.4702 [m]	0.0713 [m]
SGDm	1.3735 [m]	0.5338 [m]	0.1389 [m]

Como se puede observar, las curvas obtenidas con el optimizador *Adam* presentan cierto nivel de sobreajuste en las coordenadas X y Y, dando como resultado valores de RMSE de 1.0164 y 0.4882, respectivamente. Este fenómeno no ocurre para la red que utiliza el

optimizador *RMSProp* en ninguna de las tres coordenadas, ya que las curvas de validación y de entrenamiento se mantienen juntas en todo el proceso, obteniendo de esta manera un decremento en el valor de RMSE, específicamente en la coordenada X con un valor de 0.8369. Por otro lado, se observa que con el optimizador *SGDm* existe sobreentrenamiento en las tres coordenadas, produciendo valores de RMSE más altos en relación a los otros dos optimizadores.

De esta manera se determina que, la configuración CNN 4 con el optimizador *RMSProp* conforman la red más óptima para este modelo.

Fase 6: Ajuste Final de Hiperparámetros

En los ajustes empleados, primeramente, se consideró realizar un aumento del número de épocas de 80 a 100 en la coordenada X, ya que hasta este valor se presentó todavía decaimiento en las curvas de entrenamiento y validación, según lo indicado en la Figura 35. Adicional a ello, se colocó un *Batch Size* de 32, es decir, se tomó un conjunto de datos más pequeño, pero en mayor número. Esto hizo que se reduzca aún más el RMSE, atribuido al hecho de que la actualización de los pesos se hace más frecuentemente, ayudando así a mejorar la convergencia del modelo. Finalmente, dado que en las curvas obtenidas en la Figura 33 presentaron cierto nivel de oscilación, se configuró una tasa de aprendizaje adaptativa con un decaimiento del 30% de la tasa inicial de 0.001, ajustada cada 40 épocas. Esto no solo permitió solventar el problema de oscilación, sino que, en conjunto con la configuración del resto de hiperparámetros mencionados, contribuyó a lograr una mejor convergencia y reducir el RMSE en un 55.44%, pasando de 0.8369, sin la implementación de ajustes de hiperparámetros, a 0.3729 con el ajuste realizado. Esto se detalla en la Tabla 14.

Figura 35

Curvas de Aprendizaje Obtenidas con la Configuración Optimizada del Modelo CNN

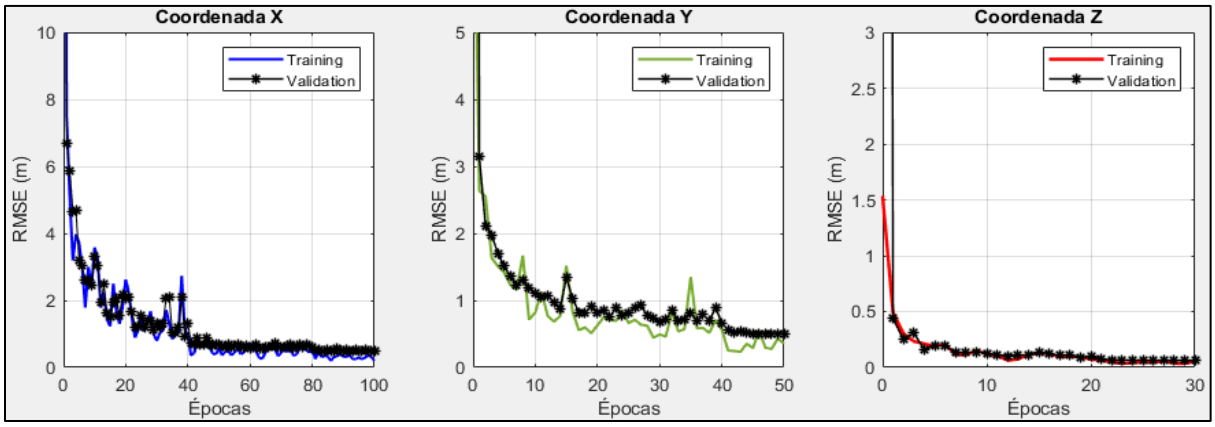

Los mismos ajustes se aplicaron inicialmente a la coordenada Y. Sin embargo, a partir de las 40 épocas ya no se presentaron indicios de decaimiento en las curvas de entrenamiento y validación. En ese sentido, se disminuyó el número de épocas al valor de 50 y se ajustó una tasa de aprendizaje adaptativa a las 40 épocas con una reducción al 2% del valor inicial, logrando así un óptimo valor de RMSE con menos iteraciones en relación al caso de la coordenada X.

Finalmente, para la coordenada Z, dado que las curvas de la Figura 33 presentaron una estabilidad mucho más rápida en relación al resto de coordenadas, se establecieron 30 épocas para ejecutar el entrenamiento, un *Batch Size* también de 32 y una tasa de aprendizaje adaptativa del 30% a las 20 épocas. Cabe aclarar que a comparación de DNN, en este caso no fue necesario aplicar técnicas de regularización a ninguna de las tres coordenadas debido a la inexistencia de sobreajuste. Con todas estas consideraciones, se obtuvieron los resultados que se presentan en la Tabla 14.

Tabla 14

Resultados de RMSE Obtenidos con la Configuración Optimizada del Modelo CNN

Parámetro	Coordenada X	Coordenada Y	Coordenada Z
Tipo Segmentación	A	A	A
Normalización	Z-Score	Z-Score	Z-Score
Configuración	CNN 4	CNN 4	CNN 4
Optimizador	RMSProp	RMSProp	RMSProp
Épocas	100	50	30
Tasa de Aprendizaje inicial	0.001	0.001	0.001
Factor de caída de la tasa	0.3 @40 épocas	0.02 @ 40 épocas	0.1 @ 20 épocas
Batch Size	32	32	32
Regularización	-	-	-
RMSE [m]	0.3729	0.3851	0.0378

Al notar que los valores de RMSE son notablemente bajos en relación al rango total de las dimensiones de la oficina, con un error medio de apenas 0.3729 [m] con respecto a los 54 [m] totales de extensión en la coordenada X, 0.3851 [m] en relación a los 12 [m] de extensión en la coordenada Y, y 0.0378 [m] en relación a los 0.5 [m] de extensión en la coordenada Z; se concluye que el modelo de CNN es el mejor dentro de todos los considerados en este estudio.

Comparación de resultados

La Tabla 15 resume los resultados finales obtenidos en cada modelo, revelando notables diferencias en su respectivo rendimiento y una mejora progresiva en el error de predicción.

Tabla 15

Cuadro Comparativo Final de los Resultados Obtenidos en Todos los Modelos

Modelo	RMSE [m] en X	RMSE [m] en Y	RMSE [m] en Z
LR	138.5307	28.9687	2.7505
RT	8.6631	2.3131	0.2124
DNN	1.6696	0.6496	0.1926
CNN	0.3729	0.3851	0.0378

Los resultados del sistema de posicionamiento reflejan un gran contraste en la capacidad predictiva entre los cuatro modelos evaluados. Mientras que la regresión lineal, siendo el modelo más simple utilizado como punto de partida, mostró un desempeño significativamente inferior con valores de RMSE de 138.5307 [m] para la coordenada X, 28.9687 [m] para la coordenada Y y 2.7505 [m] para la coordenada Z; el árbol de regresión presentó una mejora sustancial en la precisión con valores de RMSE de 8.6631 [m], 2.3131 [m] y 0.2124 [m] para las mismas coordenadas, respectivamente.

Sin embargo, la red neuronal profunda (DNN) y la red neuronal convolucional (CNN) demostraron un rendimiento aún más destacado, con valores de RMSE significativamente más bajos en todas las coordenadas, siendo los más precisos los obtenidos por la CNN con 0.3729 [m] para la coordenada X, 0.3851 [m] para la coordenada Y y 0.0378 [m] para la coordenada Z. Estos resultados respaldan la superioridad de los enfoques de aprendizaje profundo en la obtención de una alta precisión en el sistema de posicionamiento propuesto.

Análisis de resultados con segmentación de datos Tipo B y C

En la metodología propuesta se detalló que, tras implementar la segmentación Tipo A en todos los modelos e identificar al mejor, se realizaría una evaluación más profunda de su rendimiento enfrentándolo a condiciones diversas de SNR, lo cual se lograría mediante la implementación de las segmentaciones Tipo B y C.

En consecuencia, considerando que el modelo de CNN demostró ser el más preciso en relación a LR, RT y DNN; se procedió a realizar los entrenamientos correspondientes con las segmentaciones Tipo B y Tipo C. Estos entrenamientos se llevaron a cabo bajo los mismos ajustes detallados en la Tabla 15, que se emplearon para la segmentación Tipo A. En las Figuras 36 y 37 se muestran los comportamientos del modelo respectivos.

Figura 36

Curvas de Aprendizaje Obtenidas con Segmentación Tipo B

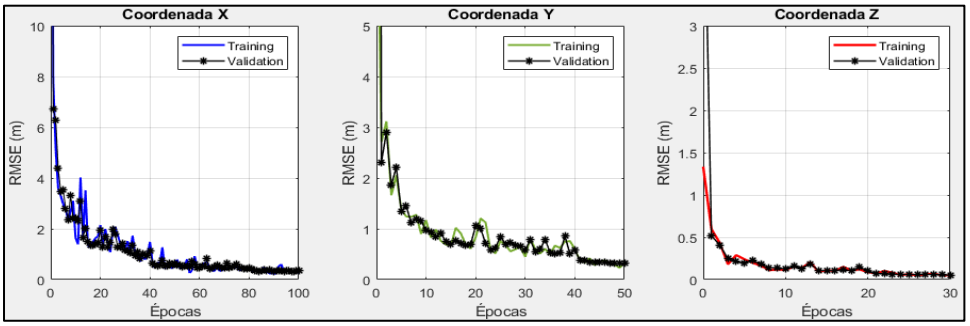

Figura 37

Curvas de Aprendizaje Obtenidas con Segmentación Tipo C

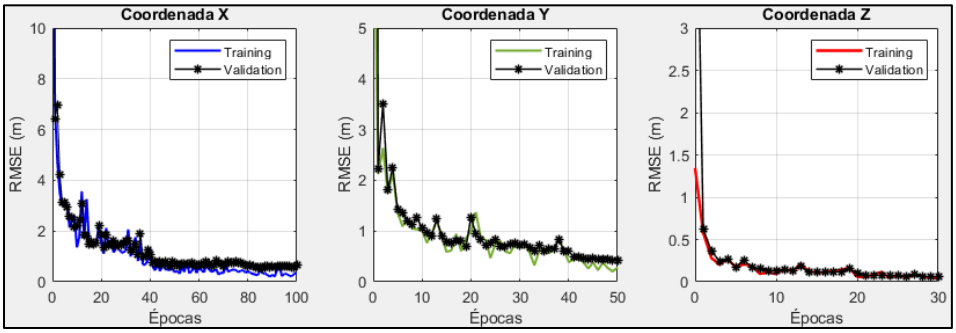

La Figura 36 indica que, con la Segmentación Tipo B, las curvas de entrenamiento y validación permanecen constantemente juntas en las tres coordenadas. Esto destaca una efectiva generalización del modelo, indicando que el sistema es capaz de realizar predicciones de gran precisión cuando se enfrenta a niveles de SNR que se encuentren dentro del rango de entrenamiento establecido.

Los valores mínimos de RMSE obtenidos refuerzan esta observación, alcanzando tan solo 0.1674 [m] en la coordenada X, 0.1919 [m] en la coordenada Y, y 0.0442 en la coordenada Z. Estos resultados se lograron al evaluar el sistema con un SNR de 20 dB, situado dentro del rango de entrenamiento que se estableció en 10 y 50 dB, como se detalla en la Tabla 16.

Esta tendencia cambia ligeramente en el caso de la Segmentación Tipo C (Figura 37), ya que en las coordenadas X y Y se presenta un leve sobreajuste, dando como resultado un sistema menos preciso. Esto es comprensible, ya que el nivel de SNR de 10 dB es inferior al rango considerado para el entrenamiento, establecido en 20 dB y 50 dB. La Tabla 16 proporciona resumidamente los valores de RMSE obtenidos para los tres tipos de segmentación.

Tabla 16

Resultados de RMSE Obtenidos por Cada Tipo de Segmentación de Datos

Segmentación de datos	**Datos de entrenamiento**	**Datos de validación**	**RMSE [m] en X**	**RMSE [m] en Y**	**RMSE [m] en Z**
Tipo A	50, 20 y 10 dB	50, 20 y 10 dB	0.3729	0.3851	0.0378
Tipo B	50 y 10 dB	20 dB	0.1674	0.1919	0.0442
Tipo C	50 y 20 dB	10 dB	0.4317	0.4615	0.0614

Cálculo de la Distancia Euclidiana

Aunque los resultados de RMSE para cada coordenada, resaltan la alta precisión lograda de las predicciones individuales, se reconoce la necesidad de una métrica global que permita evaluar la magnitud de la distancia real en las tres dimensiones. Esto se puede lograr empleando el cálculo del promedio de la distancia euclidiana para cada posición, de acuerdo a la ecuación (8).

$$D_{euclidiana\,prom} = \frac{\sum_{i=1}^{N}\sqrt{\left(P_x(i)-\widehat{P_x}(i)\right)^2+\left(P_y(i)-\widehat{P_y}(i)\right)^2+\left(P_z(i)-\widehat{P_z}(i)\right)^2}}{N} \quad (8)$$

Esta ecuación considera las coordenadas predichas en comparación con sus respectivas coordenadas reales. Donde $P_x(i)$ es la coordenada X real y $\widehat{P_x}(i)$ denota la coordenada X predicha, $P_y(i)$ indica la coordenada Y real y $\widehat{P_y}(i)$ es la coordenada Y predicha, $P_z(i)$ corresponde a la coordenada Z real y $\widehat{P_z}(i)$ es la coordenada Z predicha, mientras que N representa el número total de posiciones tomadas del conjunto de validación.

Tras efectuar este cálculo para los tres tipos de segmentación, se obtuvieron los valores promedio de la distancia euclidiana presentados en la Tabla 17.

Tabla 17

Distancias Euclidianas Obtenidas por Cada Tipo de Segmentación de Datos

Segmentación de datos	Distancia Euclidiana [m]
Tipo A	0.3971
Tipo B	0.2282
Tipo C	0.5341

Estos resultados revelan una consistencia con las tendencias observadas en los valores de RMSE de la Tabla 15. Es así, que el valor más bajo se obtuvo con la segmentación Tipo B, registrando tan solo 22.82 cm. Le sigue la segmentación Tipo A con 39.71 cm, mientras que la segmentación Tipo C presenta la distancia euclidiana más alta, con un valor de 53.41 cm.

Visualización de Puntos Predichos en el Escenario

La visualización directa en el escenario permite representar de manera tangible las métricas de desempeño previamente obtenidas. Para lograr esto, se tomó una muestra aleatoria con 15 coordenadas para representar gráficamente los puntos reales y los puntos

predichos dentro del escenario de la oficina. Las Figuras 38 y 39 ilustran esta visualización en 3D y en los planos X-Y y X-Z, respectivamente, teniendo en cuenta la segmentación Tipo A.

Figura 38

Visualización en 3D de Puntos Predichos con Segmentación Tipo A

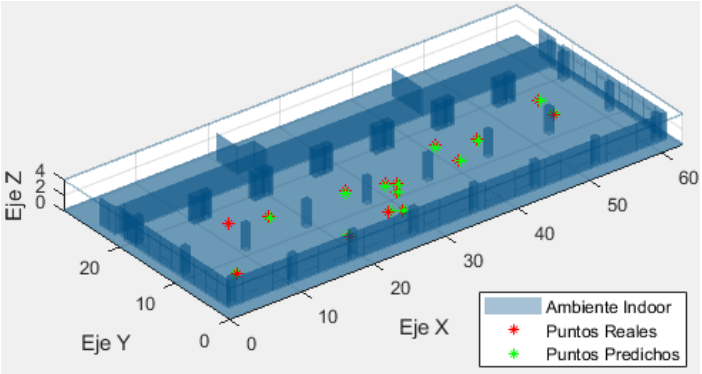

Figura 39

Visualización de Puntos Predichos en los Planos X-Y y X-Z con Segmentación Tipo A

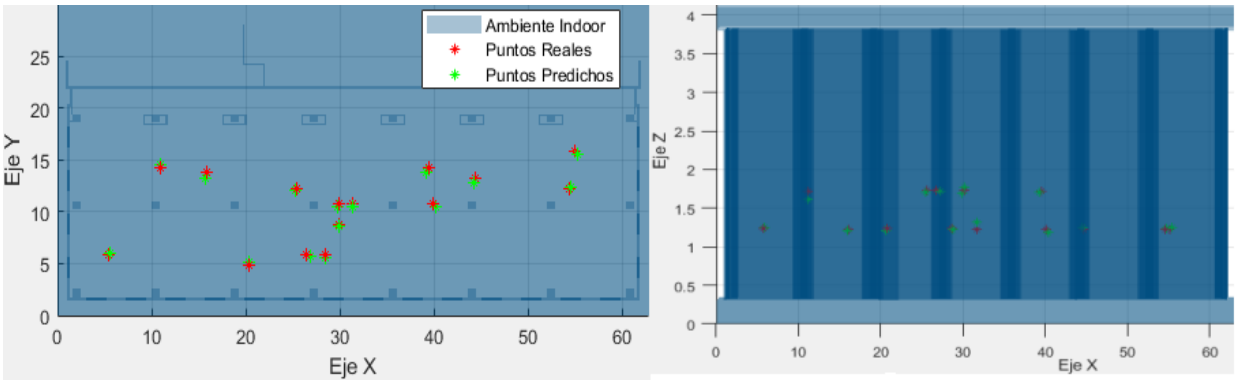

Al observar las Figuras 38 y 39, se aprecia una variabilidad en la distancia entre algunos pares de puntos (predichos y reales), evidenciando que ciertos pares presentan una discrepancia mayor que otros. Estas observaciones concuerdan con las métricas de desempeño analizadas, las cuales proporcionan valores promedio y sugieren la existencia de cierta variabilidad alrededor de dichos valores. A pesar de esto, la proximidad general entre los puntos predichos y reales es altamente satisfactoria, tanto en el plano X-Y, como en el plano X-Z. Esto remarca la eficiencia del modelo de CNN diseñado para proporcionar un sistema de posicionamiento de alta precisión.

Figura 40

Visualización de Puntos Predichos en los Planos X-Y y X-Z con Segmentación Tipo B

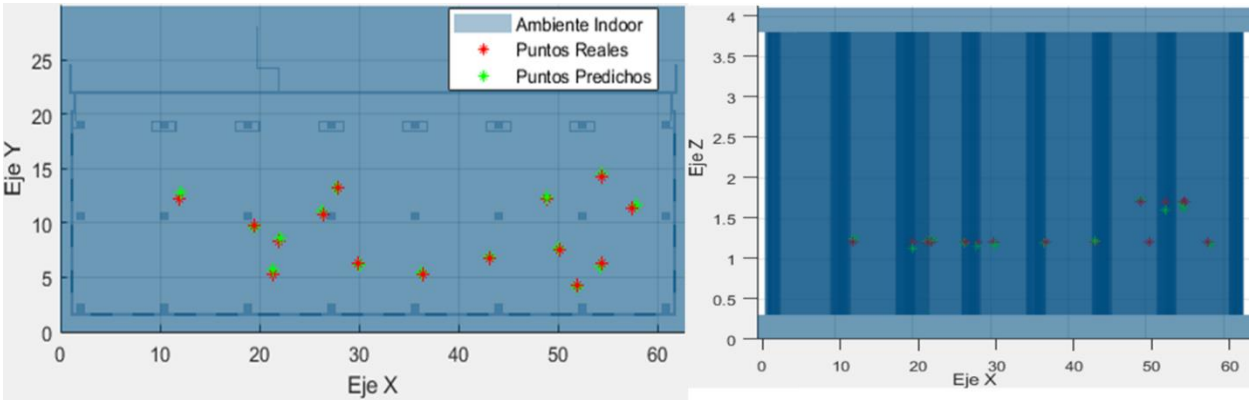

Figura 41

Visualización de Puntos Predichos en los Planos X-Y y X-Z con Segmentación Tipo C

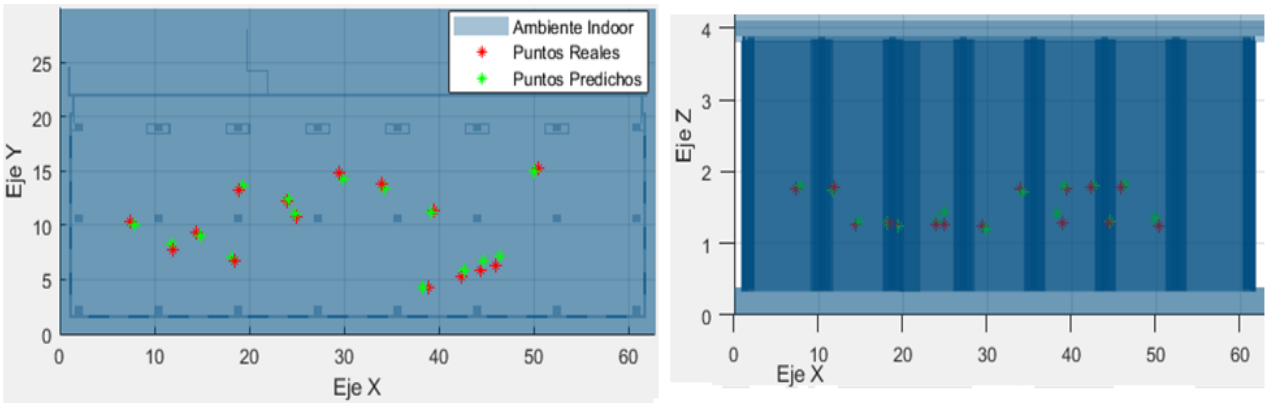

Finalmente, en las Figuras 40 y 41, correspondientes a la Segmentación Tipo B y Tipo C, respectivamente, se confirma que con la Segmentación Tipo B se obtiene la mejor precisión en la predicción de los puntos, ya que la mayoría prácticamente están sobrepuestos a los puntos reales. En el contexto de este análisis, se clasifica al sistema con esta segmentación como el "escenario óptimo", dado que el canal presenta niveles de Relación Señal-Ruido (SNR) dentro del rango considerado durante el entrenamiento de la red.

Por otro lado, cuando la SNR del canal es inferior a las establecidas en el conjunto de entrenamiento (sistema con segmentación Tipo C), se observa una diferencia mayor en el

distanciamiento entre puntos reales y predichos. Esta disminución de precisión, como se mencionó con anterioridad, es comprensible debido a la distorsión en la información contenida en las matrices CFR, provocada por niveles de ruido más elevados. A pesar de esto, la capacidad predictiva del modelo mantiene un nivel aceptable, lo que justifica la clasificación de este sistema como el "escenario menos favorable" en el contexto de este análisis.

En cualquier caso, con la segmentación Tipo A se tiene una estimación de predicción más acertada a la realidad, ya que además de tomar todos los niveles de SNR para entrenar a la red, se tienen datos con diferentes niveles de SNR para el conjunto de validación, lo que permite simular un escenario que representa a un canal inalámbrico cambiante. Por esta razón, el valor de distancia euclidiana promedio de 39.71 [cm] se adopta como la métrica alcanzada en este trabajo.

Es así, que este análisis no solo corrobora la pequeña magnitud de los valores de RMSE y distancias euclidianas en relación a las dimensiones del escenario, sino que también destaca la robustez y alta precisión del sistema de posicionamiento ante diversos niveles de ruido, gracias a la CNN con 4 capas convolucionales.

Capítulo V: Conclusiones y Trabajos Futuros

En este capítulo se presentan las conclusiones derivadas de los resultados obtenidos y se sugieren mejoras para futuras investigaciones que contribuyan a implementar sistemas de este tipo en aplicaciones de posicionamiento y localización.

Conclusiones

Se ha logrado desarrollar un sistema predictor de posicionamiento de dispositivos con una precisión, medida en términos de la distancia euclidiana promedio, de 39.71 [cm], en el entorno tridimensional de una oficina con dimensiones de 60.5 x 20 x 2.4 [m]. Esto permite destacarlo como un sistema de alta precisión debido a su baja representatividad en relación al rango total del escenario.

Tras la evaluación cuantitativa realizada con los cuatro modelos propuestos, se concluye que los algoritmos de ML tradicional no son los más viables a ser utilizados en este sistema de posicionamiento, debido a los elevados valores de RMSE que se obtuvieron en las tres coordenadas evaluadas. Esto se atribuye en gran parte a su capacidad limitada para modelar y reconocer no linealidades en los datos, aspectos que los algoritmos de DL logran de manera más eficaz. Es así, que estos últimos, aún en su forma más básica en términos de configuraciones e hiperparámetros, superaron el desempeño de los modelos de ML.

En la etapa de entrenamiento inicial, el modelo LR proporcionó valores de RMSE de 138.53 [m] en X, 28.9687 [m] en Y y 2.7505 en Z. Esto determinó el descarte instantáneo de este modelo como opción viable, debido a sus altos errores en las predicciones. Tras esto, se empleó el modelo RT, que, aunque experimentó una reducción significativa del error, del 93.74% en la coordenada X, 92.05% en la coordenada Y y 92.27% en la coordenada Z; aún presentó valores que representaban aproximadamente una cuarta parte del rango total, justificando la necesidad de adoptar algoritmos de DL.

La metodología estructurada en fases aplicada a los modelos de DL, contribuyó significativamente para determinar las mejores configuraciones y ajustes tanto para DNN como para CNN. Este proceso condujo a la mejor precisión en la predicción de coordenadas, lograda con la elección de la configuración con 4 capas ocultas para DNN y 4 capas convolucionales para CNN, siendo este último el modelo con el que se lograron valores de 0.3729 [m] en X, 0.3851 [m] en Y y 0.0378 [m] en Z, superando a todos los considerados en este estudio.

La elección del optimizador y los valores de los hiperparámetros, resultó ser específica para cada modelo. Si bien en DNN se presentaron los mejores resultados con el optimizador *Adam*, en CNN esto cambió, ya que los mejores resultados se obtuvieron con el optimizador *RMSProp.* Asimismo, los valores de la tasa de aprendizaje jugaron un papel diferente para cada modelo; en CNN se utilizó una tasa adaptativa debido a la disminución que presentaban las curvas de aprendizaje, mientras que una estrategia similar en DNN resultó en una convergencia más lenta. En definitiva, todo esto destaca que no hay una receta específica para aplicar a cada modelo, por lo que el proceso iterativo llevado a cabo mediante la metodología propuesta, resalta la importancia de este estudio.

En los modelos DNN y CNN, cada coordenada conllevó un ajuste diferente de hiperparámetros. Esto se atribuye a las diferencias en los rangos presentes en cada una, por lo que generalizar estrictamente un ajuste para todas no es lo más óptimo. Esta adaptación no solo permitió optimizar el rendimiento de cada modelo según las características de cada coordenada, sino que también permitió obtener los mejores resultados de RMSE sin un consumo innecesario de recursos.

El proceso de linealización planteado para los modelos de LR, RT, ANN y DNN fue fundamental para su implementación y posterior entrenamiento. Sin embargo, luego de aplicar dicho procedimiento a la información presente en la estructura original de cuatro dimensiones de las matrices CFR, se obtuvo una cantidad de 15440 variables predictoras. Esto resultó en

una desventaja significativa en los modelos de ML, ya que difícilmente lograron modelar una relación lineal entre tantas variables predictoras y las coordenadas reales contenidas en las etiquetas. Asimismo, este proceso implicó la pérdida de correlación de los datos originales de las matrices CFR, lo que justifica una de las razones por la que los valores de RMSE finales alcanzados con CNN superan a DNN en un 77.66% para la coordenada X, en un 40.91% para la coordenada Y y en un 80.33% para la coordenada Z.

Tras realizar la evaluación con segmentaciones Tipo B y Tipo C al modelo CNN, se demostró que el sistema funciona mejor con niveles de SNR intermedios al rango de entrenamiento, dado que se obtuvo una distancia euclidiana de 22.81 [cm]. Por otro lado, la variabilidad en los niveles de SNR, especialmente cuando estos son inferiores al rango de entrenamiento, introduce desafíos adicionales debido a la mayor presencia de ruido. Si bien esto afecta negativamente la capacidad predictiva del modelo, no es muy crítico, ya que aún se mantiene un nivel de precisión aceptable.

Además de haber obtenido los mejores resultados mediante la CNN configurada con 4 capas convolucionales y considerando todo el proceso para llegar al ajuste óptimo de los hiperparámetros, gran parte se debe a la diversidad de los datos en cuanto a los diferentes niveles de SNR presentes en las matrices CFR. Todo esto en conjunto no solo logró una alta precisión en la predicción de las coordenadas, sino que además proporciona una robustez significativa ante el ruido, demostrando mejoras en todo sentido frente a los resultados expuestos en el Estado del Arte.

Trabajos futuros

Tras haber llevado a cabo la tarea de regresión, se propone emplear un sistema de clasificación. Este enfoque implica la utilización de las coordenadas reales como conjunto de entrenamiento, mientras que las coordenadas predichas logradas en este trabajo, serían destinadas al conjunto de prueba. La finalidad de esto radica, no solo en evaluar el rendimiento

del sistema logrado mediante regresión, sino también en la identificación de la ubicación del dispositivo en subáreas previamente divididas dentro del escenario. Esto podría ser el punto de partida para el desarrollo de aplicaciones de navegación en tiempo real en ambientes interiores, donde se determine la ubicación exacta de una persona en escenarios de mayor extensión, como un centro comercial, en el que se incluya información sobre el lugar específico o el piso en el que se encuentra. Si bien en la presente investigación se utilizó la coordenada Z para saber si una persona está sentada o de pie con el dispositivo, en este contexto se podría utilizar para saber en qué piso se encuentra. Esta transición hacia un modelo de clasificación da un enfoque más detallado, no sólo centrándose en coordenadas, sino también en la identificación de un lugar específico en el que podría ubicarse el dispositivo.

Se podría implementar modelos basados en redes pre-entrenadas como, Google-Net, Res-Net o Alex-Net, como otra alternativa para intentar mejorar la precisión en las predicciones de coordenadas, o en su defecto, generar datos sintéticos con mayor variedad de niveles de SNR, a partir de los datos originales. Esto permitiría simular peores condiciones de canal, y, en consecuencia, obtener un sistema con una mayor capacidad de generalización y robustez frente al ruido.

Referencias

Ashenden, S. K. (2021). The Era of Artificial Intelligence, Machine Learning, and Data Science in the Pharmaceutical Industry. Elsevier Inc. doi:https://doi.org/10.1016/C2019-0-01262-9

Brown, S. (21 de Abril de 2021). Machine learning, explained. Obtenido de mitsloan.mit.edu: https://mitsloan.mit.edu/ideas-made-to-matter/machine-learning-explained

CISCO. (2024). What is 5G? Obtenido de CISCO: https://www.cisco.com/c/en/us/solutions/what-is-5g.html#~faqs

Gao, K., Wang, H., Lv, H., & Liu, W. (2022). Toward 5G NR High-Precision Indoor Positioning via Channel Frequency Response: A New Paradigm and Dataset Generation Method. IEEE Journal on Selected Areas in Communications, 40(7), 2233–2247. https://doi.org/10.1109/JSAC.2022.3157397

Giuseppe, C., Kishore, A. V., & Alexis, P. (2018). Hands-On Machine Learning on Google Cloud Platform: Implementing smart and efficient analytics using Cloud ML Engine. Packt Publishing.

Hong, Y., Thaj, T., & Viterbo, E. (2022). Delay-Doppler Communications. Elsevier Inc.

Huff, S. D. (2018). Supervised Learning with Linear Regression: An Executive Review of Hot Technology. Independently published.

IBM. (03 de Noviembre de 2022). Regression trees. Obtenido de www.ibm.com: https://www.ibm.com/docs/en/db2-warehouse?topic=procedures-regression-trees

IBM. (2024). What are convolutional neural networks? Obtenido de ibm.com: https://www.ibm.com/topics/convolutional-neural-networks

IBM. (2024). What is unsupervised learning? Obtenido de ibm.com: https://www.ibm.com/topics/unsupervised-learning

Jakub, N., Mahmood, A., Ikram Ashraf, M., Bjornson, E., & Gidlund, M. (25 de Diciembre de 2022). arxiv.org. Obtenido de https://arxiv.org/pdf/2209.01183.pdf

Khandelwal, R. (2019a, February 3). Machine learning : Gradient Descent. DataDrivenInvestor. https://medium.datadriveninvestor.com/overview-of-different-optimizers-for-neural-networks-e0ed119440c3

Khandelwal, R. (2019b, February 3). Overview of different Optimizers for neural networks. DataDrivenInvestor. https://medium.datadriveninvestor.com/overview-of-different-optimizers-for-neural-networks-e0ed119440c3

Kristersson, M., & Konakanchi, P. S. (08 de Junio de 2023). Why is precise indoor positioning your best companion for 5G monetization? Obtenido de ericcson.com: https://www.ericsson.com/en/blog/2023/6/why-is-precise-indoor-positioning-your-best-companion-for-5g-monetization

Li, C., De Bast, S., Tanghe, E., Pollin, S., & Joseph, W. (2022). Toward Fine-Grained Indoor Localization Based on Massive MIMO-OFDM System: Experiment and Analysis. IEEEDataPort. https://doi.org/10.1109/JSEN.2021.3111986.

Ma, Y., Zhou, G., & Wang, S. (2019). WiFi Sensing with Channel State Information: A Survey. ACM Comput. doi:https://doi.org/10.1145/3310194

Mautz, Rainer., Ingensand, Hilmar., & Kunz, Melanie. (2010). 2D Indoor positioning system using GPS signals. International Conference on Indoor Positioning and Indoor Navigation. https://doi.org/10.1109/ICCSDET.2018.8821184

Morales, V. (2020, November 15). Redes Neuronales. https://bookdown.org/victor_morales/TecnicasML/redes-neuronales.html

Pan, M., Liu, S., Peng Liu, Qi, W., Huang, Y., Zheng, W., Wu, Q., & Gardill, M. (2023, March 14). 5G CFR/CSI dataset for wireless channel parameter estimation, array calibration, and indoor positioning | IEEE DataPort. IEEEDataPort.

Pérez, C. (2022). MACHINE LEARNING WITH MATLAB. kNN, CLUSTER ANALYSIS AND PATTERN RECOGNITION WITH NEURAL NETWORKS. Scientific Books.

Rahayu, S. R. (2022). Perbandingan Haversine Formula dan Euclidean Distance dalam Pencarian Jarak Terdekat Rumah Penampungan Hewan. Jurnal Ilmiah FIFO.

Ranimol, J., & Swapna B, S. (2018a). Indoor Positioning Using WiFi Fingerprint. International Conference on Indoor Positioning and Indoor Navigation. https://doi.org/10.1109/ICCSDET.2018.8821184

Ranimol, J., & Swapna B, S. (2018b). Performance Evaluation of Indoor Positioning Algorithm using Bluetooth Low Energy. International Conference on Indoor Positioning and Indoor Navigation, (2018). https://doi.org/10.1109/ICITSI.2018.8695934.

Sharma, P., & Machiwal, D. (2021). Advances in Streamflow Forecasting. Elsevier Inc. doi:https://doi.org/10.1016/C2019-0-02163-2

Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on Image Data Augmentation . Journal of Big Data.

Yang, Y., Chew, Y. H., & Tjhung, T. T. (2006). Frequency-domain Channel Frequency Response Estimation for Space-Time Coded MIMO Systems. 2006 IEEE International Conference on Communications, 3123-3128. doi:10.1109/ICC.2006.255285

Zaidi, A., Athley, F., Medbo, J., Gustavsson, U., Durisi, G., & Chen, X. (2018). 5G Physical Layer. Elsevier Ltd. doi:https://doi.org/10.1016/C2017-0-01973-0

Zhou, X., Chen, L., & Ruan, Y. a. (2024). Indoor positioning with multi-beam CSI of commercial 5G signals. Urban Info. doi:https://doi.org/10.1007/s44212-023-00034-4

Apéndices

Apéndice 1: Glosario de Siglas y Acrónimos

Adam: Adaptative Moment Estimation

ANN: Artificial Neural Network

BLE: Bluetooth Los Energy

CFR: Channel Frequency Response

CIR: Channel Impulse Response

CNN: Convolutional Neural Network

CSI: Channel State Información)

CSI – RS: Channel State Información - Reference Signal

DL: Deep Learning

DIS: Distributed ULA

DNN: Deep Neural Network

FkNN: Fuzzy k-Nearest Neighbors

gNB: gNodeB

GPS: Global Positioning System

IA: Inteligencia Artificial

ISAC: Integrated Sensing and Communication

k-NN: k-Nearest Neighbors

LOS: Line of Sight

LR: Linear Regression

MIMO: Múltiple Input, Múltiple Output

ML: Machine Learning

MSE: Mean Square Error

NLOS: No Line of Sight

OFDM: Orthogonal Frequency División Multiplexing

ReLU: Rectified Linear Unit

RMSE: Root Mean Square Error

RMSProp: Root Mean Square Propagation

RRU: Remote Radio Unit

RSRP: Reference Signal Received Power

RSSI: Received Signal Strength Indicador

RT: Regression Tree

SGD: Stochastic Gradient Descent

SGDM: Stochastic Gradient Descent with Momentum

SNR: Signal to Noise Ratio

UE: User Equipment

ULA: Uniform Linear Array

URA: Uniform Rectangular Array

3GPP: 3rd Generation Partnership Project